ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÁO CÁO BÀI TẬP LỚN

Nhóm 2

MÔN: XỬ LÝ ẢNH

KHẢO SÁT ẢNH HƯỞNG CỦA XỬ LÝ ẢNH ĐẾN HIỆU NĂNG NHẬN DẠNG BIỂN BÁO GIAO THÔNG TRONG ĐIỀU KIỆN THIẾU SÁNG

Giảng viên hướng dẫn: TS. Nguyễn Ngọc Giang

24100093 – Kiều Thị Thu Trang – 24100093@st.phenikaa-uni.edu.vn

24100012 – Trần Minh Sang – 24100012@st.phenikaa-uni.edu.vn

24102651 – Ngô Quang Thiện – 24102651@st.phenikaa-uni.edu.vn

github.com/kttt294/GTSRB-Low-Light-Preprocessing | image-preprocessing.techvi.io.vn

Hà Nội, tháng 10 năm 2026

MỤC LỤC

1 GIỚI THIỆU BÀI TOÁN 1
1.1 Đặt vấn đề 1
1.2 Yêu cầu và phạm vi nghiên cứu 1
1.3 Đầu vào và đầu ra của hệ thống 2
1.4 Các hướng tiếp cận và giải pháp khảo sát 2
1.5 Đóng góp triển khai và xây dựng quy trình thực nghiệm 3
1.6 Ý nghĩa và bố cục báo cáo 3
2 XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM 3
2.1 Giới thiệu bộ dữ liệu GTSRB 3
2.2 Tiền xử lý và chuẩn hóa ảnh 4
2.3 Mô hình suy giảm thiếu sáng 5
2.4 Khảo sát histogram và cấu trúc ảnh 7
2.5 Bảo đảm điều kiện so sánh công bằng 7
3 CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH 8
3.1 Nguyên tắc chung của khối tăng cường 8
3.2 Hiệu chỉnh Gamma 8
3.3 Cân bằng histogram toàn cục (HE) 9
3.4 Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE) 10
3.5 Retinex đa tỉ lệ (Multi-Scale Retinex) 11
3.6 Các phương pháp tăng cường dựa trên học sâu 12
3.7 Minh họa trước và sau xử lý 13
3.8 Đánh giá chất lượng bằng PSNR và SSIM 15
3.9 Cơ chế học sâu và liên hệ với sai số nhận dạng 15
3.10 Khử nhiễu và thứ tự xử lý 17
4 THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ 19
4.1 Thiết lập mô hình kiểm chứng ResNet-18 19
4.2 Chỉ số đánh giá nhận dạng 20
4.3 Giao thức chọn tham số và tổng hợp số liệu 20
4.4 Phạm vi đánh giá và kiểm tra bằng chứng 21
4.5 Chất lượng ảnh của các phương pháp tăng sáng 21
4.6 Nhận dạng trên subset 430 ảnh 22
4.7 Đánh giá tăng sáng trên full-test 22
4.8 Khử nhiễu và các chuỗi kết hợp 23
4.9 Ảnh hưởng của thứ tự trên full-test 25
5 THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN 26
5.1 Chất lượng ảnh cao có bảo đảm nhận dạng tốt? 26
5.2 Phương pháp và kết quả phân tích tương quan 26
5.3 Ablation: tách độ tối và từng thành phần nhiễu 26
5.4 Diễn giải hiệu quả khử nhiễu và thứ tự 27
5.5 Chi phí xử lý và giới hạn triển khai 28
5.6 Phân tích lỗi ghép cặp và theo lớp 30
6 ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ 36
6.1 Tiêu chí lựa chọn 36
6.2 Quy trình được lựa chọn 36
6.3 Đối chứng và tổ chức cài đặt 37
6.4 Hướng đánh giá tiếp theo 37
6.5 Tái lập thực nghiệm 37
7 KẾT LUẬN 38
TÀI LIỆU THAM KHẢO 39

1. GIỚI THIỆU BÀI TOÁN

1.1. Đặt vấn đề

Trong các hệ thống hỗ trợ lái xe và giao thông thông minh, biển báo cung cấp những thông tin trực tiếp về giới hạn tốc độ, hướng di chuyển và các tình huống cần cảnh báo. Khả năng nhận dạng đúng biển báo phụ thuộc trước hết vào chất lượng hình ảnh mà hệ thống tiếp nhận. Khi điều kiện chiếu sáng suy giảm, những đặc trưng quan trọng như đường viền, chữ số và mũi tên có thể trở nên khó phân biệt, ngay cả khi vị trí của biển báo đã được xác định.

Một hướng giải quyết thường được cân nhắc là tăng cường ảnh trước khi đưa vào mô hình nhận dạng. Tuy nhiên, tăng độ sáng không đồng nghĩa với phục hồi đầy đủ thông tin. Một phép biến đổi có thể làm vùng tối dễ quan sát hơn nhưng đồng thời khuếch đại nhiễu, thay đổi màu sắc hoặc làm nhòe những chi tiết nhỏ. Đối với biển báo giao thông, chỉ một nét bị mất trong chữ số hoặc một hướng mũi tên bị biến dạng cũng có thể dẫn đến dự đoán sai lớp.

Từ đó, bài toán được đặt ra là: *các phương pháp xử lý ảnh cải thiện chất lượng ảnh thiếu sáng đến mức nào, và sự cải thiện đó có thực sự giúp mô hình nhận dạng chính xác hơn hay không?* Đây là câu hỏi cần được trả lời bằng cả thước đo chất lượng ảnh lẫn kết quả nhận dạng trên cùng một điều kiện thực nghiệm.

Thứ nhất, suy giảm độ sáng đi kèm với suy giảm tỷ lệ tín hiệu trên nhiễu. Vùng tối có biên độ tín hiệu nhỏ, do đó nhiễu có thể chiếm tỷ lệ đáng kể so với thông tin hữu ích. Nếu chỉ áp dụng phép tăng sáng, phần nhiễu cũng được nâng lên cùng với cấu trúc của biển báo. Vì vậy, đánh giá một phương pháp trên ảnh chỉ làm tối bằng Gamma sẽ chưa phản ánh đầy đủ trường hợp ảnh đồng thời chứa nhiễu.

Thứ hai, chất lượng ảnh và chất lượng đặc trưng nhận dạng không hoàn toàn trùng nhau. PSNR phản ánh sai số cường độ điểm ảnh, còn SSIM xem xét độ tương đồng về cấu trúc cục bộ. Trong khi đó, mô hình nhận dạng học những đặc trưng phục vụ phân lớp. Một ảnh có sai số trung bình thấp vẫn có thể làm mất nét của chữ số; ngược lại, một ảnh khác ảnh tham chiếu về độ sáng vẫn có thể giữ được hình dạng cần thiết để nhận dạng.

Thứ ba, so sánh thuật toán cần kiểm soát các yếu tố ngoài xử lý ảnh. Nếu thay đổi kiến trúc mô hình hoặc huấn luyện lại riêng cho từng phương pháp tăng cường, rất khó tách biệt phần cải thiện đến từ ảnh và phần cải thiện đến từ mô hình. Bài tập lớn vì thế sử dụng duy nhất kiến trúc ResNet-18, huấn luyện trên ảnh gốc và giữ cố định trọng số khi so sánh các phép xử lý.

1.2. Yêu cầu và phạm vi nghiên cứu

Đề bài yêu cầu khảo sát ảnh hưởng của xử lý ảnh đến hiệu năng nhận dạng biển báo giao thông trong điều kiện thiếu sáng trên bộ dữ liệu GTSRB. Ảnh suy giảm được mô phỏng bằng Gamma kết hợp nhiễu Gaussian và Poisson ở nhiều mức độ. Các phương pháp tăng cường cần so sánh gồm hiệu chỉnh Gamma, cân bằng histogram (HE), cân bằng histogram cục bộ có giới hạn tương phản (CLAHE), Retinex, Zero-DCE, Retinexformer và phương pháp dựa trên diffusion.

Nghiên cứu còn so sánh Gaussian, bilateral và Non-local Means khi dùng đơn lẻ, cùng hai thứ tự phối hợp với Gamma và CLAHE. Độ mạnh bộ lọc được chọn trên validation và giữ giống nhau trong từng cặp thứ tự. Chất lượng ảnh được đánh giá bằng PSNR và SSIM. Hiệu năng nhận dạng được đo bằng Accuracy và F1-score, trong đó Macro-F1 là tiêu chí chính để tránh đánh giá thiên lệch về các lớp có nhiều ảnh. Kết quả được dùng để phân tích tương quan giữa chất lượng ảnh và khả năng nhận dạng, từ đó lựa chọn quy trình tiền xử lý phù hợp.

Trong phạm vi triển khai, đầu vào là vùng ảnh đã chứa biển báo, không phải toàn cảnh giao thông. Hệ thống giải quyết bài toán phân loại vào một trong 43 lớp của GTSRB; chưa bao gồm phát hiện vị trí biển báo, theo dõi đối tượng hoặc xử lý video. Điều kiện thiếu sáng được tạo có kiểm soát từ ảnh gốc, do đó có ảnh tham chiếu tương ứng để tính PSNR và SSIM.

1.3. Đầu vào và đầu ra của hệ thống

Đầu vào: ảnh màu RGB sau khi cắt vùng quan tâm và đưa về kích thước 64×64 pixel. Giá trị cường độ được chuẩn hóa về đoạn $[0, 1]$. Từ ảnh gốc X, mô hình suy giảm tạo ảnh thiếu sáng Y với một mức tối và một hạt giống sinh nhiễu xác định.

Đầu ra của khối xử lý ảnh: ảnh tăng cường $\widehat{X} = E(Y)$ có cùng kích thước, thứ tự kênh màu và miền giá trị với đầu vào. Hàm E chỉ nhận ảnh thiếu sáng; ảnh tham chiếu và nhãn lớp không được đưa vào thuật toán tăng cường.

Đầu ra của khối nhận dạng: vector 43 giá trị dự đoán và nhãn lớp có giá trị lớn nhất. Trước khi đi qua ResNet-18, ảnh được nội suy lên 224×224 và chuẩn hóa theo ImageNet. Việc đổi kích thước này chỉ phục vụ mô hình nhận dạng; các phép tăng cường và đo chất lượng ảnh vẫn thực hiện ở 64×64.

Đầu ra nghiên cứu: bảng so sánh PSNR, SSIM, Accuracy, Macro-F1, thời gian xử lý; hình ảnh trực quan; phân tích ablation và tương quan; cùng một phương án tiền xử lý được chọn trên validation trước khi đánh giá test.

1.4. Các hướng tiếp cận và giải pháp khảo sát

Nhóm phương pháp truyền thống tác động trực tiếp lên cường độ hoặc phân bố mức xám. Gamma điều chỉnh phi tuyến từng điểm ảnh; HE phân phối lại histogram toàn cục; CLAHE xử lý theo vùng; Retinex ước lượng quan hệ giữa thành phần chiếu sáng và phản xạ. Những phương pháp này có ưu điểm dễ giải thích, ít tham số và chi phí tính toán tương đối thấp.

Nhóm phương pháp học sâu sử dụng thông tin đã học để điều chỉnh hoặc phục hồi ảnh. Zero-DCE ước lượng đường cong tăng sáng, Retinexformer kết hợp biểu diễn chiếu sáng với Transformer, còn phương pháp diffusion được khảo sát thực hiện phục hồi có điều kiện trong miền wavelet. Dự án sử dụng trọng số công bố của tác giả, không huấn luyện lại các bộ tăng cường trên GTSRB [1], [2], [3].

Giải pháp của bài tập lớn không giả định một nhóm phương pháp luôn tốt hơn nhóm còn lại. Tất cả được đánh giá trên cùng ảnh suy giảm, cùng tập mẫu và cùng các checkpoint

ResNet-18. Mốc đối chứng là *Identity*, tức ảnh tối giữ nguyên. Ảnh gốc *Clean* được dùng làm tham chiếu và kiểm tra hiệu năng nhận dạng khi chưa áp dụng mô hình suy giảm.

1.5. Đóng góp triển khai và xây dựng quy trình thực nghiệm

Nhóm xây dựng quy trình chuẩn bị dữ liệu từ các archive GTSRB chính thức, gồm đọc ảnh PPM và annotations, chuyển ảnh sang RGB, cắt vùng biển báo theo ROI với padding 5% và nội suy song tuyến tính về kích thước 64×64. Các bước này vận dụng kiến thức về biểu diễn ảnh, hệ tọa độ, phép cắt và lấy mẫu lại; đồng thời tạo đầu vào thống nhất cho tất cả phương pháp tăng cường và bộ phân loại. Chi tiết cài đặt và ý nghĩa của các lựa chọn được trình bày trong phần xây dựng tập dữ liệu.

Trong quá trình mô phỏng suy giảm và tăng cường, ảnh được biểu diễn bằng số thực trong miền $[0, 1]$; nhóm tăng sáng lưu kết quả trung gian bằng NumPy, còn khảo sát khử nhiễu/kết hợp truyền trực tiếp mảng float32 trong bộ nhớ để hạn chế lượng tử hóa và I/O bổ sung. Riêng HE, CLAHE và NLM có bước chuyển sang ảnh 8 bit theo cài đặt OpenCV, được mô tả rõ trong phần phương pháp. Việc thống nhất miền giá trị, thứ tự kênh và kích thước ảnh giúp tránh sai khác ngoài thuật toán khi so sánh PSNR, SSIM và hiệu năng phân loại.

Nhóm kết hợp quy trình xử lý ảnh với kiểm tra trùng lặp, chia dữ liệu theo track và lưu checksum cùng thông tin nguồn để hỗ trợ tái lập thí nghiệm. Giá trị của phần triển khai nằm ở khả năng kiểm soát, giải thích và kiểm chứng toàn bộ luồng dữ liệu; thao tác tải, giải nén và gom annotations là các bước hỗ trợ. Đây là đóng góp về triển khai và thiết kế thực nghiệm, không phải đề xuất thuật toán xử lý ảnh mới. Padding, kích thước crop và phép nội suy được trình bày là các quyết định thiết kế; chưa có thí nghiệm so sánh riêng để khẳng định chúng là cấu hình tối ưu.

1.6. Ý nghĩa và bố cục báo cáo

Về kiến thức xử lý ảnh, đề tài kết nối phép biến đổi điểm, histogram, lọc Gaussian, mô hình nhiễu và các chỉ số chất lượng trong một quy trình thống nhất. Về thực nghiệm, đề tài làm rõ sự đánh đổi giữa độ sáng, mức nhiễu, tính toàn vẹn của chi tiết và chi phí suy luận. ResNet-18 đóng vai trò công cụ kiểm chứng thông tin được giữ lại sau xử lý, thay vì là đối tượng tối ưu chính của báo cáo.

Các phần tiếp theo lần lượt trình bày dữ liệu và mô hình suy giảm; cơ sở và cài đặt các phương pháp tăng cường; thiết lập cùng kết quả thực nghiệm; phân tích tương quan và ảnh hưởng của nhiễu; quy trình tiền xử lý được đề xuất; cuối cùng là kết luận và giới hạn của nghiên cứu.

2. XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM

2.1. Giới thiệu bộ dữ liệu GTSRB

German Traffic Sign Recognition Benchmark (GTSRB) là bộ dữ liệu phân loại biển báo giao thông với 43 lớp [4]. Trong dữ liệu dự án, tập huấn luyện chính thức có 39.209 ảnh và tập kiểm thử chính thức có 12.630 ảnh. Các ảnh khác nhau về góc quan sát, kích thước biển

báo, nền cảnh và điều kiện chiếu sáng. Đây là những yếu tố khiến việc tăng cường ảnh cần giữ được đặc trưng hình học và màu sắc thay vì chỉ nâng giá trị sáng trung bình.

Một số ảnh huấn luyện được chụp liên tiếp từ cùng một biển báo. Những ảnh thuộc cùng chuỗi quan sát có mức tương đồng cao. Nếu chia train và validation ngẫu nhiên ở cấp ảnh, các khung gần giống nhau có thể xuất hiện ở cả hai tập, làm kết quả validation lạc quan hơn khả năng tổng quát thực tế. Vì vậy, dự án chia dữ liệu theo lớp và *track*, giữ các ảnh cùng track trong một tập.

Bảng 1. Phân chia dữ liệu trong quy trình ResNet-18.

Tập dữ liệu	Số ảnh	Vai trò
Huấn luyện	31.350	Huấn luyện ResNet-18 trên ảnh gốc
Validation	7.829	Chọn checkpoint và đánh giá trong huấn luyện
Cách ly	30	Loại track có ảnh trùng pixel với test khỏi huấn luyện
Official test	12.630	Kiểm thử toàn bộ tập chính thức
Validation chọn xử lý	1.290	30 ảnh/lớp để chọn tham số tăng cường
Test khảo sát	430	10 ảnh/lớp cho notebook và ablation

Tập cách ly gồm 30 ảnh thuộc track có ảnh trùng pixel với tập test, theo kiểm kê được ghi trong dự án. Toàn bộ track được tách ra để tránh chỉ loại những ảnh trùng chính xác nhưng vẫn giữ các khung gần kề. Tổng số ảnh train, validation và cách ly bằng 39.209; test chính thức được giữ riêng. Hạt giống chia dữ liệu là 42.

Các tập 1.290 và 430 ảnh là những tập con của validation và test, không phải dữ liệu bổ sung. Việc lấy cùng số ảnh mỗi lớp giúp khảo sát cân bằng 43 lớp và giảm chi phí chạy nhiều phương pháp. Tuy nhiên, kết quả trên 430 ảnh không đại diện đầy đủ cho phân bố tần suất của 12.630 ảnh test; báo cáo vì thế trình bày hai phạm vi này thành các bảng riêng.

2.2. Tiền xử lý và chuẩn hóa ảnh

2.2.1. Nguồn nhãn và hình thức học

Gói `GTSRB_Final_Training_Images.zip` đã chứa ảnh và annotations; mỗi thư mục lớp có file `GT-<ClassID>.csv`. Cột `ClassId` cung cấp nhãn 0–42, các cột ROI cung cấp vị trí biển báo. Nhãn test được tải riêng trong `GTSRB_Final_Test_GT.zip` [5]. Vì vậy, không tải một file GT train riêng không đồng nghĩa với dữ liệu train không có nhãn.

Bộ phân loại ResNet-18 học có giám sát: mỗi mẫu trả về cặp ảnh–nhãn, dùng cross-entropy và cập nhật toàn mạng. Ba enhancer học sâu chỉ nạp trọng số tác giả để suy luận; Zero-DCE gốc có cơ chế zero-reference, nhưng điều đó không làm bài toán phân loại GTSRB của dự án trở thành học không giám sát. Các thuật toán truyền thống không có bước huấn luyện.

2.2.2. Cắt vùng quan tâm

Vùng quan tâm (Region of Interest, ROI) được xác định bằng tọa độ chú thích của dữ liệu. Dự án mở rộng vùng này thêm 5% kích thước theo mỗi phía, đồng thời giới hạn khung cắt trong kích thước ảnh. Phần lề nhỏ giúp giữ đường viền biển báo và một lượng ngữ cảnh xung quanh; nếu cắt sát quá mức, những pixel biên có thể bị loại bỏ trước khi thuật toán tăng cường hoạt động.

Với ROI (x_1, y_1, x_2, y_2) có điểm cuối bao gồm trong vùng, mã nguồn chuyển x_2, y_2 sang mốc cuối không bao gồm bằng cách cộng 1. Sau đó tính độ mở rộng theo chiều rộng và chiều cao, làm tròn ra ngoài bằng phép lấy sàn/lấy trần và chặn tại biên ảnh. Quy ước này tránh bỏ mất hàng hoặc cột pixel cuối cùng khi cắt bằng thư viện ảnh.

2.2.3. Đổi kích thước và miền cường độ

Ảnh ROI được đổi sang RGB, nội suy song tuyến tính về 64×64 rồi lưu dưới dạng chuẩn hóa:

$$X \in [0,1]^{64\times64\times3}, \qquad X = \frac{I_{\text{8-bit}}}{255}. \tag{1}$$

Nội suy song tuyến tính sử dụng tổ hợp có trọng số của các pixel lân cận. Cách làm này phù hợp với yêu cầu đưa các vùng biển báo có kích thước khác nhau về cùng đầu vào, nhưng có thể làm mềm các nét vốn rất nhỏ. Do đó, quá trình phóng lên 224×224 sau tăng cường không tạo lại thông tin đã mất ở bước chuẩn hóa 64×64.

Các thuật toán làm việc với số thực `float32`. Riêng HE và CLAHE chuyển ảnh sang số nguyên 8 bit để dùng các phép xử lý histogram của OpenCV rồi chuyển trở lại số thực. Việc lượng tử hóa ở hai phương pháp này là một phần của cách cài đặt, cần được phân biệt với các phương pháp thực hiện trực tiếp trên giá trị liên tục.

2.3. Mô hình suy giảm thiếu sáng

Mô hình suy giảm được áp dụng theo thứ tự cố định: Gamma làm tối, nhiễu Poisson, nhiễu Gaussian và cuối cùng chặn về $[0, 1]$. Với một pixel của ảnh gốc X, quá trình được mô tả bởi:

$$U = X^{\gamma_d}, \tag{2}$$

$$V = \frac{\mathcal{P}(pU)}{p}, \tag{3}$$

$$Y = \text{clip}\big(V + \varepsilon, 0, 1\big), \quad \varepsilon \sim \mathcal{N}(0, \sigma_n^2). \tag{4}$$

Trong đó $\gamma_d > 1$ điều khiển mức tối, p là hệ số Poisson và σ_n là độ lệch chuẩn nhiễu Gaussian. Phép lũy thừa áp dụng theo từng kênh RGB trong miền ảnh chuẩn hóa; đây là mô hình suy giảm tổng hợp, không phải mô phỏng đầy đủ quá trình thu nhận ánh sáng của cảm biến RAW.

2.3.1. Vai trò của Gamma làm tối

Với $0 < X < 1$ và $\gamma_d > 1$, ta có $X^{\gamma_d} < X$. Khi tăng γ_d, vùng trung gian bị kéo về cường độ thấp mạnh hơn. Ví dụ, một pixel có cường độ 0,5 trở thành khoảng 0,354; 0,218 và 0,125 khi γ_d lần lượt bằng 1,5; 2,2 và 3,0. Điểm đen 0 và điểm trắng 1 vẫn được giữ ở hai đầu miền.

Điều này giải thích vì sao ảnh tối có histogram dịch về bên trái mà vùng phản xạ rất sáng vẫn có thể còn rõ. Phép Gamma tạo được nhiều mức suy giảm với tham số dễ kiểm soát, đồng thời vẫn giữ quan hệ xác định giữa ảnh gốc và ảnh tối khi chưa thêm nhiễu.

2.3.2. Vai trò của nhiễu Poisson và Gaussian

Trước bước chặn, nhiễu Poisson trong công thức (3) có kỳ vọng U và phương sai U/p. Khi p giảm, mức dao động tăng. Mặc dù phương sai tuyệt đối nhỏ ở vùng tối, độ lệch chuẩn tương đối so với tín hiệu là $1/\sqrt{pU}$, có thể lớn khi U rất nhỏ. Đây là đặc điểm quan trọng khi khảo sát tính nhạy nhiễu của phép tăng sáng.

Nhiễu Gaussian được cộng với độ lệch chuẩn cố định cho mọi pixel. Trong mô hình này, nó đại diện cho một thành phần nhiễu cộng đơn giản. Khi tín hiệu sau Gamma nhỏ, cùng một mức nhiễu Gaussian sẽ gây ảnh hưởng tương đối lớn hơn đến nội dung. Bước chặn cuối cùng bảo đảm ảnh nằm trong miền hợp lệ, nhưng cũng làm phân bố nhiễu gần 0 hoặc 1 không còn hoàn toàn đối xứng.

Bảng 2. Ba mức suy giảm sử dụng trong thí nghiệm.

Mức độ	γ_d	Poisson p	Gaussian σ_n
Nhẹ (mild)	1,5	120	0,005
Vừa (medium)	2,2	60	0,010
Nặng (severe)	3,0	30	0,020

Ba mức trong Bảng 2 thay đổi đồng thời độ tối và hai thành phần nhiễu. Vì vậy, sự chênh lệch giữa mức nhẹ và mức nặng phản ánh tổng tác động của cả ba yếu tố. Muốn xác định riêng ảnh hưởng của nhiễu, cần dùng thí nghiệm ablation giữ nguyên Gamma và lần lượt bật/tắt từng loại nhiễu, được trình bày ở phần thảo luận.

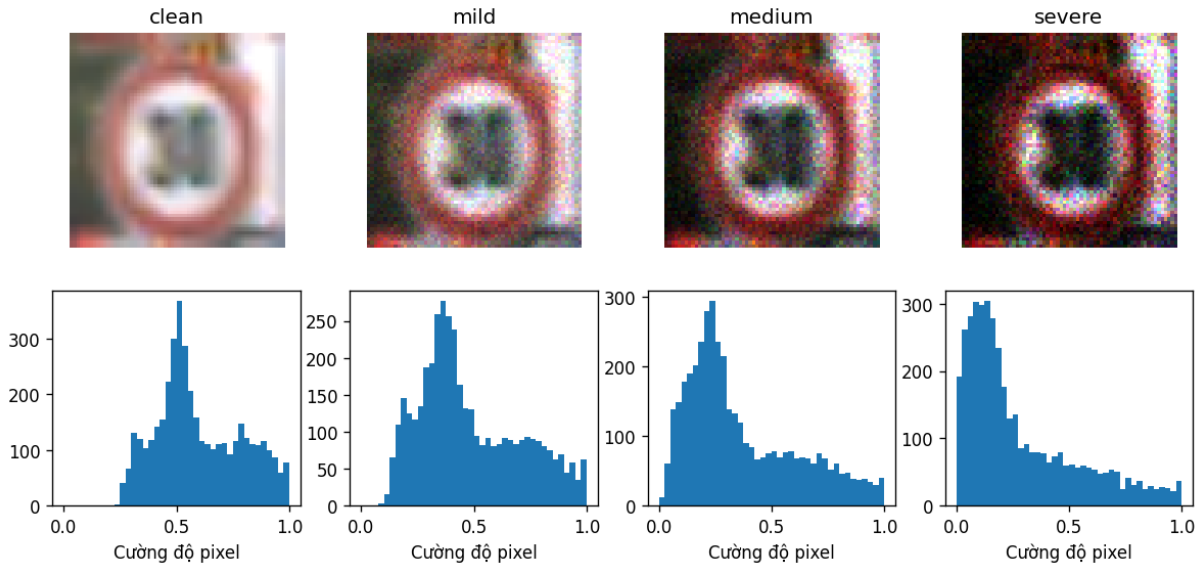
2.3.3. Nhiễu sau nội suy và giới hạn mô hình

Nghiên cứu cắt và resize ảnh gốc về 64×64 trước khi sinh nhiễu. Gọi R là toán tử lấy mẫu lại và S là phép suy giảm, đầu vào đang xét là $S(R(X))$, khác với $R(S(X))$. Với nhiễu cộng độc lập ở độ phân giải nguồn, một pixel nội suy $\sum_j w_j(X_j + \varepsilon_j)$ có phương sai nhiễu $\sigma^2 \sum_j w_j^2$; các pixel đầu ra dùng chung lân cận còn có thể tương quan. Trong khi đó, thêm Gaussian sau resize dùng phương sai σ_n^2 trực tiếp tại từng pixel crop. Poisson phụ thuộc tín hiệu và Gamma phi tuyến càng khiến hai thứ tự không tương đương.

Thiết kế này giữ kích thước và mức nhiễu đầu vào thống nhất để cô lập ảnh hưởng của tiền xử lý. Nó không tái hiện chuỗi cảm biến RAW, giải khảm màu, xử lý tín hiệu, nội suy và

nén của camera. Gaussian đơn giản có thể phù hợp với một thành phần được tạo trực tiếp trong mô hình, nên lợi ích đo được chưa chứng minh ưu thế với nhiễu đã qua xử lý camera. Chưa có ablation đổi vị trí sinh nhiễu hoặc độ phân giải để định lượng độ lệch này; không suy diễn mức độ ảnh hưởng chỉ từ lập luận lý thuyết.

2.4. Khảo sát histogram và cấu trúc ảnh



Hình 1. Ảnh tham chiếu và ba mức suy giảm trên cùng một crop validation. Hàng dưới là histogram cường độ xám; trục đứng biểu thị số pixel. Hình trích trực tiếp từ notebook ResNet-18, noise seed 101.

Quan sát Hình 1, vùng nền sáng của biển báo suy giảm rõ khi tăng mức tối. Các nét số trở nên khó phân biệt với nền và nhiễu màu xuất hiện trên cả vùng tương đối đồng nhất. Histogram tập trung ngày càng nhiều tại cường độ thấp; độ tương phản giữa các cấu trúc hữu ích không thể được suy ra chỉ từ việc histogram còn trải rộng đến gần 1.

Trên riêng ảnh minh họa này, PSNR của mức nhẹ, vừa và nặng lần lượt là 17,2577; 12,0942; 9,5306 dB. SSIM tương ứng là 0,7120; 0,5494; 0,3855. Đây là số đo của một ảnh validation được chọn theo quy tắc trong notebook, không phải giá trị trung bình của toàn bộ tập test.

Histogram chỉ biểu diễn tần suất cường độ, không chứa vị trí của pixel. Hai ảnh có histogram gần nhau vẫn có thể khác hoàn toàn về bố trí đường viền hoặc chữ số. Vì vậy, phân tích histogram trong báo cáo luôn đi kèm quan sát ảnh, SSIM và kết quả nhận dạng, tránh kết luận chất lượng chỉ từ sự dịch chuyển phân bố mức xám.

2.5. Bảo đảm điều kiện so sánh công bằng

Hạt giống sinh nhiễu được xác định từ noise seed, mã mẫu và tên điều kiện. Ba noise seed là 101, 202 và 303. Với cùng mã ảnh, cùng mức suy giảm và cùng noise seed, tất cả các phương pháp nhận đúng một ảnh tối. Cách thiết kế này tránh việc một thuật toán vô tình được đánh giá trên nhiễu nhẹ hơn thuật toán khác.

Ảnh gốc chỉ được sử dụng để tính chất lượng sau tăng cường. Nhãn lớp chỉ phục vụ huấn luyện bộ nhận dạng, chọn tham số bằng validation và tính metric. Các tập con, cấu hình và checkpoint được khóa trước test. Những ràng buộc này giúp quy kết thay đổi kết quả chủ yếu cho phép xử lý ảnh đang khảo sát trong phạm vi giao thức đã định.

3. CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH

3.1. Nguyên tắc chung của khối tăng cường

Nhiệm vụ của khối tăng cường là biến đổi ảnh thiếu sáng Y thành ảnh $\widehat{X}$ có độ sáng và cấu trúc phù hợp hơn cho quan sát cũng như nhận dạng. Mọi phương pháp đều tuân thủ cùng giao diện: nhận một ảnh RGB 64×64 trong $[0, 1]$, trả lại ảnh cùng kích thước và không truy cập ảnh tham chiếu. Điều này cho phép đánh giá phương pháp truyền thống và học sâu trong cùng quy trình.

Identity giữ nguyên ảnh tối: $E(Y) = Y$. Đây là mốc bắt buộc để xác định lợi ích thực của tăng cường. Một thuật toán có ảnh đầu ra sáng hơn nhưng Accuracy hoặc Macro-F1 thấp hơn Identity được xem là làm giảm hiệu quả nhận dạng trong điều kiện đó.

Clean là ảnh gốc trước suy giảm. Clean không phải một thuật toán phục hồi và không tham gia lựa chọn bộ tăng cường. Vai trò của nó là tạo mức hiệu năng tham chiếu, cho biết khoảng cách còn lại giữa ảnh sau xử lý với điều kiện đầu vào ban đầu.

3.2. Hiệu chỉnh Gamma

3.2.1. Cơ sở toán học

Hiệu chỉnh Gamma tăng sáng bằng phép lũy thừa:

$$\widehat{X} = Y^{\alpha}, \qquad 0 < \alpha < 1. \tag{5}$$

Với cường độ nằm giữa 0 và 1, số mũ nhỏ hơn 1 làm đầu ra lớn hơn đầu vào. Khi α giảm, mức nâng sáng mạnh hơn. Ví dụ, pixel 0,1 trở thành 0,158 với $\alpha = 0,8$; 0,251 với $\alpha = 0,6$ và 0,398 với $\alpha = 0,4$.

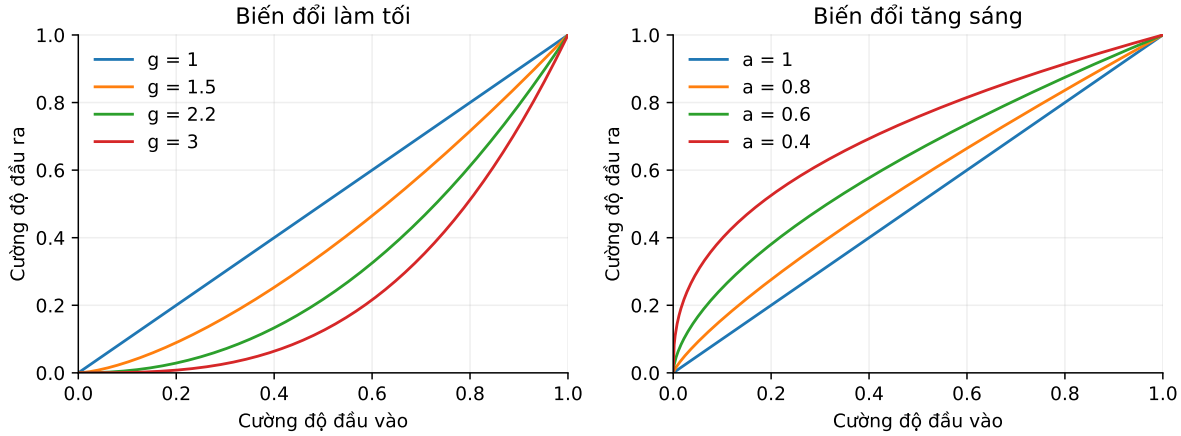
Trong trường hợp lý tưởng chỉ có Gamma làm tối, lựa chọn $\alpha = 1/\gamma_d$ sẽ khôi phục cường độ ban đầu vì $(X^{\gamma_d})^{1/\gamma_d} = X$. Khi có Poisson, Gaussian và bước chặn, phép biến đổi này không còn là nghịch đảo chính xác. Đặc biệt, clipping đã loại bỏ một phần thông tin nên không thể đảo ngược chỉ bằng một hàm điểm.

3.2.2. Ảnh hưởng đến nhiễu và cách cài đặt

Độ nhạy cục bộ của hàm tăng sáng đối với đầu vào được mô tả bởi:

$$\frac{\mathrm{d}Y^{\alpha}}{\mathrm{d}Y} = \alpha Y^{\alpha-1}. \tag{6}$$

Khi Y nhỏ và $\alpha < 1$, hệ số này có thể lớn. Với nhiễu nhỏ, cách xấp xỉ tuyến tính cho thấy nhiễu đầu vào có thể bị khuếch đại trong vùng tối. Đây là cơ sở để giải thích tại sao giảm Gamma quá mạnh làm hình ảnh sáng rõ nhưng cũng khiến nhiễu hạt nổi bật hơn.



Hình 2. Đường cong Gamma làm tối và tăng sáng trên miền $[0, 1]$. Đây là đồ thị giải tích của phép biến đổi, không phải kết quả đo trên tập ảnh.

Trong mã nguồn, Gamma được thực hiện trực tiếp bằng phép toán lũy thừa trên mảng RGB số thực, không chuyển qua ảnh 8 bit. Không có phép lọc không gian hoặc khử nhiễu kèm theo. Lưới validation khảo sát $\alpha \in \{0,4; 0,6; 0,8\}$. Notebook ResNet-18 chọn $\alpha = 0,8$, tương ứng mức tăng sáng tương đối nhẹ.

Ưu điểm: cài đặt đơn giản, chi phí thấp, giữ quan hệ đơn điệu của cường độ. **Hạn chế:** sử dụng cùng quy tắc ở mọi vị trí, không thích ứng với ánh sáng không đồng đều và không phân biệt nét thật với nhiễu. Do áp dụng phi tuyến theo từng kênh, phương pháp cũng không bảo đảm giữ nguyên tỷ lệ giữa các thành phần màu.

3.3. Cân bằng histogram toàn cục (HE)

3.3.1. Nguyên lý phân phối lại mức xám

Histogram mô tả số pixel xuất hiện tại mỗi mức cường độ. Với ảnh có L mức xám, ký hiệu n_k là số pixel tại mức k và N là tổng số pixel. Histogram chuẩn hóa và hàm phân phối tích lũy được viết:

$$p(k) = \frac{n_k}{N}, \qquad C(k) = \sum_{j=0}^{k} p(j). \tag{7}$$

Một phép ánh xạ cân bằng điển hình đưa mức xám về:

$$T(k) = \text{round}\left((L-1)\frac{C(k) - C_{\min}}{1 - C_{\min}} \right), \tag{8}$$

trong đó $C_{\min}$ là giá trị CDF khác 0 đầu tiên. Trường hợp ảnh hằng cần được xử lý riêng để tránh mẫu số bằng 0. HE giúp mở rộng khoảng mức xám đang bị tập trung, song không bảo đảm histogram rời rạc sau biến đổi sẽ phẳng hoàn toàn.

3.3.2. Xử lý trên kênh độ sáng

Nếu cân bằng độc lập R, G và B, ba phép ánh xạ có thể khác nhau và làm biến đổi mạnh màu sắc. Dự án chuyển ảnh từ RGB sang YCrCb, chỉ áp dụng `equalizeHist` trên kênh Y, giữ hai kênh màu rồi chuyển lại RGB. Trước khi đổi không gian màu, ảnh được nhân 255, làm tròn và chuyển sang `uint8`; sau xử lý được chia 255 để trở lại $[0, 1]$.

Việc chỉ tác động lên Y giúp hạn chế sai lệch màu so với cân bằng độc lập từng kênh. Tuy nhiên, quá trình lượng tử hóa và chặn miền khi chuyển đổi vẫn có thể làm thay đổi đầu ra. Do đó, không nên mô tả HE như một phép biến đổi bảo toàn màu tuyệt đối.

HE sử dụng thống kê toàn ảnh, nên vùng nền sáng và vùng biển báo tối cùng đóng góp vào một hàm ánh xạ. Trong ảnh có chiếu sáng không đồng đều, cùng một mức xám thuộc các vùng khác nhau vẫn được xử lý giống nhau. Đây là lý do tăng tương phản toàn cục có thể làm một số vùng dễ quan sát hơn nhưng đồng thời bão hòa các vùng vốn đã sáng [6].

Ưu điểm: không phải chọn tham số tăng sáng, dễ triển khai và nhanh. **Hạn chế:** có thể tăng nhiễu, thay đổi phân bố sáng quá mạnh và làm mất thông tin trong vùng bị bão hòa. Với crop nhỏ, histogram cũng nhạy với tỷ lệ nền và kích thước phần biển báo trong ảnh.

3.4. Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE)

3.4.1. Từ xử lý toàn cục đến xử lý cục bộ

CLAHE [7] chia ảnh thành một lưới ô và xây dựng phép ánh xạ histogram cho từng ô. Cách tiếp cận cục bộ giúp xử lý các vùng có điều kiện chiếu sáng khác nhau. Tuy nhiên, nếu cân bằng cục bộ không giới hạn, một vùng gần như đồng nhất có thể bị kéo giãn tương phản mạnh và làm nhiễu nổi rõ. CLAHE giải quyết điều này bằng cách giới hạn chiều cao histogram trước khi xây dựng CDF.

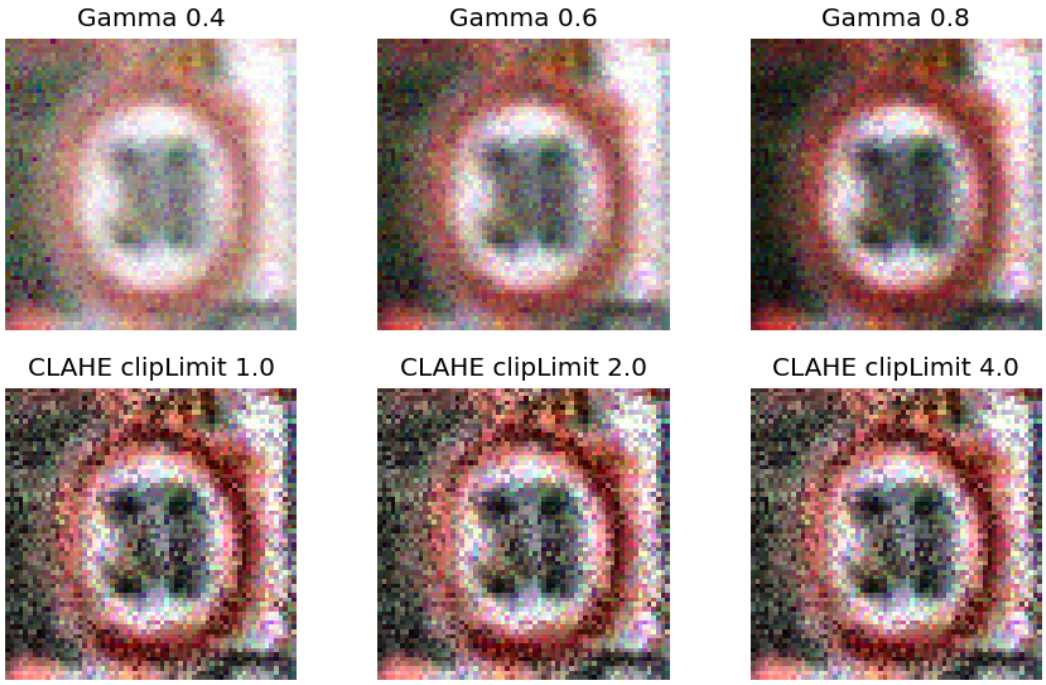
Quy trình gồm bốn bước: tính histogram mỗi ô; cắt các bin vượt ngưỡng; phân phối lại lượng dư; xây dựng ánh xạ và nội suy giữa các ô. Nội suy ở ranh giới giúp giảm hiện tượng xuất hiện các khối vuông sau xử lý. Trong triển khai của dự án, toàn bộ phép này được áp dụng trên kênh Y, tương tự HE.

3.4.2. Ý nghĩa tham số và ảnh hưởng kích thước ảnh

Hai tham số chính là `clipLimit` và `tileGridSize`. Tham số thứ nhất điều khiển mức giới hạn histogram theo quy ước OpenCV; không phải ngưỡng cường độ sáng của pixel. Tham số thứ hai là số ô theo hai chiều, không phải kích thước mỗi ô tính bằng pixel. Với ảnh 64×64, lưới 8×8 tạo ô khoảng 8×8 pixel, còn lưới 4×4 tạo ô khoảng 16×16 pixel.

Ở ô quá nhỏ, số mẫu dùng để ước lượng histogram ít, dễ khiến thống kê bị ảnh hưởng bởi nhiễu và từng nét của biển báo. Lưới thưa hơn có thể ổn định hơn nhưng mức thích ứng không gian cũng giảm. Do vậy, cấu hình tốt trên ảnh độ phân giải cao chưa chắc tốt khi chuyển sang crop 64×64.

Lưới validation khảo sát ba giá trị clip limit $\{1, 2, 4\}$ kết hợp hai lưới $\{4\times4, 8\times8\}$. Notebook chọn clip limit bằng 1 và lưới 4×4. Đây là kết quả lựa chọn bằng khả năng nhận dạng trên validation, không phải tham số được chọn bằng cách nhìn ảnh test.



Hình 3. Ảnh hưởng của Gamma và clip limit trên cùng ảnh tối mức vừa. Hàng dưới giữ lưới CLAHE 8×8 để minh họa riêng tham số clip limit; đây không phải cấu hình CLAHE được chọn cuối cùng.

Với ô nhỏ, các giá trị clip limit danh nghĩa khác nhau có thể tạo cùng ngưỡng hiệu dụng. Với ô 8×8 có 64 pixel và 256 bin, việc quy đổi ngưỡng cắt về số nguyên trong OpenCV có thể đưa các giá trị này về cùng ngưỡng hiệu dụng. Vì vậy, đổi tham số danh nghĩa chưa chắc tạo ra đầu ra khác trên ảnh nhỏ. Nhận định này phù hợp với cài đặt thư viện và quan sát thí nghiệm, không nên suy rộng thành tính chất chung cho mọi kích thước ảnh.

Ưu điểm: tăng tương phản theo vùng, kiểm soát tốt hơn sự khuếch đại histogram và có chi phí tính toán thấp hơn nhiều so với các bộ phục hồi sâu. **Hạn chế:** vẫn có thể làm nhiễu rõ hơn; chất lượng phụ thuộc tương tác giữa clip limit, lưới và độ phân giải.

3.5. Retinex đa tỉ lệ (Multi-Scale Retinex)

Cơ sở MSR dựa trên công trình của Jobson, Rahman và Woodell [8]; biến thể dưới đây được giản lược theo mã nguồn của dự án.

3.5.1. Mô hình phản xạ và chiếu sáng

Retinex xem ảnh quan sát là tích của thành phần phản xạ R và chiếu sáng L:

$$I(x, y) = R(x, y)L(x, y). \tag{9}$$

Nếu có thể ước lượng thành phần chiếu sáng biến đổi chậm, ta có thể giảm ảnh hưởng của nó và làm rõ cấu trúc phản xạ. Trong miền log, tích trở thành tổng; một dạng Single-Scale Retinex sử dụng ảnh làm mờ Gaussian để xấp xỉ thành phần chiếu sáng:

$$r_s = \log(Y + \epsilon) - \log(G_{\sigma_s} * Y + \epsilon). \tag{10}$$

Với nhiều độ lệch chuẩn Gaussian, kết quả trung bình là:

$$r = \frac{1}{S}\sum_{s=1}^{S} r_s, \qquad \epsilon = 10^{-6}. \tag{11}$$

Các độ lệch chuẩn nhỏ nhấn mạnh biến đổi cục bộ, trong khi độ lệch chuẩn lớn thể hiện cấu trúc chiếu sáng rộng hơn. Kết hợp nhiều tỉ lệ giúp giảm phụ thuộc vào một mức làm mờ duy nhất.

3.5.2. Chuẩn hóa đầu ra trong dự án

Giá trị r trong miền log chưa nằm trong $[0, 1]$. Mã nguồn lấy percentile 1% và 99% trên toàn mảng kết quả, ký hiệu là q_1, q_{99}, rồi chuẩn hóa:

$$\widehat{X} = \text{clip}\left(\frac{r - q_1}{q_{99} - q_1}, 0, 1\right). \tag{12}$$

Nếu $q_{99} - q_1 < 10^{-6}$, hàm trả lại ảnh đầu vào để tránh chia cho khoảng quá nhỏ. Hai cấu hình tỉ lệ được thử là $[3, 10, 20]$ và $[5, 15, 30]$; notebook chọn cấu hình thứ hai.

Đây là MSR giản lược, không có bước phục hồi màu riêng của MSRCR và không có khối khử nhiễu chuyên biệt. Việc chuẩn hóa percentile làm kết quả phụ thuộc vào phân bố của chính ảnh đang xử lý. Một số pixel bị kéo đến 0 hoặc 1; quan hệ màu và độ sáng tuyệt đối có thể thay đổi đáng kể so với ảnh gốc.

3.5.3. Vì sao Retinex nhạy với nhiễu?

Vùng tối có giá trị Y nhỏ, trong khi đạo hàm của hàm log là $1/(Y + \epsilon)$. Các dao động nhỏ của nhiễu vì vậy có thể tạo chênh lệch lớn trong miền log. Phép trừ ảnh làm mờ còn nhấn mạnh thành phần biến thiên nhanh, bao gồm cả biên thật lẫn nhiễu. Sau bước kéo giãn percentile, những dao động này có thể tiếp tục được khuếch đại.

Khi ảnh chỉ bị Gamma làm tối, MSR có thể làm rõ cấu trúc tốt. Khi thêm nhiễu, cùng cấu hình có thể tạo màu giả và hạt rõ trên nền. Thí nghiệm ablation ở phần sau kiểm tra trực tiếp giả thuyết này bằng cách giữ nguyên $\gamma_d = 2, 2$ và thay đổi thành phần nhiễu.

3.6. Các phương pháp tăng cường dựa trên học sâu

3.6.1. Zero-DCE

Zero-DCE ước lượng các đường cong điều chỉnh cường độ phụ thuộc ảnh. Một dạng đường cong được mô tả trong nghiên cứu gốc là $I' = I + AI(1 - I)$, với tham số A được mạng dự đoán theo vị trí và được áp dụng lặp. Phương pháp học cách điều chỉnh ảnh bằng các ràng buộc không cần ảnh tham chiếu ghép cặp [1].

Trong dự án, Zero-DCE được dùng ở chế độ suy luận với checkpoint `Epoch99.pth`. Không tối ưu lại mạng trên GTSRB. Adapter chọn ảnh tăng cường từ đầu ra của mô hình, đưa về miền hợp lệ và cùng kích thước ban đầu. Vì đường cong tác động lên ảnh chứa nhiễu, đầu ra sáng hơn vẫn cần được kiểm tra về hạt và độ rõ nét số.

3.6.2. Retinexformer

Retinexformer kết hợp biểu diễn chiếu sáng với Transformer để phục hồi ảnh thiếu sáng. Khung một giai đoạn của phương pháp sử dụng thông tin chiếu sáng nhằm hỗ trợ xử lý các suy giảm và quan hệ giữa các vùng ảnh [2]. Báo cáo sử dụng nó như một đối chứng học sâu cho MSR, không đồng nhất hai phương pháp chỉ vì cùng dựa trên ý tưởng Retinex.

Checkpoint được dùng là bản LOL-v1 do tác giả công bố. Adapter nạp kiến trúc và trọng số, chạy suy luận, sau đó lấy phần đầu ra tương ứng ảnh gốc. Ảnh cần được đệm đến bội số của 4 nếu kích thước chưa phù hợp; với crop 64×64, điều kiện này đã được thỏa mãn.

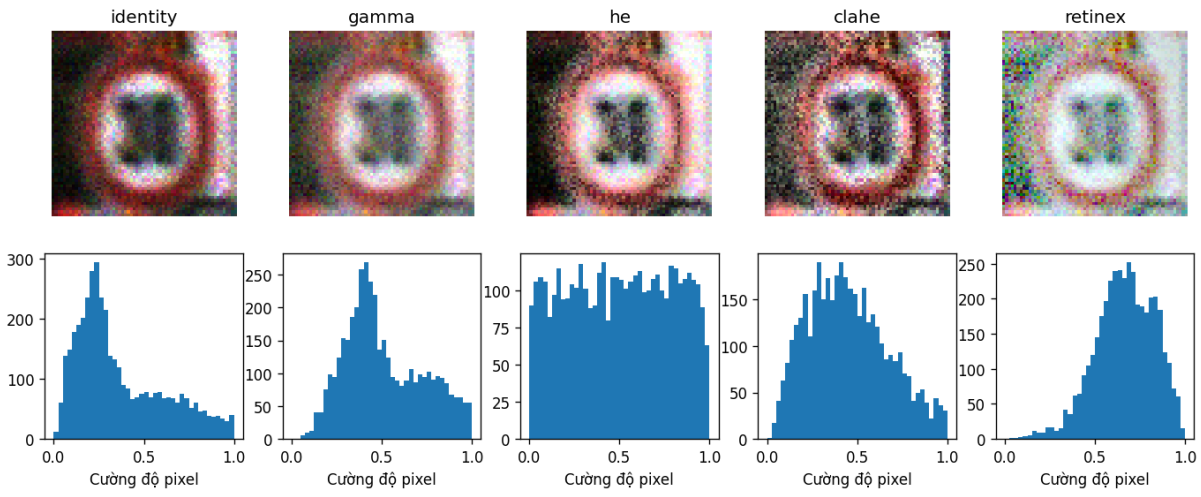
3.6.3. Tăng cường dựa trên diffusion trong miền wavelet

Phương pháp diffusion được chọn là Wavelet-based Diffusion LLIE. Nghiên cứu gốc kết hợp mô hình diffusion có điều kiện với biểu diễn wavelet và cơ chế phục hồi thành phần tần số cao [3]. Cách tiếp cận này hướng tới cân bằng thông tin chiếu sáng và chi tiết của ảnh.

Trong triển khai, mạng dùng trọng số trung bình trượt (EMA), 10 bước lấy mẫu và hạt giống suy luận được xác định theo mã ảnh. Nếu cần, ảnh được đệm lặp biên đến bội số của 32; đầu ra lấy từ trường `pred_x`, cắt về kích thước ban đầu và chặn $[0, 1]$. Nhiều bước suy luận làm chi phí lớn hơn đáng kể so với Gamma hoặc CLAHE.

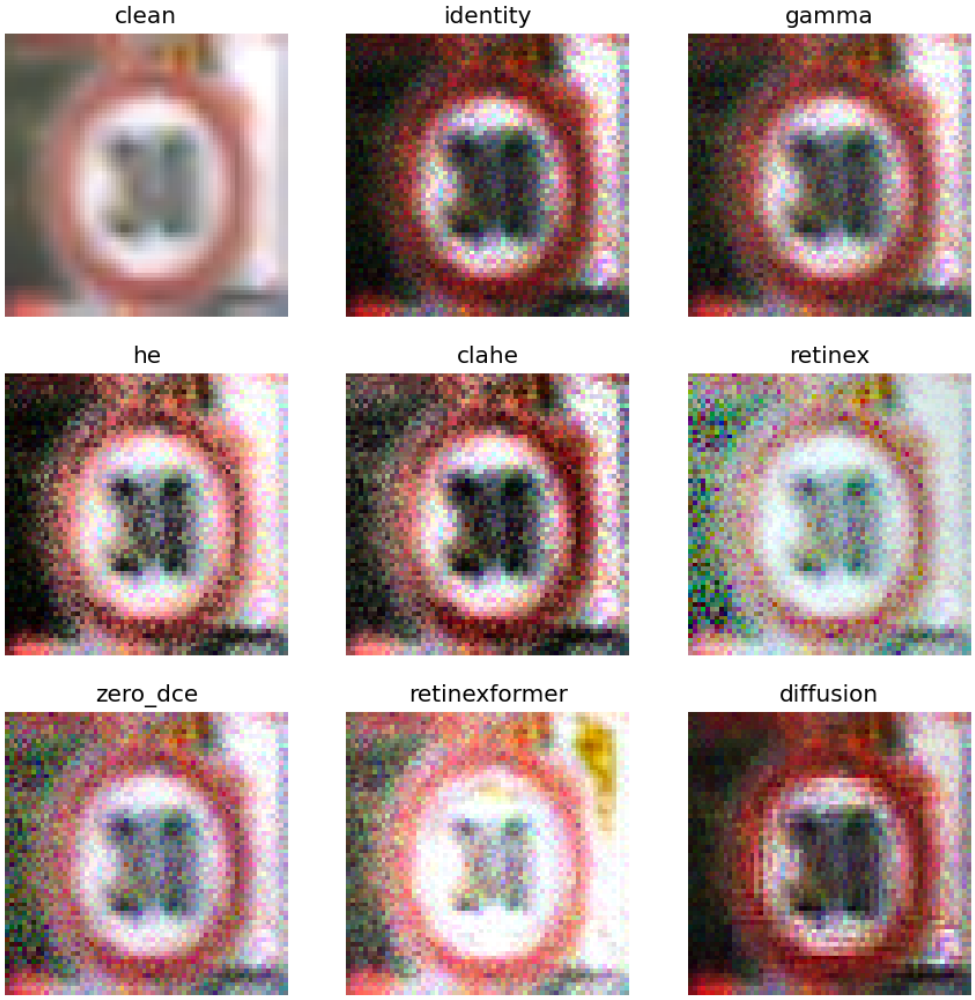
Ba mô hình sâu đều được dùng nguyên trọng số tác giả. Vì dữ liệu học trước khác miền biển báo GTSRB và khác mô hình nhiễu tổng hợp đang khảo sát, không có cơ sở mặc định rằng chúng sẽ vượt mọi phương pháp truyền thống. Đây là một nội dung cần kiểm chứng bằng kết quả thực nghiệm thay vì suy đoán theo độ phức tạp của mô hình.

3.7. Minh họa trước và sau xử lý



Hình 4. Ảnh và histogram sau các phép xử lý truyền thống với tham số mặc định: Gamma 0,6; CLAHE clip limit 2, lưới 8×8; MSR $[3, 10, 20]$. Hình dùng để giải thích cơ chế, không phải kết quả của bộ tham số đã chọn.

Hình 4 cho thấy cùng một ảnh tối có thể được biến đổi thành nhiều phân bố sáng khác nhau. Gamma nâng phần lớn pixel tối; HE phân phối lại mức sáng trên toàn ảnh; CLAHE phụ thuộc từng vùng; MSR có thể tạo thay đổi mạnh về màu và độ tương phản. Việc histogram trải rộng sau xử lý chỉ chứng minh phép ánh xạ đã thay đổi phân bố, chưa chứng minh nội dung có ích đã được phục hồi.



Hình 5. Minh họa bảy phương pháp trên một crop: Gamma 0,8; CLAHE clip 2, lưới 4×4; MSR $[5, 15, 30]$. Clean là tham chiếu, Identity là ảnh tối. Hình giải thích biến đổi ảnh, không phải bằng chứng phân loại của bộ tham số cuối.

Trong Hình 5, ảnh Zero-DCE và Retinexformer sáng lên rõ, nhưng nhiễu và sự biến đổi màu cũng cần được quan sát. MSR làm nền thay đổi mạnh, còn diffusion không nhất thiết tạo ảnh sáng nhất. Những nhận xét này chỉ có giá trị minh họa trên một mẫu; xếp hạng thuật toán phải dựa trên số liệu tổng hợp và hiệu quả nhận dạng ở các phần tiếp theo.

3.8. Đánh giá chất lượng bằng PSNR và SSIM

3.8.1. Sai số bình phương trung bình và PSNR

Với X là ảnh gốc, $\widehat{X}$ là ảnh xử lý và $N = HWC$ là số phần tử RGB:

$$\text{MSE} = \frac{1}{N}\sum_{i=1}^{N}(X_i - \widehat{X}_i)^2, \qquad \text{PSNR} = 10\log_{10}\frac{1}{\text{MSE}}. \tag{13}$$

Công thức dùng biên độ cực đại bằng 1 vì ảnh đã được chuẩn hóa. PSNR cao tương ứng sai số pixel nhỏ. MSE được tính với độ chính xác số thực 64 bit trong mã nguồn để giảm sai số cộng dồn. Nếu ảnh trùng hoàn toàn với tham chiếu, MSE bằng 0 và PSNR là vô hạn, không thay bằng một giá trị hữu hạn tùy ý.

PSNR được tính từng ảnh rồi lấy trung bình. Trung bình của log sai số khác log của sai số trung bình, nên không được gộp toàn bộ pixel của tập dữ liệu thành một MSE duy nhất rồi gọi đó là PSNR trung bình. Chỉ số cũng nhạy với thay đổi độ sáng toàn cục, dù ảnh sau thay đổi vẫn có thể giữ được các nét phân lớp.

3.8.2. Độ tương đồng cấu trúc SSIM

SSIM xem xét thống kê cục bộ của hai ảnh, gồm độ sáng, độ tương phản và mức tương đồng cấu trúc [9]. Dạng thường dùng là:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \tag{14}$$

Trong đó μ là trung bình cục bộ, σ^2 là phương sai, σ_{xy} là hiệp phương sai và các hằng số C_1, C_2 ổn định phép chia. Dự án dùng cửa sổ 7×7, miền giá trị 1, xử lý ba kênh màu, $K_1 = 0,01$, $K_2 = 0,03$, không dùng trọng số Gaussian và dùng hiệp phương sai mẫu.

SSIM bổ sung thông tin mà PSNR không thể hiện đầy đủ, song vẫn không thay thế metric nhận dạng. Nét chữ số bị sai ở một vùng nhỏ có thể không làm giảm mạnh điểm trung bình toàn ảnh. Khi ảnh đêm thực không có ảnh tham chiếu đồng vị trí, cũng không thể áp dụng trực tiếp PSNR/SSIM theo giao thức hiện tại.

3.9. Cơ chế học sâu và liên hệ với sai số nhận dạng

3.9.1. Đường cong lặp của Zero-DCE

Thay vì ước lượng trực tiếp ảnh sáng, Zero-DCE dự đoán bản đồ hệ số A_n và áp dụng đường cong nhiều lần [1]:

$$I_{n+1} = I_n + A_n \odot I_n \odot (1 - I_n), \qquad A_n \in [-1, 1]. \tag{15}$$

Với một hệ số cố định a, đạo hàm theo cường độ là $1 + a(1 - 2I)$ và không âm trên miền hợp lệ. Điều này mô tả tính đơn điệu của đường cong tại một vị trí, không bảo đảm thứ tự giữa hai pixel có hệ số khác nhau. Với $a > 0$, mức tăng bằng $aI(1 - I)$, đạt lớn nhất gần

$I = 0,5$ và bằng 0 tại hai đầu. Pixel bị clipping hoàn toàn về 0 vì thế không thể được khôi phục chỉ bằng phép biến đổi này.

Hàm mục tiêu gốc kết hợp tính nhất quán không gian, kiểm soát phơi sáng, tính ổn định màu và độ trơn của bản đồ hệ số [1]. Các ràng buộc không yêu cầu nhãn lớp biển báo. Chúng cũng không tối ưu trực tiếp việc phân biệt nét số hoặc hình mũi tên. Khi bản đồ đường cong nâng cả tín hiệu lẫn nhiễu, ảnh nhìn sáng hơn nhưng đặc trưng phân lớp vẫn có thể bị thay đổi. Đây là giả thuyết cơ chế, cần đối chiếu từng mẫu thay vì coi là nguyên nhân đã được xác nhận.

3.9.2. Thông tin chiếu sáng trong Retinexformer

Retinexformer dùng khung một giai đoạn gồm ước lượng chiếu sáng, nâng sáng và khôi phục suy giảm; đặc trưng chiếu sáng hướng dẫn tương tác giữa các vùng trong Transformer [2]. Có thể mô tả chức năng bằng sơ đồ:

$$(\widehat{L}, F_L) = g(Y), \qquad Y_{\text{up}} = Y \odot \widehat{L}, \qquad \widehat{X} = h(Y_{\text{up}}, F_L). \tag{16}$$

Trong sơ đồ này $\widehat{L}$ là bản đồ nâng sáng và F_L là đặc trưng chiếu sáng; biểu thức mô tả vai trò các khối, không thay thế toàn bộ công thức attention của bài báo. Khác với MSR giản lược, bộ phục hồi có tham số học được và tận dụng quan hệ không cục bộ. Tuy nhiên, trọng số LOL-v1 không được tối ưu riêng cho crop biển báo có nét rất nhỏ và nhiễu Poisson–Gaussian đang xét. Hiệu năng thấp hơn CLAHE trên GTSRB vì thế không phủ định kết quả của phương pháp trên các benchmark gốc.

3.9.3. Wavelet và diffusion có điều kiện

Biến đổi wavelet tách ảnh thành thành phần tần số thấp LL và các thành phần chi tiết LH, HL, HH. Phương pháp Wavelet-based Diffusion LLIE sử dụng diffusion có điều kiện trong miền wavelet kết hợp khôi phục thành phần tần số cao [3]. Công thức nhiễu thuận điển hình của diffusion là [10]:

$$z_t = \sqrt{\overline{\alpha}_t}\, z_0 + \sqrt{1 - \overline{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I). \tag{17}$$

Đặt $\beta_s \in (0, 1)$ là phương sai nhiễu ở bước s, $\alpha_s = 1 - \beta_s$ và $\overline{\alpha}_t = \prod_{s=1}^{t} \alpha_s$ là tích lũy đến bước t, không phải hệ số riêng của một bước. Ở đây z_0 là biểu diễn đích trong miền mà diffusion làm việc, không phải công thức tạo thiếu sáng của dự án. Khi suy luận, mô hình dùng điều kiện từ ảnh tối và nhiều bước khử nhiễu để ước lượng biểu diễn phục hồi trước khi tái tạo ảnh. Phân tách tần số giúp giải thích vì sao phương pháp có thể xử lý đồng thời chiếu sáng và chi tiết; không có bảo đảm rằng mọi nét số nhỏ đều được giữ đúng.

Thiết lập 10 bước, EMA và sampler của tác giả là cấu hình suy luận trong dự án. Không huấn luyện một diffusion mới trên GTSRB và không dùng nhãn biển báo để cập nhật bộ tăng cường. Độ trễ đã đo chỉ cho khối tăng cường crop; không quy đổi trực tiếp thành FPS camera.

3.9.4. Mục tiêu phục hồi và mục tiêu phân loại khác nhau

Giả sử đặc trưng của bộ phân loại là f và phép tăng cường là E. Giảm $\|E(Y) - X\|^2$ không kéo theo giảm $\|f(E(Y)) - f(X)\|$; mạng có thể nhạy với sai khác tại một vùng nhỏ chứa

chữ số hoặc biểu tượng. Để kiểm tra tác động này, cần giữ cố định f, so sánh dự đoán trên cùng ảnh và thống kê cả trường hợp được sửa đúng lẫn bị làm sai. Phân tích ghép cặp ở phần sau thực hiện đúng nguyên tắc đó.

3.10. Khử nhiễu và thứ tự xử lý

Khảo sát khử nhiễu kiểm tra ảnh hưởng của lọc không gian và thứ tự phối hợp với tăng sáng. Cấu hình được chọn trên validation; kết quả subset và full-test trình bày ở phần thực nghiệm.

3.10.1. Câu hỏi và phạm vi khảo sát

Để làm rõ ảnh hưởng của xử lý ảnh ngoài tăng độ sáng, nghiên cứu khảo sát ba bộ lọc khử nhiễu và hai thứ tự kết hợp với tăng sáng. Ba câu hỏi đặt ra là: khử nhiễu đơn lẻ có cải thiện phân loại ảnh thiếu sáng không; việc giữ biên hoặc so sánh vùng ảnh có bảo toàn chi tiết phân biệt lớp tốt hơn làm trơn thông thường không; và nên khử nhiễu trước hay sau tăng sáng? Nghiên cứu tiếp tục giới hạn ở ảnh biển báo đã cắt ROI và suy giảm tổng hợp, chưa suy rộng sang phát hiện biển báo toàn cảnh hoặc hệ thống cảnh báo trong xe.

3.10.2. Cơ chế các bộ lọc và giả thuyết

Với ảnh nhiễu I, bộ lọc Gaussian cho ảnh đầu ra

$$D_G(I)(p) = \sum_{q \in \mathcal{N}(p)} G_\sigma(p-q) I(q), \qquad \sum_{q \in \mathcal{N}(p)} G_\sigma(p-q) = 1. \tag{18}$$

Trung bình có trọng số làm giảm dao động cục bộ nhưng có thể làm mờ chữ số và đường viền nhỏ trên crop 64×64. Bilateral thêm trọng số theo khác biệt màu [11]:

$$D_B(I)(p) = \frac{1}{W_p} \sum_{q \in \mathcal{N}(p)} e^{-\|p-q\|^2/(2\sigma_s^2)} e^{-\|I(p)-I(q)\|^2/(2\sigma_c^2)} I(q), \tag{19}$$

trong đó W_p chuẩn hóa tổng trọng số. Cơ chế này hạn chế trộn qua biên có chênh lệch màu lớn; nhiễu mạnh vẫn có thể làm sai ước lượng độ tương tự. Non-local Means (NLM) [12] dùng dạng $D_N(I)(p) = \sum_q w(p,q) I(q)$, với trọng số dựa trên độ giống nhau giữa các mảnh ảnh thay vì chỉ khoảng cách điểm ảnh. Tham số lọc mạnh có thể loại nhiễu tốt hơn nhưng đồng thời xóa chi tiết. Việc cài đặt dùng các hàm OpenCV, không huấn luyện thêm bộ khử nhiễu [13, 14].

Gaussian và bilateral xử lý RGB float32 trong $[0, 1]$. NLM màu của OpenCV yêu cầu uint8: làm tròn về 8 bit, đổi RGB sang BGR, gọi bộ lọc màu rồi chuyển về RGB float32; xử lý màu nội bộ của hàm dựa trên không gian Lab. Vì vậy, tác động NLM bao gồm cả bước lượng tử hóa; cần nêu giới hạn này khi diễn giải PSNR/SSIM, không quy toàn bộ thay đổi cho nguyên lý NLM.

Với phép tăng sáng E và khử nhiễu D, so sánh $E(D(I))$ với $D(E(I))$. Hai phép nói chung không giao hoán vì tăng sáng là phi tuyến và bộ lọc có thể phụ thuộc cường độ. Khử nhiễu

trước có thể hạn chế khuếch đại nhiễu; tăng sáng trước có thể làm cấu trúc dễ phân biệt hơn nhưng cũng khuếch đại sai lệch. Hai thứ tự được kiểm tra trực tiếp, không mặc định thứ tự nào tốt hơn trước khi đo kết quả.

3.10.3. Thiết kế chọn tham số công bằng

Giữ nguyên split theo track, ảnh crop, ba mức suy giảm, noise seed 101/202/303 và ba checkpoint seed 11/22/33. Không fine-tune CNN bằng ảnh tối hay đầu ra bộ lọc. Chọn tham số trên đúng 1.290 ảnh validation đã dùng cho thí nghiệm tăng sáng, không dùng nhãn test để chọn phương pháp. Cấu hình được khóa trong `configs/processing_extension.json`.

Bảng 3. Lưới tham số khử nhiễu, lựa chọn bằng validation.

Thành phần	Cấu hình và vai trò
Gaussian	$(k, \sigma) = (3, 0{,}5)$ hoặc $(5, 0{,}8)$; đối chứng làm trơn cục bộ
Bilateral	$d = 5$; $(\sigma_c, \sigma_s) = (0{,}05, 1{,}5)$ hoặc $(0{,}10, 3)$, màu trên thang $[0, 1]$
NLM màu	$h = h_{color} = 3$ hoặc 7 trên thang 8 bit; cửa sổ mẫu 3, tìm kiếm 7
Tăng sáng kết hợp	Gamma và CLAHE, giữ tham số đã chọn từ validation đối chứng
Thứ tự	Cả khử nhiễu $\rightarrow$ tăng sáng và tăng sáng $\rightarrow$ khử nhiễu

Đầu tiên, chọn một độ mạnh cho từng bộ lọc dựa trên Macro-F1 của *khử nhiễu đơn lẻ*. Sau đó cố định cùng tham số này cho cả hai thứ tự với từng phép tăng sáng. Có 6 cấu hình đơn lẻ và 12 chuỗi kết hợp cần đánh giá thêm trên validation; sau chọn độ mạnh, tập ứng viên test có 3 bộ lọc đơn lẻ và 12 chuỗi. Cách cố định tham số giúp tránh nhầm ảnh hưởng của thứ tự với ảnh hưởng của độ mạnh bộ lọc. Tuy nhiên, tham số tốt khi lọc đơn lẻ chưa chắc tốt trong chuỗi; tăng sáng có thể đổi mức nhiễu và độ tương tự dùng để lọc. Kết quả so sánh vì thế có điều kiện trên tham số đã khóa, chưa phải tối ưu toàn cục của từng chuỗi. Muốn tìm chuỗi tối ưu cần chọn đồng thời bộ lọc, enhancer và thứ tự trên validation rồi đánh giá trên một tập test còn độc lập. Identity, Gamma, CLAHE và pipeline đối chứng đã chọn được giữ để so sánh ghép cặp; nếu trùng thì chỉ tính một lần.

3.10.4. Khóa subset, full-test và cách phân tích

Nghiên cứu sử dụng subset 430 ảnh để đánh giá toàn bộ họ phương pháp sau khi chọn độ mạnh. Tập phương pháp full-test được chọn *trước khi đọc kết quả subset*: validation chọn cặp bộ lọc–tăng sáng có điểm trung bình hai thứ tự cao nhất; giữ cả hai thứ tự, hai phép đơn lẻ tương ứng, bộ lọc đơn lẻ tốt nhất và ứng viên tổng thể tốt nhất, cùng các đối chứng. Do đó full-test khảo sát tập ứng viên đã sàng lọc, không phải mọi tổ hợp. Hai giao thức được khóa cùng lúc, ghi ID, tham số, hash mã và hash checkpoint.

Đánh giá Accuracy, Macro-F1, Weighted-F1, PSNR, SSIM và thời gian xử lý. Trung bình noise seed trong từng checkpoint rồi tổng hợp trung bình và độ lệch chuẩn qua ba checkpoint, theo cùng quy ước tổng hợp. Phân tích bổ sung gồm F1 từng lớp, confusion matrix, số ảnh chuyển từ sai sang đúng và đúng sang sai so với Identity, và chênh lệch giữa hai thứ tự trên cùng ảnh. Thời gian đo cho khối xử lý sau warm-up, không phải độ trễ toàn bộ camera. Nếu

chất lượng ảnh tăng nhưng Macro-F1 giảm, cần kiểm tra chi tiết màu, đường viền và chữ số thay vì kết luận bộ lọc tốt chỉ từ PSNR/SSIM.

Các bước xử lý không nhận nhãn hoặc ảnh sáng tham chiếu; chỉ bộ đánh giá sử dụng chúng để chấm điểm. Các phương pháp phải nhận cùng đầu vào suy giảm và cùng bộ phân loại. Phân tích thứ tự sử dụng cặp cấu hình có tham số giống nhau, tránh nhầm tác động của độ mạnh bộ lọc với tác động của thứ tự xử lý. Các chuỗi mới được đo trong cùng phiên và phạm vi tác vụ; thời gian đối chứng dùng lại từ phiên khác chỉ mang tính mô tả.

4. THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ

4.1. Thiết lập mô hình kiểm chứng ResNet-18

ResNet-18 là kiến trúc mạng tích chập có kết nối phần dư, giúp học phép biến đổi thông qua tổng giữa nhánh đặc trưng và nhánh đi tắt [15]. Trong bài tập lớn, lớp phân loại cuối được thay bằng ánh xạ từ 512 đặc trưng sang 43 lớp biển báo. Mô hình khởi tạo từ trọng số ImageNet và được tinh chỉnh trên tập ảnh gốc GTSRB.

Đầu vào ở khối xử lý ảnh có dạng $B \times 3 \times 64 \times 64$ khi ghép batch. Trong hàm forward của ResNet-18, toàn bộ crop được nội suy song tuyến tính lên 224×224, có chống răng cưa, rồi chuẩn hóa theo trung bình $[0,485; 0,456; 0,406]$ và độ lệch chuẩn $[0,229; 0,224; 0,225]$. Chuẩn hóa được áp dụng đúng một lần. Đầu ra là ma trận $B \times 43$.

Bảng 4. Cấu hình huấn luyện ResNet-18 dùng để kiểm chứng.

Thành phần	Thiết lập
Kiến trúc	ResNet-18, lớp cuối 43 đầu ra
Khởi tạo	ImageNet, tinh chỉnh toàn mạng
Dữ liệu huấn luyện	Ảnh gốc; không huấn luyện riêng theo enhancer
Bộ tối ưu	AdamW, learning rate 10^{-4}
Weight decay / batch size	10^{-4} / 32
Số epoch tối đa	20
Dừng sớm	Patience 5, min delta 0,001
Training seed	11, 22, 33
Chọn checkpoint	Macro-F1 validation clean tốt nhất

Trong huấn luyện, các phép tăng cường nhẹ gồm xoay tối đa $10°$, tịnh tiến tối đa 5%, thay đổi nhẹ sáng/tương phản/bão hòa và xóa ngẫu nhiên một vùng nhỏ. Không lật ngang biển báo vì có thể thay đổi ý nghĩa hướng di chuyển. Cụm từ "huấn luyện clean" ở đây nghĩa là không huấn luyện bằng mô hình thiếu sáng Gamma–Poisson–Gaussian của thí nghiệm, không có nghĩa là loại bỏ mọi augmentation.

Ba checkpoint tốt nhất nằm ở epoch 3, 6 và 14 tương ứng seed 11, 22 và 33; lịch sử huấn luyện kết thúc ở epoch 8, 11 và 15. Checkpoint lưu Macro-F1 validation cao nhất; bộ đếm

dừng sớm dùng mức cải thiện tối thiểu 0,001 nên không nhất thiết dừng đúng năm epoch sau checkpoint cuối. Sau huấn luyện, trọng số được giữ cố định cho mọi phép xử lý.

4.2. Chỉ số đánh giá nhận dạng

Accuracy là tỷ lệ mẫu được phân loại đúng:

$$\text{Accuracy} = \frac{N_{\text{đúng}}}{N_{\text{tổng}}}. \tag{20}$$

Với mỗi lớp $c \in \{0, \ldots, 42\}$, Precision, Recall và F1 được tính từ số dự đoán đúng dương (TP), sai dương (FP) và sai âm (FN):

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{21}$$

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad \text{Macro-F1} = \frac{1}{43}\sum_{c=0}^{42} F1_c. \tag{22}$$

Nếu mẫu số bằng 0, chỉ số tương ứng được quy ước bằng 0 như trong mã nguồn. Mỗi lớp đóng góp như nhau vào Macro-F1, phù hợp với yêu cầu nhận dạng đầy đủ 43 loại biển báo. Weighted-F1 dùng số mẫu mỗi lớp làm trọng số và được lưu như metric bổ sung. Với tập con có đúng 10 ảnh/lớp, Weighted-F1 bằng Macro-F1 về mặt toán học; trên full-test có tần suất lớp khác nhau, hai chỉ số không nhất thiết bằng nhau.

Các bảng F1 trong báo cáo dùng Macro-F1 và ghi rõ đơn vị phần trăm. Chênh lệch giữa hai giá trị phần trăm được gọi là *điểm phần trăm*, tránh nhầm với tỷ lệ cải thiện tương đối.

4.3. Giao thức chọn tham số và tổng hợp số liệu

Tham số của bảy bộ tăng cường được chọn trên 1.290 ảnh validation, cân bằng 30 ảnh/lớp. Điểm chọn là Macro-F1 trung bình qua ba mức suy giảm, ba noise seed và ba checkpoint. Gamma thử ba số mũ; CLAHE thử sáu cấu hình; MSR thử hai bộ tỉ lệ. Mô hình sâu giữ trọng số tác giả. Với nhóm tăng sáng, các phương án cách điểm tốt nhất dưới 0,005 được so tiếp theo độ trễ; diffusion được chọn với Macro-F1 validation 72,77%, so với CLAHE 68,86%.

Khảo sát khử nhiễu dùng lại đúng tập validation và các checkpoint này. Đầu tiên chọn độ mạnh của mỗi bộ lọc khi chạy đơn lẻ, sau đó giữ nguyên tham số khi so hai thứ tự với Gamma và CLAHE. Sáu cấu hình bộ lọc và 12 chuỗi được đánh giá thêm; khi chọn độ mạnh xong, có 19 phương pháp test gồm bốn đối chứng và 15 cấu hình khử nhiễu/kết hợp. Ứng viên tổng thể được chọn bằng Macro-F1 validation lớn nhất; không chọn lại từ bảng test. Đây là tìm kiếm tuần tự trên lưới hữu hạn, không tối ưu đồng thời tham số bộ lọc, enhancer và thứ tự.

Trong mọi bảng, trung bình qua noise seed trước trong từng checkpoint rồi mới lấy mean và độ lệch chuẩn mẫu qua ba checkpoint:

$$\overline{m}_t = \frac{1}{3}\sum_{n=1}^{3} m_{t,n}, \quad \mu = \frac{1}{3}\sum_{t=1}^{3} \overline{m}_t, \quad s = \sqrt{\frac{\sum_t (\overline{m}_t - \mu)^2}{2}}. \tag{23}$$

Các noise seed và checkpoint sử dụng chung ảnh, không được coi là những ảnh độc lập. Độ lệch chuẩn qua checkpoint cũng không đo mức biến thiên PSNR/SSIM giữa ảnh.

4.4. Phạm vi đánh giá và kiểm tra bằng chứng

Nhóm tăng sáng có $3 + 3 \times 3 \times 3 \times 8 = 219$ lượt ở mỗi phạm vi: subset 430 ảnh và full-test 12.630 ảnh. Khảo sát khử nhiễu có $3 + 27 \times 19 = 516$ lượt subset. Full-test giữ tám phương pháp được khóa bằng validation, gồm các đối chứng, bộ lọc tốt nhất, cả hai thứ tự của cặp được chọn và ứng viên tổng thể tốt nhất; tổng cộng 219 lượt. Việc sàng lọc full-test được thực hiện trước khi đọc kết quả subset.

Bảng 5. Phạm vi và số dòng dự đoán đã kiểm tra; bao gồm đối chứng dùng lại, không phải toàn bộ quan sát độc lập.

Khảo sát	Ảnh/lượt	Lượt	Dòng dự đoán
Tăng sáng, subset	430	219	94.170
Tăng sáng, full-test	12.630	219	2.765.970
Khử nhiễu/kết hợp, subset	430	516	221.880
Khử nhiễu/kết hợp, full-test	12.630	219	2.765.970

Tổng cộng 5.847.990 dòng dự đoán được đối chiếu ID, nhãn, group ID và cấu hình. Accuracy, Macro-F1, Weighted-F1 được tính lại và khớp bảng tổng hợp với sai số tuyệt đối không quá 10^{-8}. Confusion matrix lưu trong ZIP được đối chiếu cho 954 lượt có ma trận; subset tăng sáng được tính lại từ CSV. Hash ba checkpoint nhất quán giữa cả bốn phạm vi. Đối chứng được dùng lại chính xác thay vì suy luận lại; số dòng lưu thêm không làm tăng số ảnh nguồn. Các bảng được sinh từ cùng gói kết quả và biên bản trong `report/evidence/final/`.

4.5. Chất lượng ảnh của các phương pháp tăng sáng

Bảng 6. PSNR (dB) / SSIM trên subset 430 ảnh; mỗi ô ghi PSNR trước, SSIM sau.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	19.49 / 0.6077	15.37 / 0.3410	13.79 / 0.2254
Gamma	23.94 / 0.7011	17.18 / 0.4498	14.84 / 0.2964
HE	11.45 / 0.3704	11.36 / 0.3237	11.06 / 0.2578
CLAHE	23.41 / 0.6982	18.29 / 0.5208	15.69 / 0.3712
MSR	8.70 / 0.3735	6.60 / 0.2408	7.26 / 0.1875
Zero-DCE	17.68 / 0.5067	20.08 / 0.4509	16.71 / 0.3157
Retinexformer	11.00 / 0.3853	14.78 / 0.4780	17.40 / 0.4350
Diffusion	14.50 / 0.5662	14.91 / 0.5411	14.88 / 0.4720

Các phương pháp làm thay đổi cả độ sáng, cấu trúc và nhiễu. Phương pháp có PSNR cao nhất không nhất thiết có SSIM cao nhất; xếp hạng cũng thay đổi theo mức suy giảm. Bảng

này mô tả chất lượng trên subset. Phân tích tương quan ở phần sau sử dụng chất lượng ảnh và nhận dạng cùng đo trên full-test, không ghép hai phạm vi.

4.6. Nhận dạng trên subset 430 ảnh

Bảng 7. Accuracy (%), mean ± sample SD trên subset 430 ảnh.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	87.67 ± 3.56	69.20 ± 5.21	47.36 ± 8.41
Gamma	89.46 ± 3.69	71.76 ± 6.07	48.27 ± 7.53
HE	85.61 ± 3.67	65.30 ± 4.68	42.22 ± 5.17
CLAHE	89.84 ± 3.94	72.92 ± 6.18	50.10 ± 8.32
MSR	81.06 ± 1.68	53.70 ± 3.48	31.55 ± 2.23
Zero-DCE	85.17 ± 5.30	64.55 ± 6.35	41.99 ± 6.28
Retinexformer	81.73 ± 2.27	70.31 ± 5.80	45.79 ± 5.66
Diffusion	91.63 ± 2.49	78.11 ± 5.26	56.02 ± 6.58

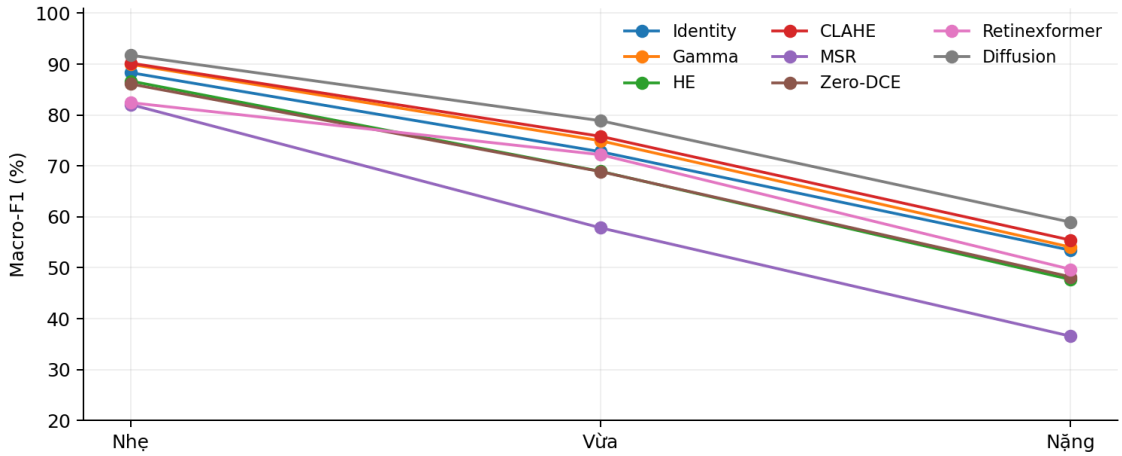
Bảng 8. Macro-F1 (%), mean ± sample SD trên cùng subset.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	88.33 ± 2.96	72.79 ± 4.32	53.45 ± 7.72
Gamma	89.97 ± 3.36	74.95 ± 5.33	54.05 ± 7.14
HE	86.68 ± 3.30	68.94 ± 4.45	47.70 ± 4.99
CLAHE	90.21 ± 3.70	75.82 ± 5.62	55.43 ± 7.73
MSR	82.08 ± 1.50	57.84 ± 2.79	36.56 ± 1.96
Zero-DCE	86.10 ± 4.97	68.90 ± 5.39	48.21 ± 6.01
Retinexformer	82.44 ± 1.90	72.21 ± 4.42	49.70 ± 4.67
Diffusion	91.75 ± 2.51	78.89 ± 4.99	58.96 ± 5.47

Macro-F1 của Identity lần lượt là 88,33%; 72,79%; 53,45% ở mức nhẹ, vừa và nặng; diffusion đạt 91,75%; 78,89%; 58,96%. Sự suy giảm còn lại ở mức nặng cho thấy nâng sáng không thể khôi phục hoàn toàn thông tin. Các khoảng cách phải được đọc cùng SD qua checkpoint.

4.7. Đánh giá tăng sáng trên full-test

Trên ảnh clean, Accuracy đạt $99,22\% \pm 0,28$ và Macro-F1 đạt $98,94\% \pm 0,32$. Identity đạt Macro-F1 90,45%; 76,07%; 58,37%, còn diffusion đạt 93,63%; 81,57%; 62,46%. Đây là đánh giá trên cùng ba CNN, không huấn luyện lại theo phương pháp. Chênh lệch với subset đến từ phạm vi ảnh khác nhau; hai bảng được tổng hợp riêng.



Hình 6. Macro-F1 trên subset; cùng checkpoint và cùng ảnh tối được dùng cho các phương pháp.

Bảng 9. Macro-F1 (%) trên toàn bộ 12.630 ảnh test, tính lại từ dự đoán thô.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	90.45 ± 3.38	76.07 ± 4.69	58.37 ± 7.77
Gamma	91.65 ± 3.45	77.50 ± 5.27	59.25 ± 7.12
HE	88.87 ± 3.68	73.15 ± 3.75	53.25 ± 5.88
CLAHE	92.20 ± 3.39	78.16 ± 5.33	60.47 ± 8.05
MSR	84.31 ± 2.04	62.56 ± 2.26	39.62 ± 2.11
Zero-DCE	88.08 ± 4.54	72.34 ± 5.16	52.78 ± 7.01
Retinexformer	83.92 ± 1.26	74.28 ± 3.08	54.22 ± 4.91
Diffusion	93.63 ± 2.13	81.57 ± 4.98	62.46 ± 5.56

4.8. Khử nhiễu và các chuỗi kết hợp

Trên validation, Gaussian chọn kernel 5×5, $\sigma = 0,8$; bilateral chọn $d = 5$, $\sigma_c = 0,10$, $\sigma_s = 3$; NLM chọn $h = h_{\text{color}} = 7$, cửa sổ mẫu 3 và tìm kiếm 7. Chuỗi Gaussian rồi Gamma đạt 77,77% Macro-F1 validation, cao hơn diffusion 72,77%, và được chọn trước test.

Gaussian đơn lẻ cải thiện nhận dạng dù không chủ động tăng sáng. Bilateral rồi tăng sáng thường tốt hơn thứ tự ngược trong tập cấu hình này; với NLM, xu hướng có thể đổi chiều. Không có quy tắc thứ tự chung cho mọi bộ lọc. Giữ cùng độ mạnh trong mỗi cặp là điều kiện để diễn giải khác biệt.

Gaussian rồi Gamma đạt Macro-F1 96,70%; 85,54%; 71,56%, tăng 6,25; 9,47; 13,19 điểm phần trăm so Identity. Ở mức vừa, Accuracy tăng từ 72,32% lên 83,75%. Ở mức nặng, CLAHE rồi Gaussian có điểm test cao hơn chuỗi được chọn khoảng 0,21 điểm phần trăm. Kết quả này được báo cáo để phân tích, không dùng thay quyết định validation; khoảng cách nhỏ chưa chứng minh ưu thế thống kê.

Bảng 10. Macro-F1 (%) của 15 cấu hình khử nhiễu/kết hợp trên subset. Mũi tên là thứ tự áp dụng; cùng tham số bộ lọc cho mỗi cặp.

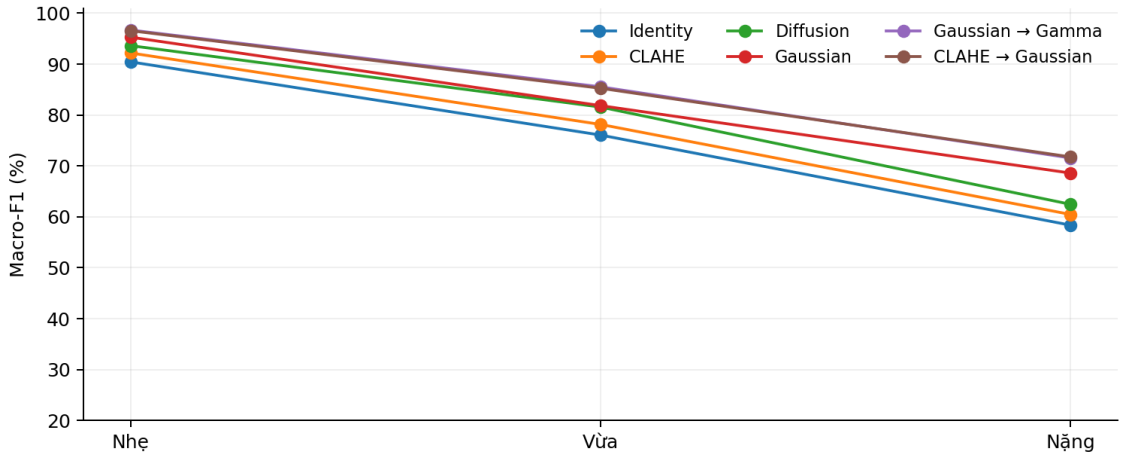
Phương pháp	Nhẹ	Vừa	Nặng
Gaussian	93.60 ± 2.63	79.37 ± 3.26	65.18 ± 2.15
Bilateral	93.76 ± 3.46	77.80 ± 5.16	57.60 ± 6.78
NLM	91.25 ± 2.13	74.34 ± 3.98	54.52 ± 7.30
Gaussian $\rightarrow$ Gamma	95.79 ± 1.38	82.98 ± 2.39	68.25 ± 1.57
Gamma $\rightarrow$ Gaussian	95.73 ± 1.30	82.82 ± 2.42	67.75 ± 1.43
Gaussian $\rightarrow$ CLAHE	95.14 ± 1.67	83.32 ± 2.32	68.40 ± 1.37
CLAHE $\rightarrow$ Gaussian	95.53 ± 1.57	83.46 ± 2.29	68.64 ± 1.86
Bilateral $\rightarrow$ Gamma	96.06 ± 2.03	83.12 ± 3.72	62.39 ± 5.44
Gamma $\rightarrow$ Bilateral	95.53 ± 1.91	80.44 ± 4.31	58.75 ± 6.78
Bilateral $\rightarrow$ CLAHE	95.71 ± 1.67	83.09 ± 3.45	63.31 ± 5.27
CLAHE $\rightarrow$ Bilateral	94.28 ± 2.78	80.41 ± 4.80	58.75 ± 7.01
NLM $\rightarrow$ Gamma	92.67 ± 2.12	76.13 ± 5.00	55.02 ± 7.05
Gamma $\rightarrow$ NLM	92.60 ± 2.03	76.69 ± 4.83	55.52 ± 7.04
NLM $\rightarrow$ CLAHE	92.80 ± 2.12	77.11 ± 5.29	56.40 ± 7.38
CLAHE $\rightarrow$ NLM	92.86 ± 1.92	78.67 ± 4.45	57.66 ± 7.00

Bảng 11. Macro-F1 (%) của tám phương pháp đã khóa cho full-test. Gaussian $\rightarrow$ Gamma được chọn bằng validation.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	90.45 ± 3.38	76.07 ± 4.69	58.37 ± 7.77
Gamma	91.65 ± 3.45	77.50 ± 5.27	59.25 ± 7.12
CLAHE	92.20 ± 3.39	78.16 ± 5.33	60.47 ± 8.05
Diffusion	93.63 ± 2.13	81.57 ± 4.98	62.46 ± 5.56
Gaussian	95.30 ± 1.93	81.85 ± 2.61	68.60 ± 2.74
Gaussian $\rightarrow$ CLAHE	96.41 ± 1.35	85.15 ± 2.70	71.62 ± 2.23
CLAHE $\rightarrow$ Gaussian	96.57 ± 1.21	85.26 ± 2.60	71.77 ± 2.30
Gaussian $\rightarrow$ Gamma	96.70 ± 1.16	85.54 ± 2.49	71.56 ± 2.01

Bảng 12. Accuracy (%) trên cùng full-test của khảo sát kết hợp.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	91.29 ± 3.54	72.32 ± 5.15	52.91 ± 7.92
Gamma	92.76 ± 3.40	74.57 ± 5.96	53.44 ± 7.22
CLAHE	93.65 ± 2.79	75.78 ± 5.27	55.56 ± 7.38
Diffusion	94.89 ± 1.67	82.78 ± 4.41	61.00 ± 6.12
Gaussian	96.10 ± 1.64	78.92 ± 3.18	63.18 ± 3.56
Gaussian $\rightarrow$ CLAHE	97.50 ± 0.88	83.71 ± 2.66	66.72 ± 2.50
CLAHE $\rightarrow$ Gaussian	97.58 ± 0.85	83.89 ± 2.65	66.83 ± 2.58
Gaussian $\rightarrow$ Gamma	97.66 ± 0.93	83.75 ± 3.10	66.33 ± 3.23



Hình 7. Full-test giữa đối chứng, tăng sáng, Gaussian đơn lẻ và hai chuỗi đại diện.

4.9. Ảnh hưởng của thứ tự trên full-test

Cặp Gaussian–CLAHE được validation chọn để giữ cả hai thứ tự trên full-test. Lấy CLAHE rồi Gaussian trừ Gaussian rồi CLAHE, chênh lệch Macro-F1 trung bình là $+0,17$, $+0,11$ và $+0,15$ điểm phần trăm ở ba mức. Một số checkpoint/noise seed có chênh lệch âm. Đây là ưu thế trung bình nhỏ trong cấu hình cụ thể, không phải kết luận thứ tự sau luôn tốt hơn.

Full-test chỉ có Gaussian rồi Gamma, không có Gamma rồi Gaussian; cặp Gamma chỉ được so thứ tự trực tiếp trên validation và subset. Không suy rộng cặp CLAHE sang mọi phép tăng sáng.

Để lượng hóa bất định của chênh lệch này, nghiên cứu dùng paired bootstrap [16] với 2.000 lần lấy mẫu lại, seed 20261025. Đơn vị lấy mẫu là ảnh nguồn test: trong từng lớp lấy có hoàn lại đúng số ảnh ban đầu, và dùng cùng số lần lặp mỗi ID cho hai phương pháp, cả ba checkpoint và ba noise seed. Tính lại Macro-F1 từng lượt, trung bình noise trong checkpoint rồi trung bình checkpoint. Không lấy chín lượt seed làm chín tập ảnh độc lập.

Báo cáo hai khoảng percentile 95%: (i) chỉ lấy mẫu ảnh, giữ cố định các CNN; (ii) lấy mẫu thêm ba nhóm checkpoint có hoàn lại, mỗi nhóm giữ ba noise seed. Khoảng thứ hai phản ánh thêm biến động do huấn luyện, nhưng chỉ có ba nhóm nên vẫn là ước lượng khám phá. Cả hai đều giả định ảnh test độc lập vì GTSRB không cung cấp track test đã kiểm chứng; không bao phủ tương quan giữa các ảnh cùng biển thực nếu có. Đây là khoảng riêng từng mức, chưa hiệu chỉnh cho ba so sánh.

Bảng 13. Chênh lệch Macro-F1, CLAHE rồi Gaussian trừ Gaussian rồi CLAHE, đơn vị điểm phần trăm. Khoảng tin cậy percentile 95% từ cùng ảnh ghép cặp.

Mức	Chênh lệch	CI chỉ ảnh	CI checkpoint + ảnh
Nhẹ	+0.165	[+0.059; +0.275]	[-0.111; +0.442]
Vừa	+0.110	[+0.015; +0.201]	[-0.164; +0.358]
Nặng	+0.154	[+0.056; +0.255]	[-0.018; +0.311]

Khoảng chỉ ảnh đều nằm trên 0 trong các CNN đang giữ cố định. Khi lấy mẫu cả checkpoint, ba khoảng đều chứa 0: ưu thế trung bình nhỏ chưa ổn định theo biến động huấn luyện. Điều này không chứng minh hai thứ tự tương đương; cần thêm lần huấn luyện độc lập và giao thức lấy mẫu phù hợp để kết luận rộng hơn.

5. THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN

5.1. Chất lượng ảnh cao có bảo đảm nhận dạng tốt?

Trên full-test mức vừa, Zero-DCE đạt PSNR 19,98 dB, cao hơn diffusion 14,77 dB, nhưng Macro-F1 chỉ đạt 72,34% so với 81,57%. Xếp hạng theo sai số pixel vì thế không thay thế được xếp hạng nhận dạng.

Khảo sát khử nhiễu còn cho phản ví dụ với cả hai chỉ số ảnh. Ở mức nặng, Gaussian đơn lẻ có PSNR 13,78 dB và SSIM 0,2847, thấp hơn diffusion 14,79 dB và 0,4768; tuy nhiên Macro-F1 của Gaussian đạt 68,60%, cao hơn diffusion 62,46%. Phép xử lý có thể giữ đặc trưng phân lớp hữu ích dù ảnh đầu ra còn tối và chưa gần ảnh tham chiếu về cấu trúc trung bình.

Gaussian rồi Gamma ở mức vừa đạt PSNR 17,62 dB, SSIM 0,5996 và Macro-F1 85,54%. Cải thiện đồng thời là kết quả đo trong giao thức này; không bảo đảm tăng PSNR/SSIM sẽ luôn tăng F1. Chỉ số ảnh đo sai khác trên toàn crop, trong khi CNN có thể phụ thuộc mạnh vào vùng nhỏ chứa nét số, viền hoặc biểu tượng.

5.2. Phương pháp và kết quả phân tích tương quan

Tương quan tính riêng từng mức, với tám phương pháp tăng sáng/đối chứng, dùng chất lượng ảnh và nhận dạng trên cùng full-test 12.630 ảnh. Mỗi phương pháp là một điểm; loại clean vì PSNR vô hạn và không phải phương án phục hồi. Pearson đo liên hệ tuyến tính:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}. \tag{24}$$

Spearman là Pearson trên thứ hạng, dùng thứ hạng trung bình khi bằng nhau.

Spearman giữa PSNR và Macro-F1 giảm từ 0,667 ở mức nhẹ xuống 0,357 ở mức vừa và 0,286 ở mức nặng. Với SSIM và Macro-F1, các giá trị tương ứng là 0,714; 0,738 và 0,619. SSIM phù hợp hơn với thứ hạng F1 trong tám phương án này, nhưng phản ví dụ Gaussian–diffusion cho thấy nó cũng không thể chọn thay metric nhận dạng.

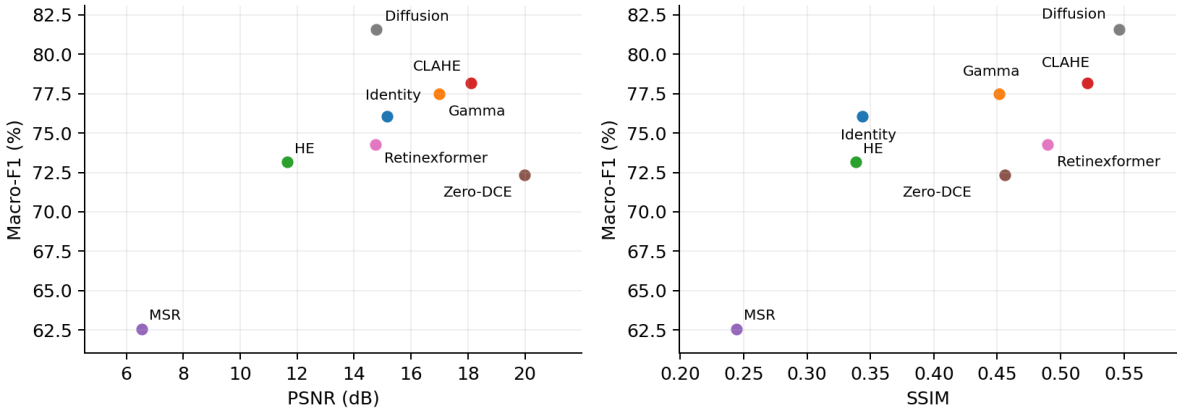
Tám điểm là quy mô nhỏ và chia sẻ ảnh, nhiễu, checkpoint. Một phương pháp thấp ở cả hai trục như MSR có thể ảnh hưởng đáng kể tới Pearson. Đây là thống kê khám phá, không chứng minh nhân quả hay tính khái quát tới camera đêm. Tương quan của khảo sát kết hợp được lưu riêng; không gộp các chuỗi có chung thành phần để tăng số điểm hình thức.

5.3. Ablation: tách độ tối và từng thành phần nhiễu

Ablation giữ $\gamma_d = 2,2$, checkpoint và tham số tăng sáng; thay riêng bốn mô hình suy giảm: chỉ Gamma, thêm Gaussian $\sigma = 0,01$, thêm Poisson $p = 60$, và thêm cả hai. Ma trận có

Bảng 14. Tương quan trên full-test, $n = 8$ phương pháp tăng sáng/đối chứng mỗi hàng.

Mức	Chất lượng	Nhận dạng	Pearson	Spearman
Vừa	PSNR	Accuracy	0.584	0.238
Vừa	PSNR	Macro-F1	0.673	0.357
Vừa	SSIM	Accuracy	0.862	0.857
Vừa	SSIM	Macro-F1	0.809	0.738
Nhẹ	PSNR	Accuracy	0.739	0.690
Nhẹ	PSNR	Macro-F1	0.713	0.667
Nhẹ	SSIM	Accuracy	0.838	0.762
Nhẹ	SSIM	Macro-F1	0.813	0.714
Nặng	PSNR	Accuracy	0.696	0.405
Nặng	PSNR	Macro-F1	0.702	0.286
Nặng	SSIM	Accuracy	0.733	0.738
Nặng	SSIM	Macro-F1	0.587	0.619



Hình 8. PSNR/SSIM và Macro-F1 mức vừa trên full-test. Mỗi điểm là phương pháp, không phải một ảnh độc lập.

$4 \times 3 \times 8 \times 3 = 288$ lượt trên 430 ảnh. Với Gamma-only, noise seed không tạo ảnh mới nên không xem là nguồn quan sát độc lập.

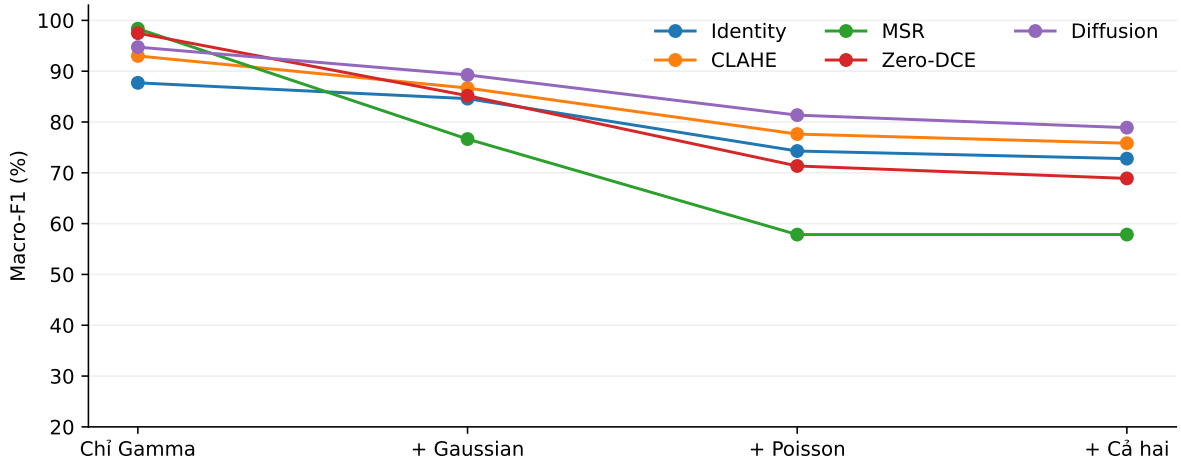
MSR đạt 98,36% với Gamma-only nhưng còn 57,84% khi thêm cả hai nhiễu. Zero-DCE giảm từ 97,49% xuống 68,90%; diffusion từ 94,74% xuống 78,89%. Kết quả củng cố yêu cầu xét nhiễu khi đánh giá tăng sáng. Không thể kết luận Poisson luôn nghiêm trọng hơn Gaussian vì hai mức nhiễu chưa được cân bằng về năng lượng.

5.4. Diễn giải hiệu quả khử nhiễu và thứ tự

Gaussian giảm dao động cục bộ, phù hợp với một thành phần nhiễu được cài trực tiếp trong mô hình suy giảm. Đặt trước Gamma có thể hạn chế khuếch đại nhiễu vùng tối. Đổi lại, bộ

Bảng 15. Macro-F1 (%) khi tách thành phần suy giảm; cùng tham số xử lý đã chọn.

Phương pháp	Chỉ Gamma	+ Gaussian	+ Poisson	+ Cả hai
Identity	87.71	84.60	74.29	72.79
Gamma	94.25	86.62	76.71	74.95
HE	93.91	82.23	72.26	68.94
CLAHE	93.00	86.68	77.62	75.82
MSR	98.36	76.64	57.84	57.84
Zero-DCE	97.49	85.17	71.35	68.90
Retinexformer	88.97	83.23	76.92	72.21
Diffusion	94.74	89.26	81.35	78.89



Hình 9. Ảnh hưởng từng thành phần suy giảm trên subset, tính từ bảng ablation cùng gói kết quả.

lọc làm mềm nét số và biên. F1 tốt trong mô hình nhiễu tổng hợp không bảo đảm tốt với lóa đèn, nhòe chuyển động hoặc nhiễu cảm biến thực.

Khoảng tin cậy chỉ lấy mẫu ảnh của cặp Gaussian–CLAHE nhỏ và dương, nhưng khoảng có lấy mẫu checkpoint đều chứa 0. Cần phân biệt một thay đổi nhất quán trong các mô hình đã giữ cố định với ưu thế ổn định khi huấn luyện lại. Kết quả không hỗ trợ quy tắc thứ tự chung cho mọi bộ lọc.

Bilateral và NLM có cơ chế giữ biên hoặc dùng độ tương tự mảnh ảnh, nhưng không mặc nhiên tốt hơn Gaussian trên crop nhỏ. Lưới tham số hữu hạn; NLM còn có lượng tử hóa 8 bit và chuyển màu nội bộ. Chênh lệch thuộc cả cấu hình triển khai, không tách riêng nguyên lý lọc khỏi mọi bước chuyển đổi.

5.5. Chi phí xử lý và giới hạn triển khai

GPU thực nghiệm là Tesla T4. Phép truyền thống chạy CPU; mô hình sâu chạy GPU theo adapter. Thời gian enhancer loại trừ tạo nhiễu, I/O, metric và CNN; chưa phải độ trễ camera. Ở phiên khảo sát khử nhiễu, Gaussian rồi Gamma đo khoảng 0,293 ms/ảnh và CLAHE rồi

Bảng 16. PSNR (dB) / SSIM trên full-test của các phương pháp đã sàng lọc.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	19.33 / 0.6115	15.17 / 0.3433	13.56 / 0.2240
Gamma	23.82 / 0.7034	16.99 / 0.4516	14.61 / 0.2948
CLAHE	23.19 / 0.6981	18.11 / 0.5209	15.45 / 0.3679
Diffusion	14.52 / 0.5756	14.77 / 0.5462	14.79 / 0.4768
Gaussian	19.75 / 0.7267	15.40 / 0.4185	13.78 / 0.2847
Gaussian $\rightarrow$ CLAHE	24.37 / 0.8495	18.46 / 0.6208	15.80 / 0.4560
CLAHE $\rightarrow$ Gaussian	25.62 / 0.8798	18.84 / 0.6536	15.93 / 0.4807
Gaussian $\rightarrow$ Gamma	25.51 / 0.8856	17.62 / 0.5996	15.22 / 0.4295

Bảng 17. Độ trễ enhancer mức vừa trên full-test nhóm tăng sáng, ms/ảnh.

Phương pháp	Thời gian
Identity	0.126
Gamma	0.230
HE	0.199
CLAHE	0.417
MSR	2.235
Zero-DCE	1.589
Retinexformer	12.578
Diffusion	227.869

Gaussian khoảng 0,688 ms/ảnh mức vừa. Đối chứng tăng sáng dùng lại từ phiên khác, nên tỷ số thời gian giữa đối chứng và chuỗi mới không phải phép đo tốc độ có kiểm soát trong cùng phiên.

Thí nghiệm giới hạn ở RGB 64×64, ROI có sẵn, một kiến trúc CNN, ba checkpoint và một mô hình thiếu sáng tổng hợp. Chưa có dữ liệu camera đêm thực, detector hoặc video. Bootstrap ở Bảng 13 chỉ khảo sát cặp Gaussian–CLAHE với ba checkpoint và ba noise seed cố định, không xác lập ưu thế cho mọi cấu hình hay quần thể camera. Lưới tham số hữu hạn và enhancer học trên miền khác; tối ưu chỉ có nghĩa tốt nhất theo validation trong tập phương án đã xét.

5.6. Phân tích lỗi ghép cặp và theo lớp

5.6.1. Định nghĩa được giúp và bị làm sai

Với cùng mã ảnh, mức suy giảm, noise seed và checkpoint, gọi b_i, e_i, y_i là dự đoán Identity, dự đoán sau xử lý và nhãn thật:

$$H = \sum_i \mathbf{1}[b_i \neq y_i,\ e_i = y_i], \tag{25}$$

$$D = \sum_i \mathbf{1}[b_i = y_i,\ e_i \neq y_i]. \tag{26}$$

Với N ảnh ghép cặp, $\Delta\text{Accuracy} = 100(H - D)/N$ điểm phần trăm. Quan hệ này kiểm tra tính nhất quán; không dùng $H - D$ thay cho thay đổi Macro-F1. Hai nhóm còn lại là cùng đúng và cùng sai; nhóm cùng sai vẫn có thể đổi sang lớp sai khác.

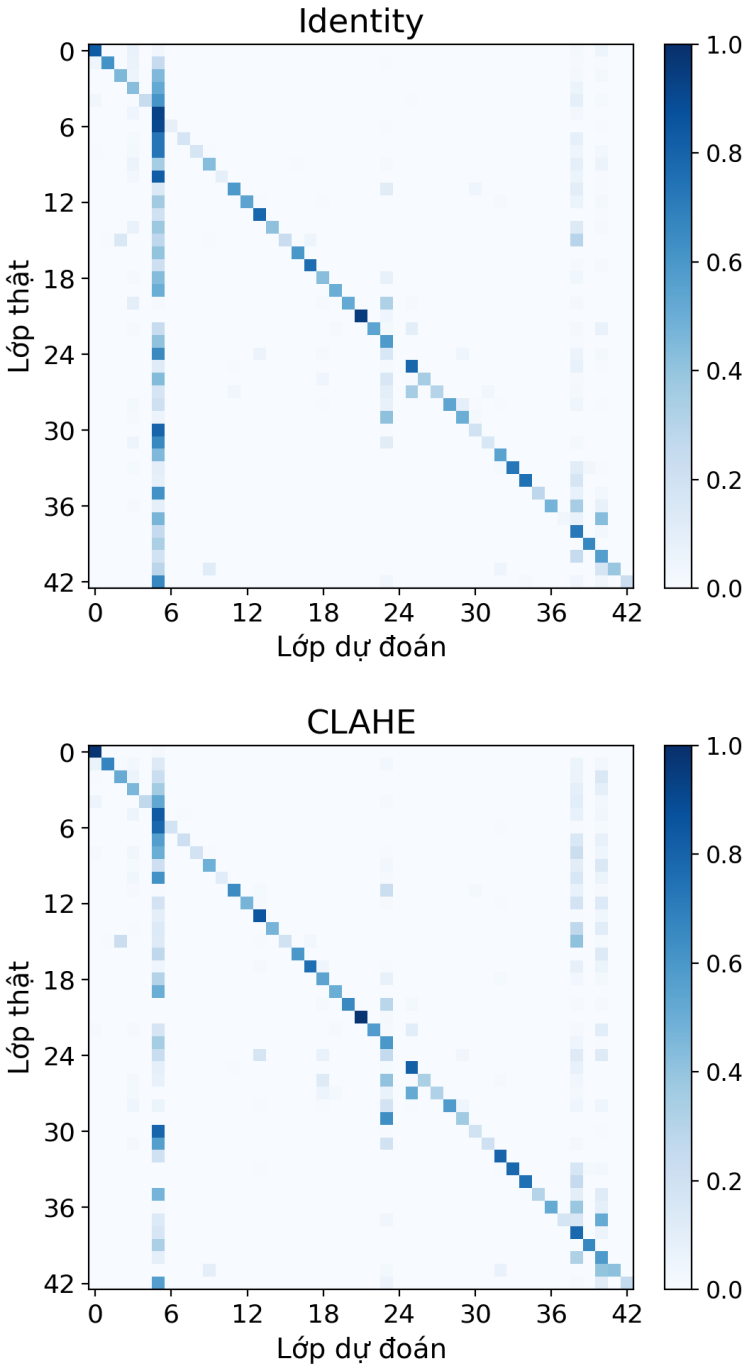
Bảng 18. Số ảnh trung bình được giúp (H), bị làm sai (D) mỗi lượt full-test 12.630 ảnh. Trung bình qua noise seed và checkpoint, không phải ảnh nguồn độc lập.

Phương pháp	Mức	H	D	Δ Acc. (đpt)
CLAHE	Nhẹ	390.00	91.89	2.36
CLAHE	Vừa	540.44	102.44	3.47
CLAHE	Nặng	462.11	128.11	2.64
Diffusion	Nhẹ	717.56	263.00	3.60
Diffusion	Vừa	1616.67	295.00	10.46
Diffusion	Nặng	1477.78	456.67	8.08
Gaussian $\rightarrow$ Gamma	Nhẹ	826.22	21.00	6.38
Gaussian $\rightarrow$ Gamma	Vừa	1472.67	29.22	11.43
Gaussian $\rightarrow$ Gamma	Nặng	1727.89	33.67	13.41

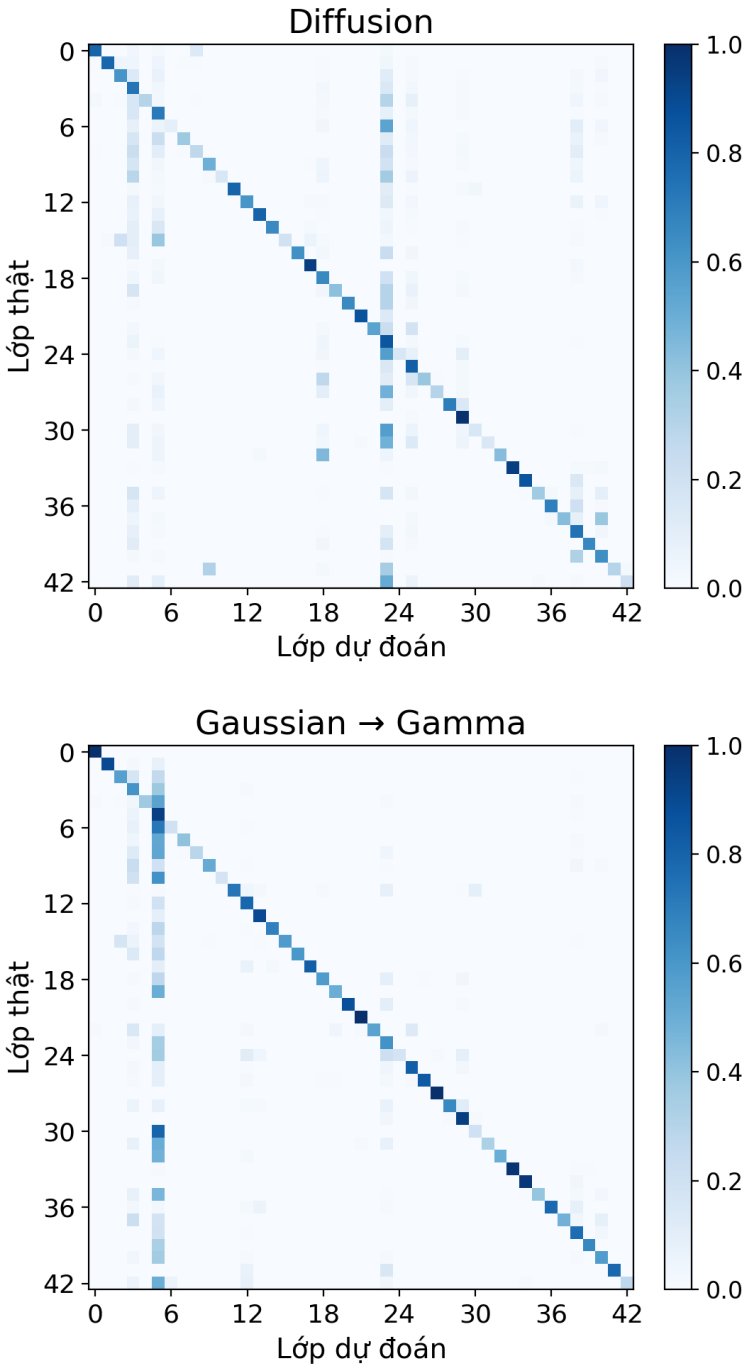
Ở mức vừa, Gaussian rồi Gamma sửa đúng trung bình 1472,67 ảnh nhưng làm sai 29,22 ảnh mỗi lượt, tăng ròng 1443,44 ảnh, tương ứng 11,43 điểm phần trăm Accuracy. Lợi ích tổng thể vẫn đi kèm nhóm mẫu bị ảnh hưởng bất lợi. Tính cả hai hướng chuyển giúp tránh chỉ trình bày ví dụ được cải thiện.

5.6.2. Ma trận nhầm lẫn và các cặp nhầm

Ma trận C_{ab} có hàng là nhãn thật và cột là dự đoán. Chuẩn hóa hàng bằng support lớp thật giúp xem recall và cặp nhầm dù full-test mất cân bằng lớp.



Hình 10. Ma trận chuẩn hóa hàng của Identity và CLAHE, full-test mức nặng, checkpoint 11, noise seed 101. Mỗi hàng là một lớp thật; cột 5 biểu thị dự đoán giới hạn 80 km/h.



Hình 11. Ma trận của diffusion và Gaussian rồi Gamma trên cùng 12.630 ảnh, mức, checkpoint và noise seed như Hình 10. Đây là một lát cắt xác định, không phải ma trận trung bình qua seed.

Bảng 19. Ba cặp nhầm có tỷ lệ trung bình cao nhất của mỗi phương pháp ở mức nặng, full-test. Mẫu nguồn dùng chung giữa các lượt.

Phương pháp	Lớp thật	Lớp dự đoán	Tỷ lệ (%)
Identity	10	5	84.16
Identity	6	5	82.67
Identity	30	5	79.93
CLAHE	30	5	79.70
CLAHE	6	5	77.41
CLAHE	10	5	74.85
Diffusion	15	5	36.67
Diffusion	6	3	27.33
Diffusion	30	3	27.04
Gaussian → Gamma	30	5	71.63
Gaussian → Gamma	10	5	66.62
Gaussian → Gamma	6	5	66.44

5.6.3. Hiện tượng tập trung dự đoán vào lớp 5

Lớp 5 là biển giới hạn 80 km/h, có 630/12.630 ảnh, tương ứng 4,99% full-test. Định nghĩa $q_5 = \sum_a C_{a5}/N$ là tỷ lệ dự đoán lớp 5 và $e_5 = (\sum_a C_{a5} - C_{55})/N$ là tỷ lệ toàn bộ ảnh bị gán sai vào lớp này. Precision lớp 5 đo phần dự đoán 80 km/h thực sự đúng. Mỗi chỉ số được tính riêng từng lượt rồi tổng hợp theo noise seed và checkpoint.

Bảng 20. Tập trung dự đoán vào lớp 5 ở mức nặng, đơn vị %. Hai cột đầu lấy mẫu số là toàn bộ 12.630 ảnh/lượt; precision dùng số ảnh được dự đoán lớp 5.

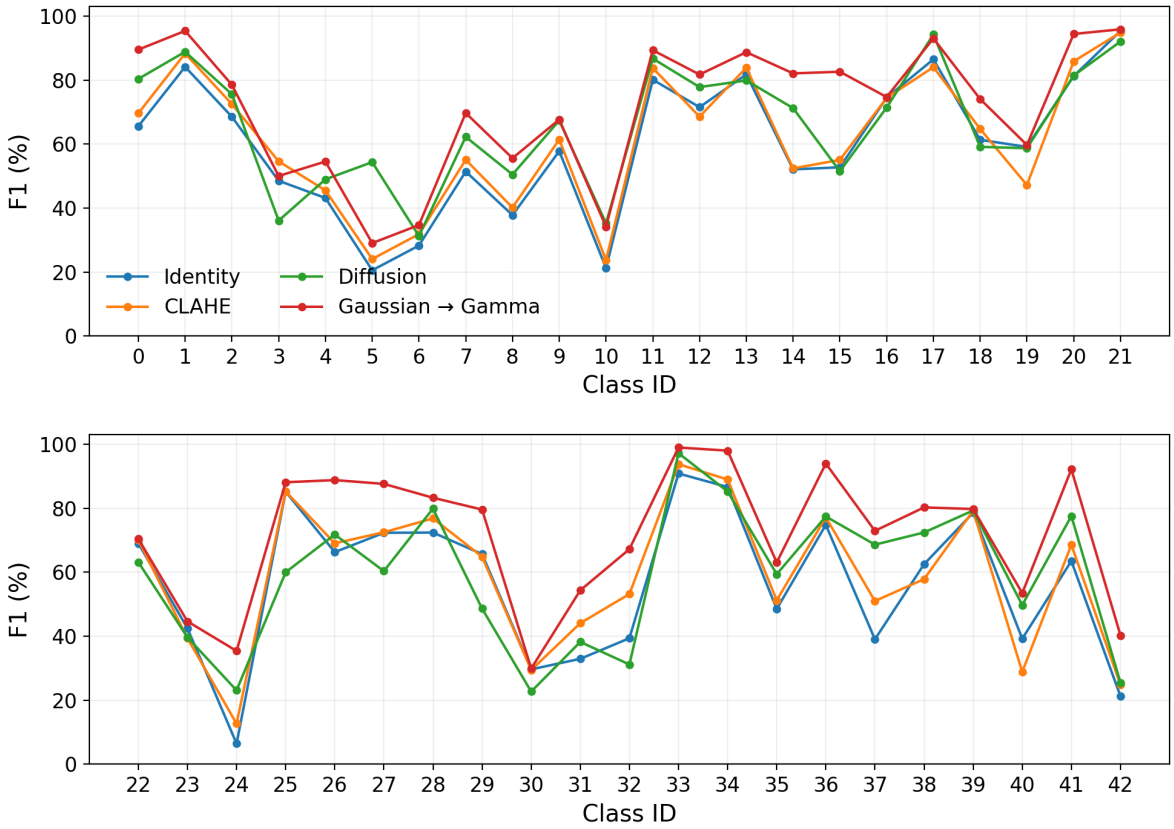
Phương pháp	Dự đoán lớp 5	Gán sai vào lớp 5	Precision lớp 5
Identity	43.17	38.32	11.51
CLAHE	34.52	29.82	13.83
Diffusion	8.99	5.21	42.58
Gaussian → Gamma	28.97	24.14	17.16

Identity dự đoán lớp 5 cho 43,17% ảnh dù tỷ lệ thật chỉ là 4,99%; 38,32% toàn tập bị gán sai vào lớp này. Gaussian rồi Gamma giảm tỷ lệ dự đoán lớp 5 còn 28,97% nhưng vẫn tập trung mạnh; precision lớp 5 chỉ đạt 17,16%. Diffusion có tỷ lệ dự đoán lớp 5 thấp hơn, 8,99%, dù Macro-F1 tổng thể thấp hơn chuỗi được chọn. Như vậy, ưu thế trung bình không đồng nghĩa mọi kiểu lỗi đều được giảm tốt nhất.

Các cột 5 đậm và những cặp nhầm như lớp 10/6/30 sang lớp 5 phản ánh xu hướng dồn quyết định về một lớp khi suy giảm nặng. Mất tương phản, nét số nhỏ và sai khác miền đầu vào là các giả thuyết phù hợp để kiểm tra; ma trận chưa chứng minh nguyên nhân nằm riêng ở màu hay hình dạng. Chưa đo activation, độ nhạy theo vùng hoặc so phân bố train nên không quy

hiện tượng này trực tiếp cho mất cân bằng lớp. Sáu ảnh kiểm chứng ở phần sau cho thấy cả sửa đúng lẫn phát sinh nhầm 60 thành 80 km/h.

5.6.4. Các lớp khó và ví dụ có metadata



Hình 12. F1 từng lớp mức nặng trên full-test, tách lớp 0–21 và 22–42 để dễ đọc. Trung bình noise trong checkpoint rồi trung bình ba checkpoint; không phải khoảng tin cậy của camera thực.

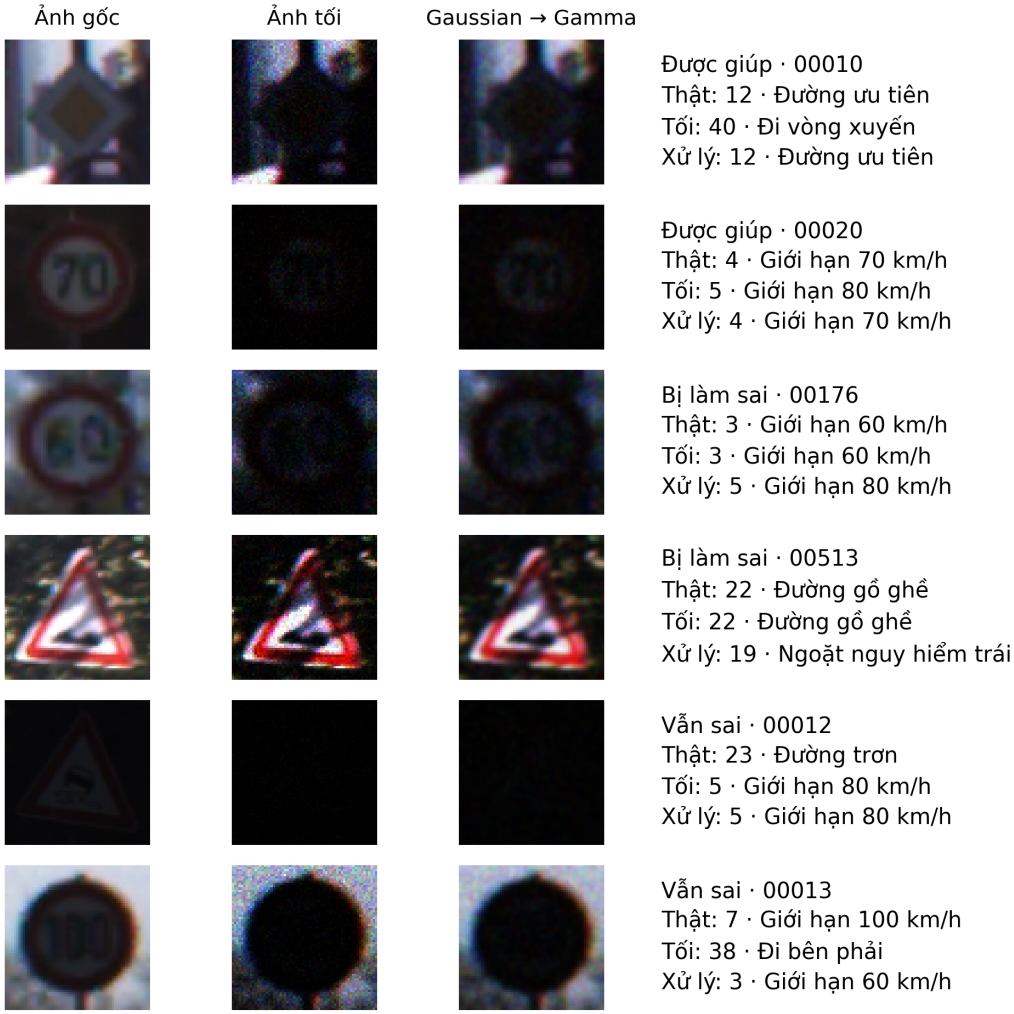
Bảng 21. Năm lớp có F1 thấp nhất của Gaussian rồi Gamma mức nặng. SD qua checkpoint sau trung bình noise; chênh lệch so Identity là điểm phần trăm.

Class ID	F1 (%)	SD	Δ F1
5	29.04	5.13	8.50
30	29.92	2.49	0.26
10	34.17	3.71	12.95
6	34.67	3.01	6.41
24	35.41	4.06	28.97

Macro-F1 tăng không có nghĩa mọi lớp đạt hiệu năng tốt. Các lớp khó vẫn có F1 thấp và cần xem cùng support, cặp nhầm và ảnh nguồn. Không quy một cặp nhầm chắc chắn cho mất nét số hoặc sai màu chỉ từ ma trận; đó là giả thuyết cần quan sát ảnh cụ thể để xác nhận.

5.6.5. Đối chiếu trực quan sáu mẫu kiểm chứng

Hình 13 dùng full-test mức vừa, checkpoint 11 và noise seed 101; mỗi nhóm lấy hai ID nhỏ nhất. Ảnh được cắt lại từ PPM chính thức theo đúng ROI, lề và phép nội suy; cả 12 dự đoán trên ảnh tối và ảnh xử lý đều khớp CSV đã kiểm chứng. Nhãn sáu ảnh được đối chiếu với annotations chính thức.



Hình 13. Ảnh gốc, ảnh tối và Gaussian rồi Gamma trên cùng sáu mẫu GTSRB [5]. Tên biển đi kèm Class ID; ID ảnh là phần cuối của `gtsrb/test/<ID>`. Các ảnh dùng cùng thang RGB, phóng bằng láng giềng gần nhất, không tự cân bằng sáng để hiển thị.

Được giúp: 00010 đổi từ vòng xuyến sang đúng đường ưu tiên; 00020 đổi từ giới hạn 80 sang đúng 70 km/h. Nhiễu hạt giảm sau lọc, nhưng đầu ra vẫn tối; nhận dạng đúng không đòi hỏi ảnh phải sáng rõ hoàn toàn.

Bị làm sai: 00176 đổi từ đúng 60 sang 80 km/h; 00513 đổi từ đúng đường gồ ghề sang ngoặt trái. Ảnh xử lý ít hạt hơn nhưng nét nhỏ vẫn mềm; giảm nhiễu không bảo đảm giữ đặc trưng phân lớp.

Vẫn sai: 00012 và 00013 còn rất tối sau xử lý, nét biểu tượng và chữ số chưa rõ đủ để dự đoán đúng. Hình cho phép quan sát hiện tượng, chưa xác định pixel hoặc cơ chế nào gây ra quyết định của CNN. Sáu mẫu không thay thế thống kê toàn tập.

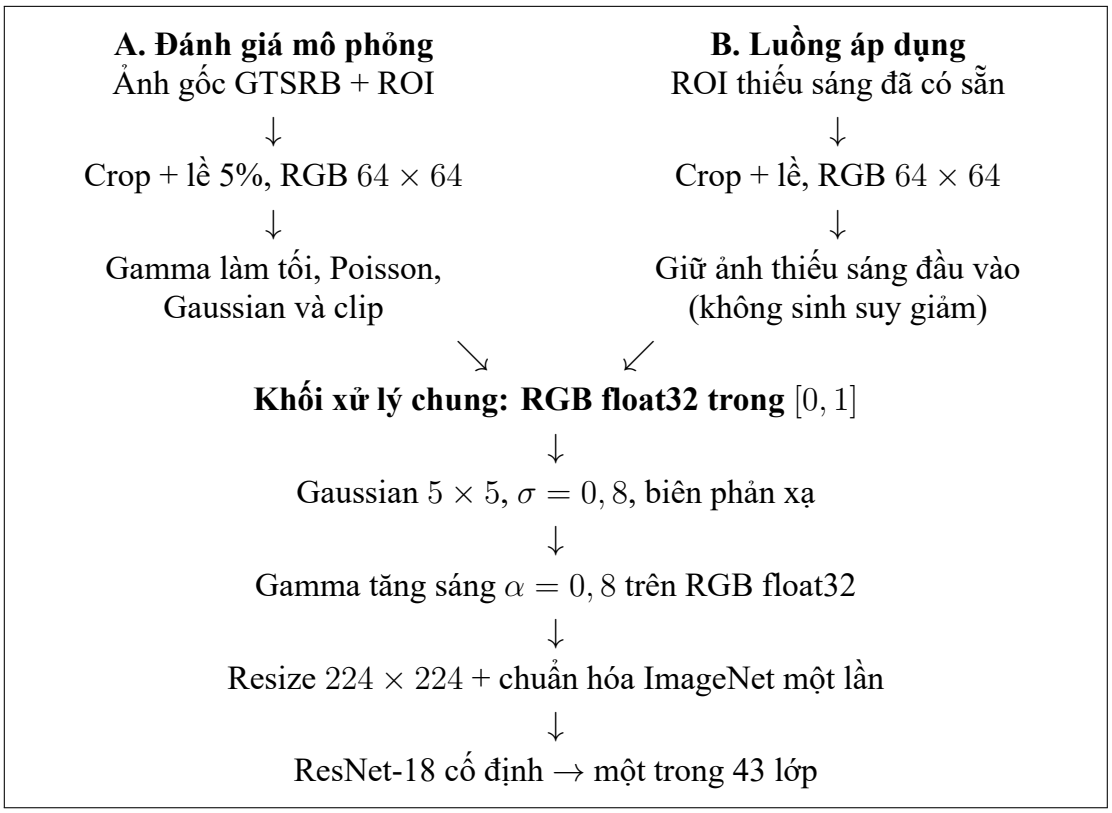
6. ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ

6.1. Tiêu chí lựa chọn

Mục tiêu là nhận dạng đủ 43 lớp, nên Macro-F1 validation dùng để chọn xử lý; Accuracy và Weighted-F1 kiểm tra bổ sung. PSNR/SSIM giải thích thay đổi ảnh, không quyết định thay hiệu năng nhận dạng. Diffusion được chọn trong nhóm tăng sáng; sau xét thêm khử nhiễu và thứ tự, Gaussian rồi Gamma đạt điểm validation cao nhất (77,77%) và được chọn trước test.

Quy trình được chọn không nhất thiết cao nhất ở mọi ô test. CLAHE rồi Gaussian có điểm test mức nặng nhỉnh hơn, nhưng thay lựa chọn sau khi thấy test sẽ làm sai vai trò tập kiểm tra. Mục tiêu khác, như ràng buộc độ trễ, cần được xác định và đánh giá bằng validation.

6.2. Quy trình được lựa chọn



Hình 14. Hai nguồn đầu vào dùng chung chuỗi được chọn trên validation. Chỉ nhánh A sinh suy giảm và dùng ảnh gốc để tính PSNR/SSIM ở 64×64; nhánh B mô tả cách áp dụng, chưa được đánh giá trên ảnh camera thực.

Crop thiếu sáng thực đi trực tiếp vào khối lọc và Gamma sau chuẩn hóa. Luồng này giả định ROI đã được cung cấp, không bổ sung detector. Nhãn và ảnh sáng tham chiếu không được đưa vào pipeline. Bộ đánh giá mới dùng ảnh tham chiếu để đo chất lượng và nhãn để chấm phân loại. Bộ lọc dùng `BORDER_REFLECT_101`; không có chuyển 8 bit trong chuỗi Gaussian–Gamma.

Đầu ra được kiểm tra kích thước, ba kênh, miền giá trị và tính hữu hạn. Ba checkpoint giữ nguyên, không thích nghi theo test. Điểm validation và F1 full-test không tự tạo thành bảo đảm an toàn cho hệ thống hỗ trợ lái xe.

6.3. Đối chứng và tổ chức cài đặt

Identity, Gamma, CLAHE, diffusion và Gaussian đơn lẻ giúp phân biệt lợi ích từng thành phần. So hai thứ tự Gaussian–CLAHE giữ clip limit 1, lưới 4×4 và cùng tham số Gaussian. Đổi cả độ mạnh lẫn thứ tự sẽ không còn cô lập được ảnh hưởng của thứ tự.

Mã xử lý ở `src/degradation.py`, `src/enhancement.py` và `src/tools/processing_pipeline.py`. `src/tools/processing_study.py` chọn tham số, khóa giao thức; `src/metrics.py` tính metric; cấu hình ở `configs/`. Tham số, split, mã ảnh và hash checkpoint đi kèm kết quả để tái lập từng phép so sánh.

6.4. Hướng đánh giá tiếp theo

Ưu tiên dữ liệu thiếu sáng thực có nhãn tương thích, kiểm tra lỗi nét số/biên/màu và toàn cảnh có detector. Không có ảnh sáng ghép cặp chính xác thì không tính PSNR/SSIM như thí nghiệm tổng hợp. Cần thêm kiến trúc nhận dạng, điều kiện thu nhận và lần huấn luyện độc lập. Khi có track test đáng tin cậy, nên lấy mẫu lại theo track thay cho từng ảnh; khoảng bootstrap hiện tại chưa xử lý được nguồn phụ thuộc này.

6.5. Tái lập thực nghiệm

6.5.1. Mã nguồn và môi trường

Notebook công khai kèm mã và cấu hình:

https://www.kaggle.com/code/kieuthithutrang/gtsrb-low-light-enhancement-for-traffic-signs

Dữ liệu tải từ archive GTSRB chính thức; mã và weights enhancer khóa theo nguồn tác giả, commit và SHA-256. Khi so sánh, giữ nguyên split, mã ảnh, mức suy giảm, noise seed và ba checkpoint. Tham số chọn trên validation trước test. Hướng dẫn nằm trong `README.md` và `configs/`.

6.5.2. Bằng chứng và tính nhất quán

Gói kết quả giữ giao thức, trạng thái, dự đoán CSV và confusion matrix NPZ. Đã tính lại Accuracy, Macro-F1, Weighted-F1 từ 5.847.990 dòng dự đoán ở bốn phạm vi, sai số so bảng tổng hợp không quá 10^{-8}; hash ba CNN khớp giữa các phạm vi. Đối chứng dùng lại được ghi nguồn, không coi là quan sát độc lập mới. Kiểm tra nhãn/group giữa các lượt không thay thế xác minh nhãn độc lập trên ảnh nguồn.

Bằng chứng gọn và provenance ở `report/evidence/final/`. ZIP không kèm ảnh GTSRB, cache hoặc weights enhancer tác giả; các đầu vào này được xác định bằng nguồn tải và cấu hình. Checkpoint CNN do nhóm huấn luyện được giữ để tái lập. SHA-256 phát hiện thay đổi file, không tự chứng minh tính đúng của kết luận nghiên cứu.

7. KẾT LUẬN

Bài tập lớn khảo sát tăng sáng, khử nhiễu và thứ tự xử lý đối với nhận dạng 43 lớp GTSRB. Ảnh thiếu sáng tạo bằng Gamma, Poisson và Gaussian ở ba mức; các phép xử lý dùng chung đầu vào và ba checkpoint ResNet-18 cố định. Tham số và tập phương pháp full-test được chọn trên validation trước test.

Trong nhóm tăng sáng, diffusion được chọn theo quy tắc validation. Khi xét thêm khử nhiễu và kết hợp, Gaussian 5×5, $\sigma = 0,8$ rồi Gamma $\alpha = 0,8$ được chọn với Macro-F1 validation 77,77%. Trên 12.630 ảnh test, chuỗi đạt Macro-F1 96,70%; 85,54%; 71,56%, tăng 6,25; 9,47; 13,19 điểm phần trăm so ảnh tối giữ nguyên. Thiếu sáng nặng vẫn chưa được khắc phục hoàn toàn.

PSNR/SSIM không thay thế đánh giá nhận dạng: Gaussian đơn lẻ mức nặng có cả PSNR/SSIM thấp hơn diffusion nhưng F1 cao hơn. Ablation cho thấy MSR từ 98,36% với Gamma-only còn 57,84% khi có cả hai nhiễu. Tăng sáng hoặc cải thiện một metric ảnh chưa đủ chứng minh giữ được chi tiết phân biệt lớp.

Thứ tự tác động phụ thuộc bộ lọc, phép tăng sáng và cấu hình. Cặp Gaussian–CLAHE trên full-test có chênh lệch trung bình nhỏ theo hướng CLAHE rồi Gaussian; một số lượt có chiều ngược lại. Khoảng bootstrap 95% chỉ ảnh là dương, nhưng khi lấy mẫu cả checkpoint đều chứa 0, nên chưa đủ cơ sở khẳng định ưu thế ổn định khi huấn luyện lại. Không có bằng chứng cho một thứ tự tốt nhất với mọi phương pháp. Ở mức vừa, chuỗi được chọn sửa đúng trung bình 1472,67 ảnh nhưng làm sai 29,22 ảnh mỗi lượt; cần xét cả lợi ích và lỗi phát sinh.

Kết quả hỗ trợ lựa chọn tiền xử lý theo tác vụ nhận dạng và kiểm soát dữ liệu. Đóng góp nhóm là triển khai, kiểm chứng và so sánh có kiểm soát, chưa đề xuất thuật toán mới. Kết luận giới hạn ở ROI GTSRB với suy giảm mô phỏng, một kiến trúc CNN và lưới tham số hữu hạn; chưa chứng minh hiệu quả trên camera đêm thực, video hoặc hệ thống cảnh báo trong xe.

———- HẾT ———-

TÀI LIỆU THAM KHẢO

[1] C. Guo *et al.*, "Zero-reference deep curve estimation for low-light image enhancement," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 1780–1789, doi: 10.1109/CVPR42600.2020.00185.

[2] Y. Cai, H. Bian, J. Lin, H. Wang, R. Timofte, and Y. Zhang, "Retinexformer: One-stage Retinex-based Transformer for low-light image enhancement," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 12504–12513, doi: 10.1109/ICCV51070.2023.01149.

[3] H. Jiang, A. Luo, H. Fan, S. Han, and S. Liu, "Low-light image enhancement with wavelet-based diffusion models," *ACM Trans. Graph.*, vol. 42, no. 6, Dec. 2023, Art. no. 238, doi: 10.1145/3618373.

[4] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "The German Traffic Sign Recognition Benchmark: A multi-class classification competition," in *Proc. Int. Joint Conf. Neural Netw. (IJCNN)*, 2011, pp. 1453–1460, doi: 10.1109/IJCNN.2011.6033395.

[5] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "German Traffic Sign Recognition Benchmark GTSRB," public dataset archive. Accessed: Oct. 24, 2026. [Online]. Available: https://sid.erda.dk/public/archives/daaeac0d7ce1152aea9b61d9f1e19370/published-archive.html

[6] OpenCV, "Histograms - 2: Histogram equalization." Accessed: Oct. 19, 2026. [Online]. Available: https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html

[7] K. Zuiderveld, "Contrast limited adaptive histogram equalization," in *Graphics Gems IV*, P. S. Heckbert, Ed. Academic Press, 1994, pp. 474–485, doi: 10.1016/B978-0-12-336156-1.50061-6.

[8] D. J. Jobson, Z. Rahman, and G. A. Woodell, "A multiscale retinex for bridging the gap between color images and the human observation of scenes," *IEEE Trans. Image Process.*, vol. 6, no. 7, pp. 965–976, July 1997, doi: 10.1109/83.597272.

[9] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, Apr. 2004, doi: 10.1109/TIP.2003.819861.

[10] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 6840–6851. [Online]. Available: https://arxiv.org/abs/2006.11239

[11] C. Tomasi and R. Manduchi, "Bilateral filtering for gray and color images," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 1998, pp. 839–846, doi: 10.1109/ICCV.1998.710815.

[12] A. Buades, B. Coll, and J.-M. Morel, “A non-local algorithm for image denoising,” in *Proc. IEEE Computer Society Conf. Computer Vision and Pattern Recognition (CVPR)*, vol. 2, 2005, pp. 60–65, doi: 10.1109/CVPR.2005.38.

[13] OpenCV, “Smoothing images.” Accessed: Oct. 24, 2026. [Online]. Available: https://docs.opencv.org/4.x/d4/d13/tutorial_py_filtering.html

[14] OpenCV, “Image denoising.” Accessed: Oct. 24, 2026. [Online]. Available: https://docs.opencv.org/4.x/d5/d69/tutorial_py_non_local_means.html

[15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[16] B. Efron, “Bootstrap methods: Another look at the jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979, doi: 10.1214/aos/1176344552.