ĐẠI HỌC PHENIKAA

TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÁO CÁO BÀI TẬP LỚN

Nhóm 2

MÔN: XỬ LÝ ẢNH

KHẢO SÁT ẢNH HƯỞNG CỦA XỬ LÝ ẢNH ĐẾN HIỆU NĂNG NHẬN DẠNG BIỂN BÁO GIAO THÔNG TRONG ĐIỀU KIỆN THIẾU SÁNG

Giảng viên hướng dẫn: TS. Nguyễn Ngọc Giang

24100093 – Kiều Thị Thu Trang – 24100093@st.phenikaa-uni.edu.vn

24100012 – Trần Minh Sang – 24100012@st.phenikaa-uni.edu.vn

24102651 – Ngô Quang Thiện – 24102651@st.phenikaa-uni.edu.vn

github.com/kttt294/GTSRB-Low-Light-Preprocessing | image-preprocessing.techvi.io.vn

Hà Nội, tháng 10 năm 2026

MỤC LỤC

1 GIỚI THIỆU BÀI TOÁN 1
1.1 Đặt vấn đề 1
1.2 Yêu cầu và phạm vi nghiên cứu 1
1.3 Đầu vào và đầu ra của hệ thống 2
1.4 Các hướng tiếp cận và giải pháp khảo sát 2
1.5 Đóng góp triển khai và xây dựng quy trình thực nghiệm 3
1.6 Ý nghĩa và bố cục báo cáo 3
2 XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM 4
2.1 Giới thiệu bộ dữ liệu GTSRB 4
2.2 Tiền xử lý và chuẩn hóa ảnh 4
2.3 Mô hình suy giảm thiếu sáng 6
2.4 Khảo sát histogram và cấu trúc ảnh 7
2.5 Bảo đảm điều kiện so sánh công bằng 8
3 CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH 8
3.1 Nguyên tắc chung của khối tăng cường 8
3.2 Hiệu chỉnh Gamma 9
3.3 Cân bằng histogram toàn cục (HE) 10
3.4 Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE) 10
3.5 Retinex đa tỉ lệ (Multi-Scale Retinex) 12
3.6 Các phương pháp tăng cường dựa trên học sâu 13
3.7 Minh họa trước và sau xử lý 14
3.8 Đánh giá chất lượng bằng PSNR và SSIM 15
3.9 Cơ chế học sâu và liên hệ với sai số nhận dạng 16
3.10 Khử nhiễu và thứ tự xử lý 17
4 THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ 20
4.1 Thiết lập mô hình kiểm chứng ResNet-18 20
4.2 Chỉ số đánh giá nhận dạng 21
4.3 Giao thức chọn tham số và tổng hợp số liệu 21
4.4 Phạm vi đánh giá và kiểm tra bằng chứng 22
4.5 Chất lượng ảnh của các phương pháp tăng sáng 22
4.6 Nhận dạng trên subset 430 ảnh 23
4.7 Đánh giá tăng sáng trên full-test 23
4.8 Khử nhiễu và các chuỗi kết hợp 24
4.9 Ảnh hưởng của thứ tự trên full-test 26
5 THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN 27
5.1 Chất lượng ảnh cao có bảo đảm nhận dạng tốt? 27
5.2 Phương pháp và kết quả phân tích tương quan 27
5.3 Ablation: tách độ tối và từng thành phần nhiễu 29
5.4 Diễn giải hiệu quả khử nhiễu và thứ tự 29
5.5 Chi phí xử lý và giới hạn triển khai 30
5.6 Phân tích lỗi ghép cặp và theo lớp 31
6 ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ 37
6.1 Tiêu chí lựa chọn 37
6.2 Quy trình được lựa chọn 37
6.3 Đối chứng và tổ chức cài đặt 38
6.4 Hướng đánh giá tiếp theo 38
6.5 Tái lập thực nghiệm 38
6.6 Website demo 40
7 KẾT LUẬN 42
TÀI LIỆU THAM KHẢO 43

1. GIỚI THIỆU BÀI TOÁN

1.1. Đặt vấn đề

Trong các hệ thống hỗ trợ lái xe và giao thông thông minh, biển báo cung cấp những thông tin trực tiếp về giới hạn tốc độ, hướng di chuyển và các tình huống cần cảnh báo. Khả năng nhận dạng đúng biển báo phụ thuộc trước hết vào chất lượng hình ảnh mà hệ thống tiếp nhận. Khi điều kiện chiếu sáng suy giảm, những đặc trưng quan trọng như đường viền, chữ số và mũi tên có thể trở nên khó phân biệt, ngay cả khi vị trí của biển báo đã được xác định.

Một hướng giải quyết thường được cân nhắc là tăng cường ảnh trước khi đưa vào mô hình nhận dạng. Tuy nhiên, tăng độ sáng không đồng nghĩa với phục hồi đầy đủ thông tin. Một phép biến đổi có thể làm vùng tối dễ quan sát hơn nhưng đồng thời khuếch đại nhiễu, thay đổi màu sắc hoặc làm nhòe những chi tiết nhỏ. Đối với biển báo giao thông, chỉ một nét bị mất trong chữ số hoặc một hướng mũi tên bị biến dạng cũng có thể dẫn đến dự đoán sai lớp.

Nhóm đặt ra câu hỏi chính cho đề tài là: *các phương pháp xử lý ảnh có giúp mô hình nhận dạng biển báo chính xác hơn khi ảnh bị thiếu sáng hay không?* Để trả lời câu hỏi này, nhóm không chỉ quan sát ảnh trước và sau xử lý mà còn tính các chỉ số chất lượng ảnh và kết quả phân loại. Những phép so sánh này cần được thực hiện trên cùng dữ liệu và cùng mô hình nhận dạng.

Khi tìm hiểu bài toán, nhóm nhận thấy ảnh thiếu sáng cần được xem xét cùng với nhiễu. Vùng tối có tín hiệu nhỏ nên nhiễu có thể chiếm tỷ lệ đáng kể so với phần thông tin hữu ích. Nếu phương pháp chỉ nâng độ sáng, nó có thể làm rõ cả cấu trúc biển báo lẫn nhiễu. Vì vậy, nhóm cho rằng việc chỉ làm tối ảnh bằng Gamma là chưa đủ để khảo sát tình huống ảnh vừa tối vừa nhiễu.

Nhóm cũng phân biệt chất lượng ảnh với khả năng nhận dạng của mô hình. PSNR phản ánh sai số cường độ pixel, còn SSIM xem xét sự tương đồng về cấu trúc cục bộ. Trong khi đó, mô hình phân loại dựa vào các đặc trưng đã học để phân biệt từng lớp. Một ảnh có sai số trung bình thấp vẫn có thể bị mất nét chữ số. Ngược lại, một ảnh chưa gần ảnh tham chiếu về độ sáng vẫn có thể giữ được hình dạng cần cho nhận dạng.

Để so sánh các phép xử lý, nhóm cần giữ các yếu tố còn lại ổn định. Nếu nhóm vừa đổi cách xử lý ảnh vừa huấn luyện lại mô hình riêng cho mỗi phương pháp, kết quả sẽ phản ánh đồng thời cả hai thay đổi. Vì vậy, nhóm sử dụng một kiến trúc ResNet-18, huấn luyện trên ảnh gốc rồi giữ nguyên trọng số khi đánh giá. Cách làm này cho biết mỗi phép xử lý giúp ích như thế nào đối với bộ nhận dạng đã có, nhưng chưa cho biết kết quả khi mô hình được huấn luyện thích nghi với ảnh sau xử lý.

1.2. Yêu cầu và phạm vi nghiên cứu

Đề bài yêu cầu khảo sát ảnh hưởng của xử lý ảnh đến hiệu năng nhận dạng biển báo giao thông trong điều kiện thiếu sáng trên bộ dữ liệu GTSRB. Ảnh suy giảm được mô phỏng bằng Gamma kết hợp nhiễu Gaussian và Poisson ở nhiều mức độ. Các phương pháp tăng cường cần so sánh gồm hiệu chỉnh Gamma, cân bằng histogram (HE), cân bằng histogram cục bộ có giới hạn tương phản (CLAHE), Retinex, Zero-DCE, Retinexformer và phương pháp dựa trên diffusion.

Ngoài các phương pháp tăng cường ảnh, nhóm khảo sát ba bộ lọc Gaussian, bilateral và Non-local Means. Nhóm thử từng bộ lọc riêng lẻ, sau đó kết hợp chúng với Gamma và CLAHE theo hai thứ tự. Độ mạnh của bộ lọc được chọn trên tập validation, tức tập dùng để lựa chọn cấu hình, và giữ giống nhau khi đảo thứ tự. Nhóm dùng PSNR và SSIM để đánh giá chất lượng ảnh, đồng thời dùng Accuracy và F1-score để đánh giá nhận dạng. Macro-F1 là tiêu chí chính vì chỉ số này cho mỗi lớp vai trò như nhau. Từ những kết quả đó, nhóm phân tích mối liên hệ giữa chất lượng ảnh và khả năng nhận dạng để lựa chọn quy trình tiền xử lý.

Trong phạm vi bài tập lớn, nhóm chỉ xử lý vùng ảnh đã chứa biển báo, không xử lý toàn cảnh giao thông. Bộ phân loại đưa mỗi ảnh vào một trong 43 lớp của GTSRB. Hệ thống chưa có bước phát hiện vị trí biển báo, theo dõi đối tượng hoặc xử lý video. Nhóm tạo điều kiện thiếu sáng từ ảnh gốc bằng mô hình suy giảm đã xác định. Nhờ vậy, mỗi ảnh suy giảm có một ảnh tham chiếu tương ứng để tính PSNR và SSIM.

1.3. Đầu vào và đầu ra của hệ thống

Đầu vào: Hệ thống nhận ảnh màu RGB đã cắt vùng quan tâm và đổi về kích thước 64×64 pixel. Giá trị cường độ được chuẩn hóa về $[0, 1]$. Từ ảnh gốc X, nhóm tạo ảnh thiếu sáng Y theo mức suy giảm và hạt giống sinh nhiễu đã chọn.

Đầu ra của khối xử lý ảnh: Mỗi phương pháp tạo ảnh $\widehat{X} = E(Y)$ có cùng kích thước, thứ tự kênh màu và miền giá trị với đầu vào. Hàm E chỉ nhận ảnh thiếu sáng. Nhóm không đưa ảnh tham chiếu hoặc nhãn lớp vào thuật toán tăng cường.

Đầu ra của khối nhận dạng: ResNet-18 trả về vector 43 giá trị dự đoán, từ đó nhóm lấy lớp có giá trị lớn nhất làm kết quả phân loại. Trước khi vào mạng, ảnh được nội suy lên 224×224 và chuẩn hóa theo ImageNet. Bước này phục vụ riêng bộ nhận dạng. Các phép xử lý ảnh và phép đo PSNR, SSIM vẫn được thực hiện ở 64×64.

Đầu ra nghiên cứu: Báo cáo trình bày các bảng PSNR, SSIM, Accuracy, Macro-F1 và thời gian xử lý. Nhóm bổ sung hình ảnh trước và sau xử lý, phân tích từng thành phần suy giảm bằng ablation và khảo sát tương quan giữa các chỉ số. Quy trình đề xuất được chọn trên validation trước khi đánh giá test.

1.4. Các hướng tiếp cận và giải pháp khảo sát

Các phương pháp truyền thống xử lý trực tiếp cường độ hoặc phân bố mức xám của ảnh. Gamma biến đổi từng pixel bằng hàm lũy thừa. HE phân bố lại mức sáng theo histogram toàn ảnh, còn CLAHE thực hiện theo từng vùng nhỏ. Retinex dựa trên mối quan hệ giữa phản xạ và chiếu sáng để làm rõ nội dung. Những phương pháp này có cách triển khai tương đối dễ theo dõi và thường có chi phí tính toán thấp.

Nhóm phương pháp học sâu sử dụng thông tin đã học để điều chỉnh hoặc phục hồi ảnh. Zero-DCE ước lượng đường cong tăng sáng, Retinexformer kết hợp biểu diễn chiếu sáng với Transformer, còn phương pháp diffusion được khảo sát thực hiện phục hồi có điều kiện trong miền wavelet. Dự án sử dụng trọng số công bố của tác giả, không huấn luyện lại các bộ tăng cường trên GTSRB [1], [2], [3].

Giải pháp của bài tập lớn không giả định một nhóm phương pháp luôn tốt hơn nhóm còn lại. Tất cả được đánh giá trên cùng ảnh suy giảm, cùng tập mẫu và cùng các checkpoint ResNet-18, tức các bộ trọng số đã lưu sau huấn luyện. Mốc đối chứng là *Identity*, tức ảnh tối giữ nguyên. Ảnh gốc *Clean* được dùng làm tham chiếu và kiểm tra hiệu năng nhận dạng khi chưa áp dụng mô hình suy giảm.

1.5. Đóng góp triển khai và xây dựng quy trình thực nghiệm

Nhóm xây dựng quy trình chuẩn bị dữ liệu từ các archive GTSRB chính thức, gồm đọc ảnh PPM và annotations, chuyển ảnh sang RGB, cắt vùng biển báo theo ROI với padding 5% và nội suy song tuyến tính về kích thước 64×64. Các bước này vận dụng kiến thức về biểu diễn ảnh, hệ tọa độ, phép cắt và lấy mẫu lại. Quy trình này đồng thời tạo đầu vào thống nhất cho tất cả phương pháp tăng cường và bộ phân loại. Chi tiết cài đặt và ý nghĩa của các lựa chọn được trình bày trong phần xây dựng tập dữ liệu.

Nhóm dùng ảnh số thực trong miền $[0, 1]$ khi tạo suy giảm và tăng cường. Trong khảo sát tăng sáng, kết quả trung gian được lưu bằng NumPy. Với khử nhiễu và kết hợp, mã truyền trực tiếp mảng float32 trong bộ nhớ để hạn chế lượng tử hóa và giảm thao tác đọc ghi. Riêng HE, CLAHE và NLM có bước chuyển sang ảnh 8 bit theo cài đặt OpenCV. Nhóm nêu rõ các khác biệt này ở phần phương pháp vì chúng có thể ảnh hưởng đến so sánh chất lượng ảnh và phân loại.

Nhóm kết hợp quy trình xử lý ảnh với kiểm tra trùng lặp, chia dữ liệu theo track và lưu checksum cùng thông tin nguồn để hỗ trợ tái lập thí nghiệm. Giá trị của phần triển khai nằm ở khả năng kiểm soát, giải thích và kiểm chứng toàn bộ luồng dữ liệu. Các thao tác tải, giải nén và gom annotations là các bước hỗ trợ. Đây là đóng góp về triển khai và thiết kế thực nghiệm, không phải đề xuất thuật toán xử lý ảnh mới. Padding, kích thước crop và phép nội suy được trình bày là các quyết định thiết kế. Nhóm chưa có thí nghiệm so sánh riêng để khẳng định chúng là cấu hình tối ưu.

1.6. Ý nghĩa và bố cục báo cáo

Về kiến thức xử lý ảnh, đề tài kết nối phép biến đổi điểm, histogram, lọc Gaussian, mô hình nhiễu và các chỉ số chất lượng trong một quy trình thống nhất. Về thực nghiệm, đề tài làm rõ sự đánh đổi giữa độ sáng, mức nhiễu, tính toàn vẹn của chi tiết và chi phí suy luận. ResNet-18 đóng vai trò công cụ kiểm chứng thông tin được giữ lại sau xử lý, thay vì là đối tượng tối ưu chính của báo cáo.

Báo cáo bắt đầu bằng cách chuẩn bị dữ liệu và tạo ảnh suy giảm. Phần tiếp theo giải thích cơ sở và cách cài đặt các phương pháp xử lý ảnh. Sau đó, nhóm trình bày thiết lập thí nghiệm, kết quả nhận dạng và chất lượng ảnh. Phần thảo luận tập trung vào tương quan, ảnh hưởng của nhiễu và những trường hợp nhận dạng sai. Cuối cùng, nhóm đề xuất quy trình tiền xử lý và nêu các kết luận cùng giới hạn của đề tài.

2. XÂY DỰNG TẬP DỮ LIỆU VÀ MÔ PHỎNG SUY GIẢM

2.1. Giới thiệu bộ dữ liệu GTSRB

German Traffic Sign Recognition Benchmark (GTSRB) là bộ dữ liệu phân loại biển báo giao thông với 43 lớp [4]. Trong dữ liệu dự án, tập huấn luyện chính thức có 39.209 ảnh và tập kiểm thử chính thức có 12.630 ảnh. Các ảnh khác nhau về góc quan sát, kích thước biển báo, nền cảnh và điều kiện chiếu sáng. Đây là những yếu tố khiến việc tăng cường ảnh cần giữ được đặc trưng hình học và màu sắc thay vì chỉ nâng giá trị sáng trung bình.

Một số ảnh huấn luyện được chụp liên tiếp từ cùng một biển báo. Những ảnh thuộc cùng chuỗi quan sát có mức tương đồng cao. Nếu chia train và validation ngẫu nhiên ở cấp ảnh, các khung gần giống nhau có thể xuất hiện ở cả hai tập, làm kết quả validation lạc quan hơn khả năng tổng quát thực tế. Vì vậy, dự án chia dữ liệu theo lớp và *track*, giữ các ảnh cùng track trong một tập.

Bảng 1. Phân chia dữ liệu trong quy trình ResNet-18.

Tập dữ liệu	Số ảnh	Vai trò
Huấn luyện	31.350	Huấn luyện ResNet-18 trên ảnh gốc
Validation	7.829	Chọn checkpoint và đánh giá trong huấn luyện
Cách ly	30	Loại track có ảnh trùng pixel với test khỏi huấn luyện
Official test	12.630	Kiểm thử toàn bộ tập chính thức
Validation chọn xử lý	1.290	30 ảnh/lớp để chọn tham số tăng cường
Test khảo sát	430	10 ảnh/lớp cho notebook và ablation

Nhóm tách riêng 30 ảnh thuộc track có ảnh trùng pixel với tập test. Một track là chuỗi ảnh chụp liên tiếp cùng một biển báo thực tế. Nhóm loại cả track khỏi train và validation, thay vì chỉ bỏ ảnh trùng chính xác rồi giữ lại những khung hình gần giống nó. Tổng số ảnh train, validation và cách ly vẫn là 39.209. Tập test chính thức được giữ nguyên, và nhóm dùng hạt giống 42 khi chia dữ liệu.

Tập 1.290 ảnh được lấy từ validation, còn tập 430 ảnh được lấy từ test. Đây không phải dữ liệu được thêm từ nguồn khác. Nhóm lấy cùng số ảnh mỗi lớp để việc khảo sát cân bằng giữa 43 lớp và giảm thời gian thử nhiều phương pháp. Tuy nhiên, tập 430 ảnh không có cùng phân bố tần suất lớp với toàn bộ 12.630 ảnh test. Vì vậy, nhóm trình bày kết quả của hai phạm vi ở các bảng riêng.

2.2. Tiền xử lý và chuẩn hóa ảnh

2.2.1. Nguồn nhãn và hình thức học

Gói `GTSRB_Final_Training_Images.zip` đã chứa ảnh và các tệp chú thích. Mỗi thư mục lớp có một tệp `GT-<ClassID>.csv`. Cột `ClassId` cung cấp nhãn 0–42, còn các cột ROI cung cấp

tọa độ biển báo. Nhóm chỉ cần tải nhãn test riêng trong `GTSRB_Final_Test_GT.zip` [5]. Do đó, việc không có một gói ground truth train tải riêng không có nghĩa tập train thiếu nhãn.

Nhóm huấn luyện ResNet-18 theo cách học có giám sát. Mỗi mẫu gồm một ảnh và nhãn lớp, mô hình sử dụng cross-entropy để cập nhật trọng số trên toàn mạng. Với ba mô hình tăng cường học sâu, nhóm chỉ nạp trọng số pretrained do tác giả công bố để suy luận. Zero-DCE gốc có cách học không cần ảnh tham chiếu ghép cặp, nhưng đặc điểm đó không làm bài toán phân loại GTSRB của nhóm trở thành học không giám sát. Những phương pháp xử lý ảnh truyền thống không cần huấn luyện.

2.2.2. Cắt vùng quan tâm

Vùng quan tâm (Region of Interest, ROI) được xác định bằng tọa độ chú thích của dữ liệu. Dự án mở rộng vùng này thêm 5% kích thước theo mỗi phía, đồng thời giới hạn khung cắt trong kích thước ảnh. Phần lề nhỏ giúp giữ đường viền biển báo và một lượng ngữ cảnh xung quanh. Nếu cắt sát quá mức, những pixel biên có thể bị loại bỏ trước khi thuật toán tăng cường hoạt động.

Với ROI (x_1, y_1, x_2, y_2) có điểm cuối bao gồm trong vùng, mã nguồn chuyển x_2, y_2 sang mốc cuối không bao gồm bằng cách cộng 1. Sau đó tính độ mở rộng theo chiều rộng và chiều cao, làm tròn ra ngoài bằng phép lấy sàn/lấy trần và chặn tại biên ảnh. Quy ước này tránh bỏ mất hàng hoặc cột pixel cuối cùng khi cắt bằng thư viện ảnh.

2.2.3. Đổi kích thước và miền cường độ

Ảnh ROI được đổi sang RGB, nội suy song tuyến tính về 64×64 rồi lưu dưới dạng chuẩn hóa:

$$X \in [0,1]^{64\times64\times3}, \qquad X = \frac{I_{\text{8-bit}}}{255}. \tag{1}$$

Nội suy song tuyến tính sử dụng tổ hợp có trọng số của các pixel lân cận. Cách làm này phù hợp với yêu cầu đưa các vùng biển báo có kích thước khác nhau về cùng đầu vào, nhưng có thể làm mềm các nét vốn rất nhỏ. Do đó, quá trình phóng lên 224×224 sau tăng cường không tạo lại thông tin đã mất ở bước chuẩn hóa 64×64.

Các thuật toán làm việc với số thực `float32`. Riêng HE và CLAHE chuyển ảnh sang số nguyên 8 bit để dùng các phép xử lý histogram của OpenCV rồi chuyển trở lại số thực. Việc lượng tử hóa ở hai phương pháp này là một phần của cách cài đặt, cần được phân biệt với các phương pháp thực hiện trực tiếp trên giá trị liên tục.

2.3. Mô hình suy giảm thiếu sáng

Mô hình suy giảm được áp dụng theo thứ tự cố định: Gamma làm tối, nhiễu Poisson, nhiễu Gaussian và cuối cùng chặn về $[0, 1]$. Với một pixel của ảnh gốc X, quá trình được mô tả bởi:

$$U = X^{\gamma_d}, \tag{2}$$

$$V = \frac{\mathcal{P}(pU)}{p}, \tag{3}$$

$$Y = \text{clip}\big(V + \varepsilon, 0, 1\big), \quad \varepsilon \sim \mathcal{N}(0, \sigma_n^2). \tag{4}$$

Trong đó $\gamma_d > 1$ điều khiển mức tối, p là hệ số Poisson và σ_n là độ lệch chuẩn nhiễu Gaussian. Phép lũy thừa áp dụng theo từng kênh RGB trong miền ảnh chuẩn hóa. Đây là mô hình suy giảm tổng hợp, không phải mô phỏng đầy đủ quá trình thu nhận ánh sáng của cảm biến RAW.

2.3.1. Vai trò của Gamma làm tối

Với $0 < X < 1$ và $\gamma_d > 1$, ta có $X^{\gamma_d} < X$. Khi tăng γ_d, vùng trung gian bị kéo về cường độ thấp mạnh hơn. Ví dụ, một pixel có cường độ 0,5 trở thành khoảng 0,354, 0,218 và 0,125 khi γ_d lần lượt bằng 1,5, 2,2 và 3,0. Điểm đen 0 và điểm trắng 1 vẫn được giữ ở hai đầu miền.

Điều này giải thích vì sao ảnh tối có histogram dịch về bên trái mà vùng phản xạ rất sáng vẫn có thể còn rõ. Phép Gamma tạo được nhiều mức suy giảm với tham số dễ kiểm soát, đồng thời vẫn giữ quan hệ xác định giữa ảnh gốc và ảnh tối khi chưa thêm nhiễu.

2.3.2. Vai trò của nhiễu Poisson và Gaussian

Trước bước chặn, nhiễu Poisson trong công thức (3) có kỳ vọng U và phương sai U/p. Khi p giảm, mức dao động tăng. Mặc dù phương sai tuyệt đối nhỏ ở vùng tối, độ lệch chuẩn tương đối so với tín hiệu là $1/\sqrt{pU}$, có thể lớn khi U rất nhỏ. Đây là đặc điểm quan trọng khi khảo sát tính nhạy nhiễu của phép tăng sáng.

Nhiễu Gaussian được cộng với độ lệch chuẩn cố định cho mọi pixel. Trong mô hình này, nó đại diện cho một thành phần nhiễu cộng đơn giản. Khi tín hiệu sau Gamma nhỏ, cùng một mức nhiễu Gaussian sẽ gây ảnh hưởng tương đối lớn hơn đến nội dung. Bước chặn cuối cùng bảo đảm ảnh nằm trong miền hợp lệ, nhưng cũng làm phân bố nhiễu gần 0 hoặc 1 không còn hoàn toàn đối xứng.

Bảng 2. Ba mức suy giảm sử dụng trong thí nghiệm.

Mức độ	γ_d	Poisson p	Gaussian σ_n
Nhẹ (mild)	1,5	120	0,005
Vừa (medium)	2,2	60	0,010
Nặng (severe)	3,0	30	0,020

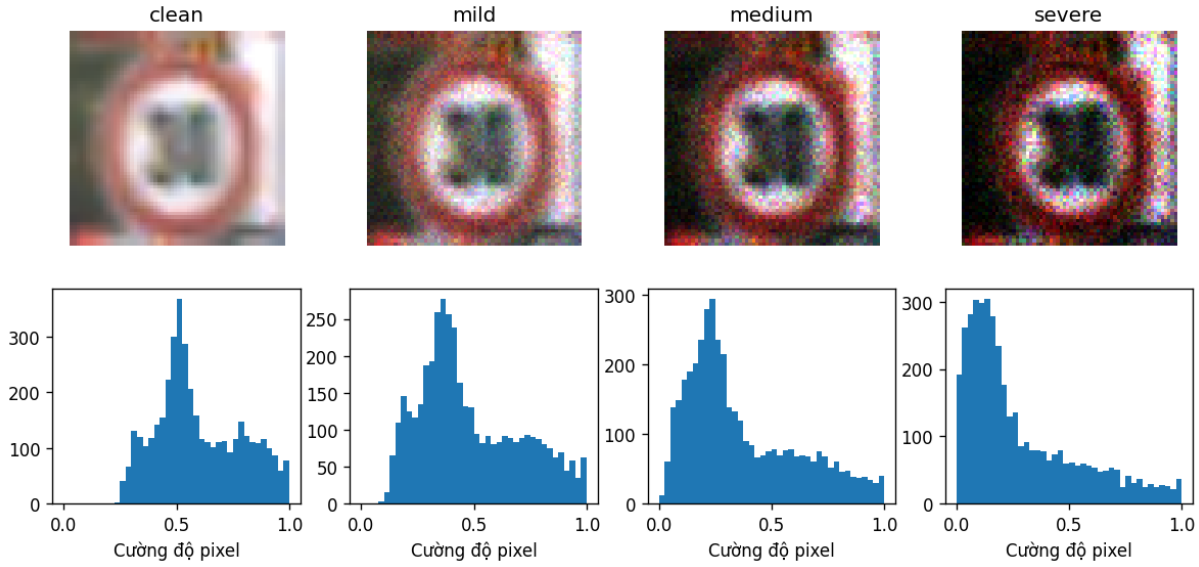
Ba mức trong Bảng 2 thay đổi đồng thời độ tối và hai thành phần nhiễu. Vì vậy, sự chênh lệch giữa mức nhẹ và mức nặng phản ánh tổng tác động của cả ba yếu tố. Muốn xác định riêng ảnh hưởng của nhiễu, cần dùng thí nghiệm ablation giữ nguyên Gamma và lần lượt bật/tắt từng loại nhiễu, được trình bày ở phần thảo luận.

2.3.3. Nhiễu sau nội suy và giới hạn mô hình

Nghiên cứu cắt và resize ảnh gốc về 64×64 trước khi sinh nhiễu. Gọi R là toán tử lấy mẫu lại và S là phép suy giảm, đầu vào đang xét là $S(R(X))$, khác với $R(S(X))$. Với nhiễu cộng độc lập ở độ phân giải nguồn, một pixel nội suy $\sum_j w_j(X_j + \varepsilon_j)$ có phương sai nhiễu $\sigma^2 \sum_j w_j^2$. Các pixel đầu ra dùng chung lân cận còn có thể tương quan. Trong khi đó, thêm Gaussian sau resize dùng phương sai σ_n^2 trực tiếp tại từng pixel crop. Poisson phụ thuộc tín hiệu và Gamma phi tuyến càng khiến hai thứ tự không tương đương.

Thiết kế này giữ kích thước và mức nhiễu đầu vào thống nhất để cô lập ảnh hưởng của tiền xử lý. Nó không tái hiện chuỗi cảm biến RAW, giải khảm màu, xử lý tín hiệu, nội suy và nén của camera. Gaussian đơn giản có thể phù hợp với một thành phần được tạo trực tiếp trong mô hình, nên lợi ích đo được chưa chứng minh ưu thế với nhiễu đã qua xử lý camera. Nhóm chưa thực hiện ablation để thay đổi vị trí sinh nhiễu hoặc độ phân giải. Vì vậy, nhóm chưa định lượng được độ lệch này và không suy ra mức ảnh hưởng chỉ từ lập luận lý thuyết.

2.4. Khảo sát histogram và cấu trúc ảnh



Hình 1. Ảnh tham chiếu và ba mức suy giảm trên cùng một crop validation. Hàng dưới là histogram cường độ xám; trục đứng biểu thị số pixel. Hình trích trực tiếp từ notebook ResNet-18, noise seed 101.

Quan sát Hình 1, vùng nền sáng của biển báo suy giảm rõ khi tăng mức tối. Các nét số trở nên khó phân biệt với nền và nhiễu màu xuất hiện trên cả vùng tương đối đồng nhất. Histogram tập trung ngày càng nhiều tại cường độ thấp. Độ tương phản giữa các cấu trúc hữu ích không thể được suy ra chỉ từ việc histogram còn trải rộng đến gần 1.

Trên riêng ảnh minh họa này, PSNR của mức nhẹ, vừa và nặng lần lượt là 17,2577, 12,0942 và 9,5306 dB. SSIM tương ứng là 0,7120, 0,5494 và 0,3855. Đây là số đo của một ảnh validation được chọn theo quy tắc trong notebook, không phải giá trị trung bình của toàn bộ tập test.

Histogram chỉ biểu diễn tần suất cường độ, không chứa vị trí của pixel. Hai ảnh có histogram gần nhau vẫn có thể khác hoàn toàn về bố trí đường viền hoặc chữ số. Vì vậy, phân tích histogram trong báo cáo luôn đi kèm quan sát ảnh, SSIM và kết quả nhận dạng, tránh kết luận chất lượng chỉ từ sự dịch chuyển phân bố mức xám.

2.5. Bảo đảm điều kiện so sánh công bằng

Hạt giống sinh nhiễu được xác định từ noise seed, mã mẫu và tên điều kiện. Ba noise seed là 101, 202 và 303. Với cùng mã ảnh, cùng mức suy giảm và cùng noise seed, tất cả các phương pháp nhận đúng một ảnh tối. Cách thiết kế này tránh việc một thuật toán vô tình được đánh giá trên nhiễu nhẹ hơn thuật toán khác.

Trong bước đánh giá phép tăng cường, ảnh gốc đóng vai trò tham chiếu để tính chất lượng đầu ra. Thuật toán xử lý không được nhận ảnh gốc hoặc nhãn lớp. Nhóm dùng nhãn để huấn luyện bộ nhận dạng, lựa chọn tham số trên validation và tính các chỉ số đánh giá. Các tập con, cấu hình và checkpoint được cố định trước khi chạy test. Nhờ vậy, nhóm có thể so sánh tác động của các phép xử lý trong cùng điều kiện, dù kết quả vẫn phụ thuộc mô hình và phạm vi dữ liệu đã chọn.

3. CÁC PHƯƠNG PHÁP XỬ LÝ ẢNH

3.1. Nguyên tắc chung của khối tăng cường

Nhiệm vụ của khối tăng cường là biến đổi ảnh thiếu sáng Y thành ảnh $\widehat{X}$ có độ sáng và cấu trúc phù hợp hơn cho quan sát cũng như nhận dạng. Mọi phương pháp đều tuân thủ cùng giao diện: nhận một ảnh RGB 64×64 trong $[0, 1]$, trả lại ảnh cùng kích thước và không truy cập ảnh tham chiếu. Điều này cho phép đánh giá phương pháp truyền thống và học sâu trong cùng quy trình.

Identity giữ nguyên ảnh tối: $E(Y) = Y$. Đây là mốc bắt buộc để xác định lợi ích thực của tăng cường. Một thuật toán có ảnh đầu ra sáng hơn nhưng Accuracy hoặc Macro-F1 thấp hơn Identity được xem là làm giảm hiệu quả nhận dạng trong điều kiện đó.

Clean là ảnh gốc trước suy giảm. Clean không phải một thuật toán phục hồi và không tham gia lựa chọn bộ tăng cường. Vai trò của nó là tạo mức hiệu năng tham chiếu, cho biết khoảng cách còn lại giữa ảnh sau xử lý với điều kiện đầu vào ban đầu.

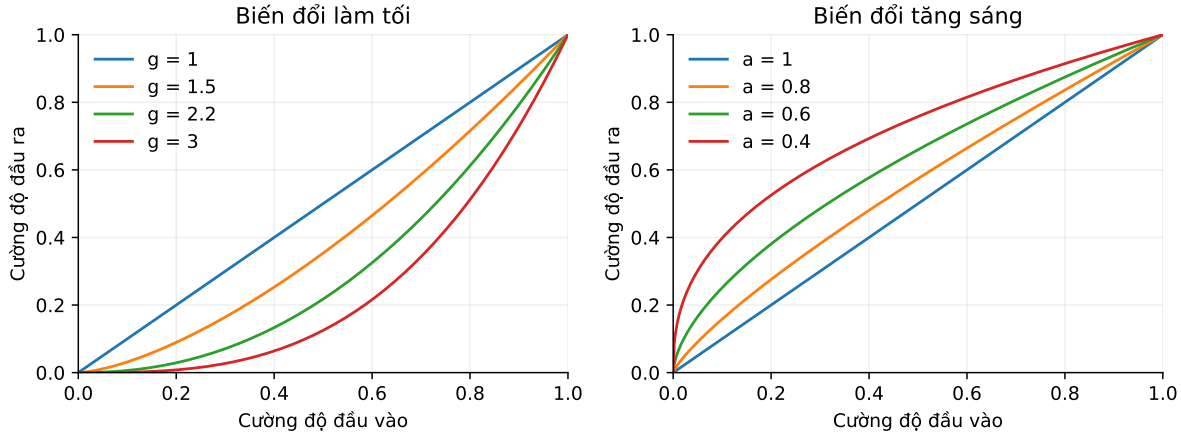
3.2. Hiệu chỉnh Gamma

3.2.1. Cơ sở toán học

Hiệu chỉnh Gamma tăng sáng bằng phép lũy thừa:

$$\widehat{X} = Y^{\alpha}, \qquad 0 < \alpha < 1. \tag{5}$$

Với cường độ nằm giữa 0 và 1, số mũ nhỏ hơn 1 làm đầu ra lớn hơn đầu vào. Khi α giảm, mức nâng sáng mạnh hơn. Ví dụ, pixel 0,1 trở thành 0,158 với $\alpha = 0,8$, 0,251 với $\alpha = 0,6$ và 0,398 với $\alpha = 0,4$.



Hình 2. Đường cong Gamma làm tối và tăng sáng trên miền $[0, 1]$. Đây là đồ thị giải tích của phép biến đổi, không phải kết quả đo trên tập ảnh.

Trong trường hợp lý tưởng chỉ có Gamma làm tối, lựa chọn $\alpha = 1/\gamma_d$ sẽ khôi phục cường độ ban đầu vì $(X^{\gamma_d})^{1/\gamma_d} = X$. Khi có Poisson, Gaussian và bước chặn, phép biến đổi này không còn là nghịch đảo chính xác. Đặc biệt, clipping đã loại bỏ một phần thông tin nên không thể đảo ngược chỉ bằng một hàm điểm.

3.2.2. Ảnh hưởng đến nhiễu và cách cài đặt

Độ nhạy cục bộ của hàm tăng sáng đối với đầu vào được mô tả bởi:

$$\frac{\mathrm{d}Y^{\alpha}}{\mathrm{d}Y} = \alpha Y^{\alpha-1}. \tag{6}$$

Khi Y nhỏ và $\alpha < 1$, hệ số này có thể lớn. Với nhiễu nhỏ, cách xấp xỉ tuyến tính cho thấy nhiễu đầu vào có thể bị khuếch đại trong vùng tối. Đây là cơ sở để giải thích tại sao giảm Gamma quá mạnh làm hình ảnh sáng rõ nhưng cũng khiến nhiễu hạt nổi bật hơn.

Nhóm cài đặt Gamma bằng phép lũy thừa trực tiếp trên mảng RGB số thực, không chuyển ảnh sang 8 bit. Phương pháp này không có bước lọc không gian hoặc khử nhiễu đi kèm. Nhóm thử các giá trị $\alpha \in \{0,4; 0,6; 0,8\}$ trên validation và chọn $\alpha = 0,8$ theo kết quả nhận dạng. Đây là mức nâng sáng nhẹ hơn hai giá trị còn lại trong lưới khảo sát.

Gamma có ưu điểm là dễ cài đặt, chi phí thấp và giữ tính đơn điệu của phép biến đổi cường độ. Tuy nhiên, phương pháp dùng cùng một quy tắc ở mọi vị trí nên chưa thích ứng tốt với

chiếu sáng không đồng đều. Nó cũng không phân biệt được nét thật và nhiễu. Khi áp dụng phi tuyến riêng cho từng kênh RGB, tỷ lệ giữa các thành phần màu có thể thay đổi.

3.3. Cân bằng histogram toàn cục (HE)

3.3.1. Nguyên lý phân phối lại mức xám

Histogram mô tả số pixel xuất hiện tại mỗi mức cường độ. Với ảnh có L mức xám, ký hiệu n_k là số pixel tại mức k và N là tổng số pixel. Histogram chuẩn hóa và hàm phân phối tích lũy được viết:

$$p(k) = \frac{n_k}{N}, \qquad C(k) = \sum_{j=0}^{k} p(j). \tag{7}$$

Một phép ánh xạ cân bằng điển hình đưa mức xám về:

$$T(k) = \text{round}\left((L-1)\frac{C(k) - C_{\text{min}}}{1 - C_{\text{min}}} \right), \tag{8}$$

trong đó C_{min} là giá trị CDF khác 0 đầu tiên. Trường hợp ảnh hằng cần được xử lý riêng để tránh mẫu số bằng 0. HE giúp mở rộng khoảng mức xám đang bị tập trung, song không bảo đảm histogram rời rạc sau biến đổi sẽ phẳng hoàn toàn.

3.3.2. Xử lý trên kênh độ sáng

Nếu cân bằng độc lập R, G và B, ba phép ánh xạ có thể khác nhau và làm biến đổi mạnh màu sắc. Dự án chuyển ảnh từ RGB sang YCrCb, chỉ áp dụng `equalizeHist` trên kênh Y, giữ hai kênh màu rồi chuyển lại RGB. Trước khi đổi không gian màu, ảnh được nhân 255, làm tròn và chuyển sang `uint8`. Sau xử lý, mã chia kết quả cho 255 để trở lại $[0, 1]$.

Việc chỉ tác động lên Y giúp hạn chế sai lệch màu so với cân bằng độc lập từng kênh. Tuy nhiên, quá trình lượng tử hóa và chặn miền khi chuyển đổi vẫn có thể làm thay đổi đầu ra. Do đó, không nên mô tả HE như một phép biến đổi bảo toàn màu tuyệt đối.

HE sử dụng thống kê toàn ảnh, nên vùng nền sáng và vùng biển báo tối cùng đóng góp vào một hàm ánh xạ. Trong ảnh có chiếu sáng không đồng đều, cùng một mức xám thuộc các vùng khác nhau vẫn được xử lý giống nhau. Đây là lý do tăng tương phản toàn cục có thể làm một số vùng dễ quan sát hơn nhưng đồng thời bão hòa các vùng vốn đã sáng [6].

HE không cần chọn một hệ số tăng sáng riêng và có cách triển khai đơn giản. Tuy nhiên, phương pháp có thể làm nhiễu rõ hơn, thay đổi phân bố sáng quá mạnh hoặc làm mất thông tin ở vùng bị bão hòa. Với ảnh crop nhỏ, histogram còn phụ thuộc vào tỷ lệ giữa nền và phần biển báo trong ảnh.

3.4. Cân bằng histogram thích nghi có giới hạn tương phản (CLAHE)

3.4.1. Từ xử lý toàn cục đến xử lý cục bộ

CLAHE [7] chia ảnh thành một lưới ô và xây dựng phép ánh xạ histogram cho từng ô. Cách tiếp cận cục bộ giúp xử lý các vùng có điều kiện chiếu sáng khác nhau. Tuy nhiên, nếu

cân bằng cục bộ không giới hạn, một vùng gần như đồng nhất có thể bị kéo giãn tương phản mạnh và làm nhiễu nổi rõ. CLAHE giải quyết điều này bằng cách giới hạn chiều cao histogram trước khi xây dựng CDF.

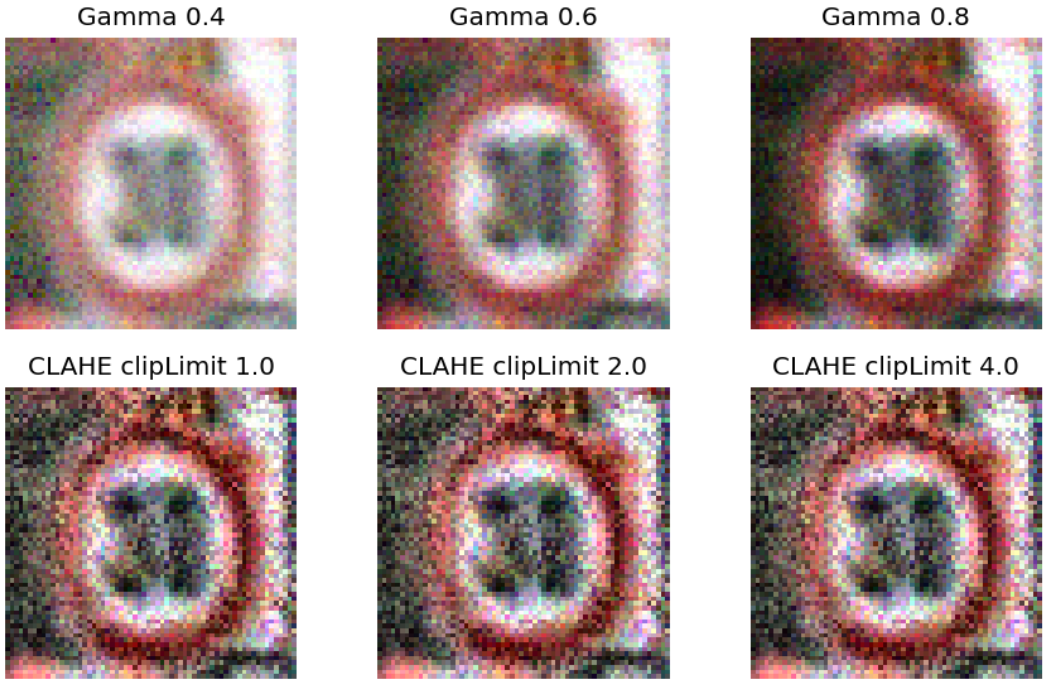
Trước hết, CLAHE tính histogram cho mỗi ô. Phương pháp cắt các cột histogram vượt ngưỡng rồi phân phối lại phần dư. Sau đó, thuật toán xây dựng ánh xạ mức sáng và nội suy giữa các ô. Bước nội suy giúp giảm ranh giới khối vuông sau xử lý. Trong mã của nhóm, CLAHE được áp dụng trên kênh Y, tương tự cách thực hiện HE.

3.4.2. Ý nghĩa tham số và ảnh hưởng kích thước ảnh

Nhóm cần chọn hai tham số chính là `clipLimit` và `tileGridSize`. Tham số `clipLimit` điều khiển mức giới hạn histogram theo quy ước OpenCV, không phải ngưỡng độ sáng để chặn pixel. Tham số `tileGridSize` cho biết số ô theo hai chiều. Với ảnh 64×64, lưới 8×8 tạo các ô khoảng 8×8 pixel, còn lưới 4×4 tạo các ô khoảng 16×16 pixel.

Ở ô quá nhỏ, số mẫu dùng để ước lượng histogram ít, dễ khiến thống kê bị ảnh hưởng bởi nhiễu và từng nét của biển báo. Lưới thưa hơn có thể ổn định hơn nhưng mức thích ứng không gian cũng giảm. Do vậy, cấu hình tốt trên ảnh độ phân giải cao chưa chắc tốt khi chuyển sang crop 64×64.

Lưới validation khảo sát ba giá trị clip limit $\{1, 2, 4\}$ kết hợp hai lưới $\{4\times4, 8\times8\}$. Notebook chọn clip limit bằng 1 và lưới 4×4. Đây là kết quả lựa chọn bằng khả năng nhận dạng trên validation, không phải tham số được chọn bằng cách nhìn ảnh test.



Hình 3. Ảnh hưởng của Gamma và clip limit trên cùng ảnh tối mức vừa. Hàng dưới giữ lưới CLAHE 8×8 để minh họa riêng tham số clip limit; đây không phải cấu hình CLAHE được chọn cuối cùng.

Với ô nhỏ, các giá trị clip limit danh nghĩa khác nhau có thể tạo cùng ngưỡng hiệu dụng. Với ô 8×8 có 64 pixel và 256 bin, việc quy đổi ngưỡng cắt về số nguyên trong OpenCV có thể đưa các giá trị này về cùng ngưỡng hiệu dụng. Vì vậy, đổi tham số danh nghĩa chưa chắc tạo ra đầu ra khác trên ảnh nhỏ. Nhận định này phù hợp với cài đặt thư viện và quan sát thí nghiệm, không nên suy rộng thành tính chất chung cho mọi kích thước ảnh.

CLAHE có thể điều chỉnh tương phản theo từng vùng và kiểm soát sự khuếch đại histogram tốt hơn HE. Chi phí của phương pháp cũng thấp hơn nhiều so với các mô hình phục hồi học sâu. Dù vậy, ảnh đầu ra vẫn có thể xuất hiện nhiễu rõ hơn. Chất lượng còn phụ thuộc đồng thời vào clip limit, lưới chia ô và độ phân giải của ảnh.

3.5. Retinex đa tỉ lệ (Multi-Scale Retinex)

Cơ sở MSR dựa trên công trình của Jobson, Rahman và Woodell [8]. Biến thể dưới đây được giản lược theo mã nguồn của dự án.

3.5.1. Mô hình phản xạ và chiếu sáng

Retinex xem ảnh quan sát là tích của thành phần phản xạ R và chiếu sáng L:

$$I(x, y) = R(x, y)L(x, y). \tag{9}$$

Nếu có thể ước lượng thành phần chiếu sáng biến đổi chậm, ta có thể giảm ảnh hưởng của nó và làm rõ cấu trúc phản xạ. Trong miền log, tích trở thành tổng. Một dạng Single-Scale Retinex sử dụng ảnh làm mờ Gaussian để xấp xỉ thành phần chiếu sáng:

$$r_s = \log(Y + \epsilon) - \log(G_{\sigma_s} * Y + \epsilon). \tag{10}$$

Với nhiều độ lệch chuẩn Gaussian, kết quả trung bình là:

$$r = \frac{1}{S} \sum_{s=1}^{S} r_s, \qquad \epsilon = 10^{-6}. \tag{11}$$

Các độ lệch chuẩn nhỏ nhấn mạnh biến đổi cục bộ, trong khi độ lệch chuẩn lớn thể hiện cấu trúc chiếu sáng rộng hơn. Kết hợp nhiều tỉ lệ giúp giảm phụ thuộc vào một mức làm mờ duy nhất.

3.5.2. Chuẩn hóa đầu ra trong dự án

Giá trị r trong miền log chưa nằm trong $[0, 1]$. Mã nguồn lấy percentile 1% và 99% trên toàn mảng kết quả, ký hiệu là q_1, q_{99}, rồi chuẩn hóa:

$$\widehat{X} = \text{clip}\left(\frac{r - q_1}{q_{99} - q_1}, 0, 1 \right). \tag{12}$$

Nếu $q_{99} - q_1 < 10^{-6}$, hàm trả lại ảnh đầu vào để tránh chia cho khoảng quá nhỏ. Hai cấu hình tỉ lệ được thử là $[3, 10, 20]$ và $[5, 15, 30]$. Notebook chọn cấu hình thứ hai.

Đây là MSR giản lược, không có bước phục hồi màu riêng của MSRCR và không có khối khử nhiễu chuyên biệt. Việc chuẩn hóa percentile làm kết quả phụ thuộc vào phân bố của chính ảnh đang xử lý. Một số pixel bị kéo đến 0 hoặc 1. Quan hệ màu và độ sáng tuyệt đối có thể thay đổi đáng kể so với ảnh gốc.

3.5.3. Vì sao Retinex nhạy với nhiễu?

Vùng tối có giá trị Y nhỏ, trong khi đạo hàm của hàm log là $1/(Y + \epsilon)$. Các dao động nhỏ của nhiễu vì vậy có thể tạo chênh lệch lớn trong miền log. Phép trừ ảnh làm mờ còn nhấn mạnh thành phần biến thiên nhanh, bao gồm cả biên thật lẫn nhiễu. Sau bước kéo giãn percentile, những dao động này có thể tiếp tục được khuếch đại.

Khi ảnh chỉ bị Gamma làm tối, MSR có thể làm rõ cấu trúc tốt. Khi thêm nhiễu, cùng cấu hình có thể tạo màu giả và hạt rõ trên nền. Thí nghiệm ablation ở phần sau kiểm tra trực tiếp giả thuyết này bằng cách giữ nguyên $\gamma_d = 2, 2$ và thay đổi thành phần nhiễu.

3.6. Các phương pháp tăng cường dựa trên học sâu

3.6.1. Zero-DCE

Zero-DCE ước lượng các đường cong điều chỉnh cường độ phụ thuộc ảnh. Một dạng đường cong được mô tả trong nghiên cứu gốc là $I' = I + AI(1 - I)$, với tham số A được mạng dự đoán theo vị trí và được áp dụng lặp. Phương pháp học cách điều chỉnh ảnh bằng các ràng buộc không cần ảnh tham chiếu ghép cặp [1].

Nhóm sử dụng Zero-DCE ở chế độ suy luận với checkpoint pretrained `Epoch99.pth`, không cập nhật lại trọng số trên GTSRB. Phần mã tích hợp mô hình lấy ảnh tăng cường từ đầu ra và đưa ảnh về cùng kích thước, miền giá trị với đầu vào. Vì mô hình tác động lên ảnh vốn có nhiễu, nhóm vẫn cần kiểm tra nhiễu hạt và độ rõ của nét số, thay vì chỉ quan sát ảnh có sáng lên hay không.

3.6.2. Retinexformer

Retinexformer kết hợp biểu diễn chiếu sáng với Transformer để phục hồi ảnh thiếu sáng. Khung một giai đoạn của phương pháp sử dụng thông tin chiếu sáng nhằm hỗ trợ xử lý các suy giảm và quan hệ giữa các vùng ảnh [2]. Báo cáo sử dụng nó như một đối chứng học sâu cho MSR, không đồng nhất hai phương pháp chỉ vì cùng dựa trên ý tưởng Retinex.

Nhóm dùng checkpoint pretrained trên LOL-v1 do tác giả công bố. Phần mã tích hợp nạp kiến trúc và trọng số, thực hiện suy luận rồi lấy phần đầu ra tương ứng với kích thước ảnh ban đầu. Nếu kích thước ảnh chưa phù hợp, mã cần đệm ảnh đến bội số của 4. Ảnh crop 64×64 của nhóm đã đáp ứng điều kiện này.

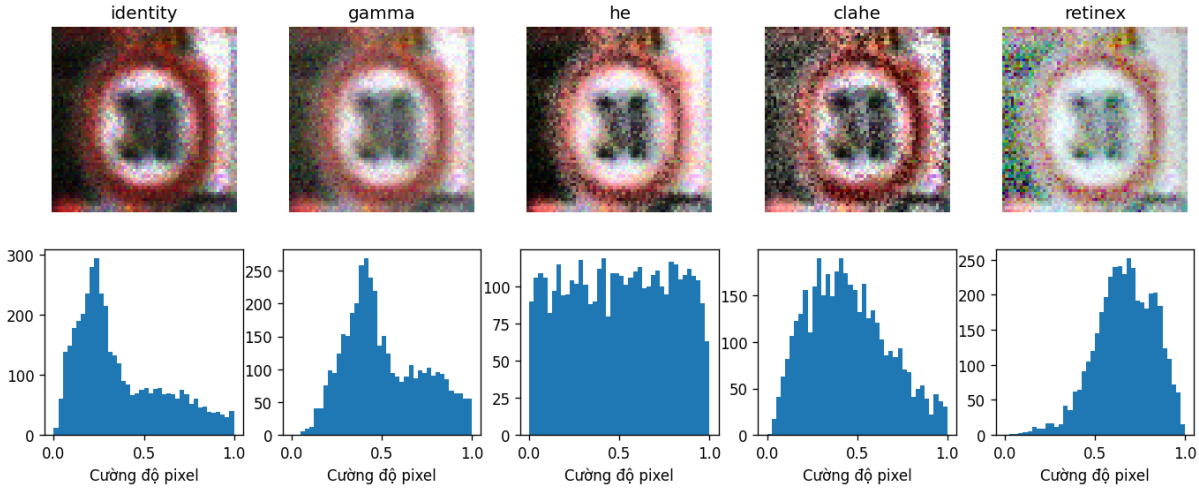
3.6.3. Tăng cường dựa trên diffusion trong miền wavelet

Phương pháp diffusion được chọn là Wavelet-based Diffusion LLIE. Nghiên cứu gốc kết hợp mô hình diffusion có điều kiện với biểu diễn wavelet và cơ chế phục hồi thành phần tần số cao [3]. Cách tiếp cận này hướng tới cân bằng thông tin chiếu sáng và chi tiết của ảnh.

Trong lần chạy của nhóm, mô hình diffusion dùng trọng số trung bình trượt (EMA) và 10 bước lấy mẫu. Hạt giống suy luận được xác định theo mã ảnh để có thể chạy lại. Khi cần, mã đệm ảnh bằng cách lặp biên đến bội số của 32. Sau suy luận, mã lấy trường `pred_x`, cắt về kích thước đầu vào và chặn giá trị về $[0, 1]$. Việc thực hiện nhiều bước suy luận khiến phương pháp có chi phí cao hơn đáng kể so với Gamma hoặc CLAHE.

Nhóm giữ nguyên trọng số pretrained của cả ba mô hình học sâu. Các mô hình này đã được học trên dữ liệu khác với biển báo GTSRB và khác dạng nhiễu tổng hợp trong thí nghiệm. Vì vậy, nhóm không mặc định mô hình phức tạp hơn sẽ cho kết quả tốt hơn phương pháp truyền thống. Phần thực nghiệm sẽ kiểm tra điều này bằng các chỉ số chất lượng ảnh và nhận dạng.

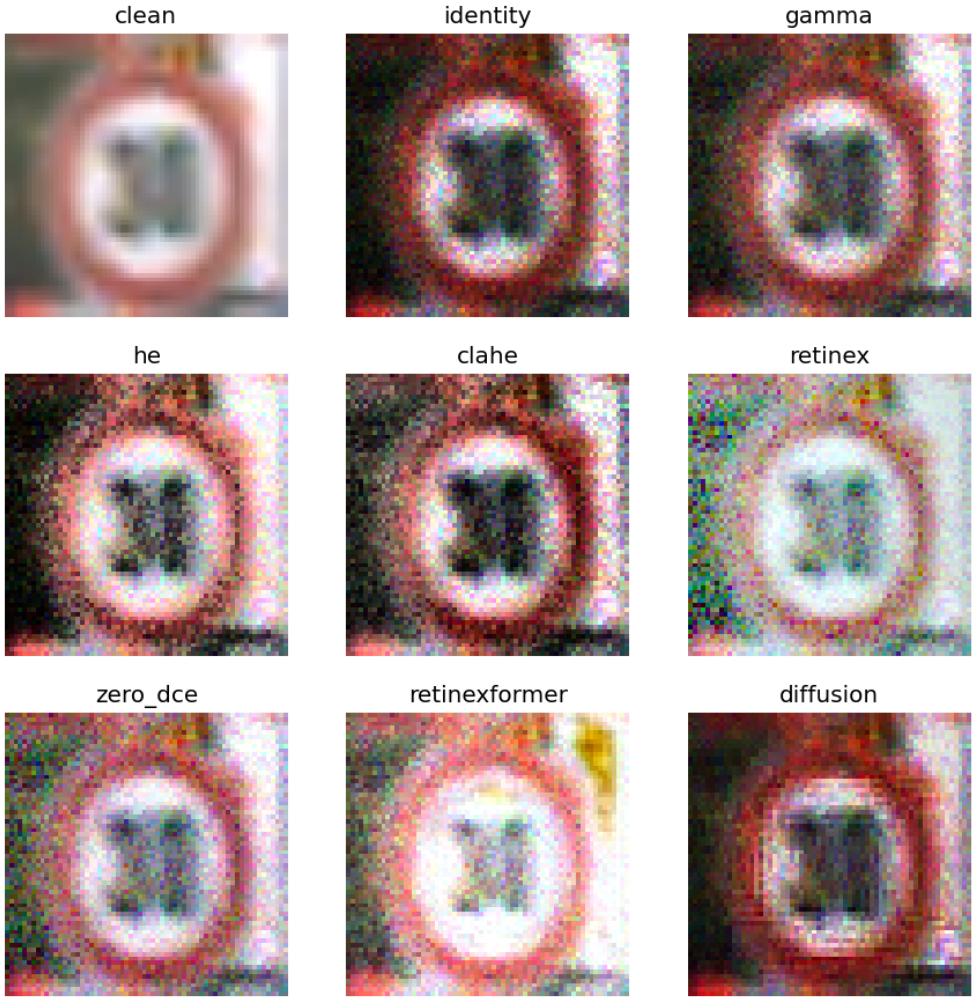
3.7. Minh họa trước và sau xử lý



Hình 4. Ảnh và histogram sau các phép xử lý truyền thống với tham số mặc định: Gamma 0,6; CLAHE clip limit 2, lưới 8×8; MSR $[3, 10, 20]$. Hình dùng để giải thích cơ chế, không phải kết quả của bộ tham số đã chọn.

Hình 4 cho thấy cùng một ảnh tối có thể được biến đổi thành nhiều phân bố sáng khác nhau. Gamma nâng phần lớn pixel tối. HE phân phối lại mức sáng trên toàn ảnh. CLAHE phụ thuộc từng vùng. MSR có thể tạo thay đổi mạnh về màu và độ tương phản. Việc histogram trải rộng sau xử lý chỉ chứng minh phép ánh xạ đã thay đổi phân bố, chưa chứng minh nội dung có ích đã được phục hồi.

Trong Hình 5, ảnh Zero-DCE và Retinexformer sáng lên rõ, nhưng nhiễu và sự biến đổi màu cũng cần được quan sát. MSR làm nền thay đổi mạnh, còn diffusion không nhất thiết tạo ảnh sáng nhất. Những nhận xét này chỉ có giá trị minh họa trên một mẫu. Việc xếp hạng thuật toán phải dựa trên số liệu tổng hợp và hiệu quả nhận dạng ở các phần tiếp theo.



Hình 5. Minh họa bảy phương pháp trên một crop: Gamma 0,8; CLAHE clip 2, lưới 4×4; MSR $[5, 15, 30]$. Clean là tham chiếu, Identity là ảnh tối. Hình giải thích biến đổi ảnh, không phải bằng chứng phân loại của bộ tham số cuối.

3.8. Đánh giá chất lượng bằng PSNR và SSIM

3.8.1. Sai số bình phương trung bình và PSNR

Với X là ảnh gốc, $\widehat{X}$ là ảnh xử lý và $N = HWC$ là số phần tử RGB:

$$\text{MSE} = \frac{1}{N}\sum_{i=1}^{N}(X_i - \widehat{X}_i)^2, \qquad \text{PSNR} = 10\log_{10}\frac{1}{\text{MSE}}. \tag{13}$$

Công thức dùng biên độ cực đại bằng 1 vì ảnh đã được chuẩn hóa. PSNR cao tương ứng sai số pixel nhỏ. MSE được tính với độ chính xác số thực 64 bit trong mã nguồn để giảm sai số cộng dồn. Nếu ảnh trùng hoàn toàn với tham chiếu, MSE bằng 0 và PSNR là vô hạn, không thay bằng một giá trị hữu hạn tùy ý.

PSNR được tính từng ảnh rồi lấy trung bình. Trung bình của log sai số khác log của sai số trung bình, nên không được gộp toàn bộ pixel của tập dữ liệu thành một MSE duy nhất rồi

gọi đó là PSNR trung bình. Chỉ số cũng nhạy với thay đổi độ sáng toàn cục, dù ảnh sau thay đổi vẫn có thể giữ được các nét phân lớp.

3.8.2. Độ tương đồng cấu trúc SSIM

SSIM xem xét thống kê cục bộ của hai ảnh, gồm độ sáng, độ tương phản và mức tương đồng cấu trúc [9]. Dạng thường dùng là:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \tag{14}$$

Trong đó μ là trung bình cục bộ, σ^2 là phương sai, σ_{xy} là hiệp phương sai và các hằng số C_1, C_2 ổn định phép chia. Dự án dùng cửa sổ 7×7, miền giá trị 1, xử lý ba kênh màu, $K_1 = 0,01$, $K_2 = 0,03$, không dùng trọng số Gaussian và dùng hiệp phương sai mẫu.

SSIM bổ sung thông tin mà PSNR không thể hiện đầy đủ, song vẫn không thay thế metric nhận dạng. Nét chữ số bị sai ở một vùng nhỏ có thể không làm giảm mạnh điểm trung bình toàn ảnh. Khi ảnh đêm thực không có ảnh tham chiếu đồng vị trí, cũng không thể áp dụng trực tiếp PSNR/SSIM theo giao thức hiện tại.

3.9. Cơ chế học sâu và liên hệ với sai số nhận dạng

3.9.1. Đường cong lặp của Zero-DCE

Thay vì ước lượng trực tiếp ảnh sáng, Zero-DCE dự đoán bản đồ hệ số A_n và áp dụng đường cong nhiều lần [1]:

$$I_{n+1} = I_n + A_n \odot I_n \odot (1 - I_n), \qquad A_n \in [-1, 1]. \tag{15}$$

Với một hệ số cố định a, đạo hàm theo cường độ là $1 + a(1 - 2I)$ và không âm trên miền hợp lệ. Điều này mô tả tính đơn điệu của đường cong tại một vị trí, không bảo đảm thứ tự giữa hai pixel có hệ số khác nhau. Với $a > 0$, mức tăng bằng $aI(1 - I)$, đạt lớn nhất gần $I = 0,5$ và bằng 0 tại hai đầu. Pixel bị clipping hoàn toàn về 0 vì thế không thể được khôi phục chỉ bằng phép biến đổi này.

Hàm mục tiêu gốc kết hợp tính nhất quán không gian, kiểm soát phơi sáng, tính ổn định màu và độ trơn của bản đồ hệ số [1]. Các ràng buộc không yêu cầu nhãn lớp biển báo. Chúng cũng không tối ưu trực tiếp việc phân biệt nét số hoặc hình mũi tên. Khi bản đồ đường cong nâng cả tín hiệu lẫn nhiễu, ảnh nhìn sáng hơn nhưng đặc trưng phân lớp vẫn có thể bị thay đổi. Đây là giả thuyết cơ chế, cần đối chiếu từng mẫu thay vì coi là nguyên nhân đã được xác nhận.

3.9.2. Thông tin chiếu sáng trong Retinexformer

Retinexformer dùng khung một giai đoạn gồm ước lượng chiếu sáng, nâng sáng và khôi phục suy giảm. Đặc trưng chiếu sáng hướng dẫn tương tác giữa các vùng trong Transformer [2]. Có thể mô tả chức năng bằng sơ đồ:

$$(\widehat{L}, F_L) = g(Y), \qquad Y_{\text{up}} = Y \odot \widehat{L}, \qquad \widehat{X} = h(Y_{\text{up}}, F_L). \tag{16}$$

Trong sơ đồ này $\widehat{L}$ là bản đồ nâng sáng và F_L là đặc trưng chiếu sáng. Biểu thức mô tả vai trò các khối, không thay thế toàn bộ công thức attention của bài báo. Khác với MSR giản lược, bộ phục hồi có tham số học được và tận dụng quan hệ không cục bộ. Tuy nhiên, trọng số LOL-v1 không được tối ưu riêng cho crop biển báo có nét rất nhỏ và nhiễu Poisson–Gaussian đang xét. Hiệu năng thấp hơn CLAHE trên GTSRB vì thế không phủ định kết quả của phương pháp trên các benchmark gốc.

3.9.3. Wavelet và diffusion có điều kiện

Biến đổi wavelet tách ảnh thành thành phần tần số thấp LL và các thành phần chi tiết LH, HL, HH. Phương pháp Wavelet-based Diffusion LLIE sử dụng diffusion có điều kiện trong miền wavelet kết hợp khôi phục thành phần tần số cao [3]. Công thức nhiễu thuận điển hình của diffusion là [10]:

$$z_t = \sqrt{\overline{\alpha}_t}\, z_0 + \sqrt{1 - \overline{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I). \tag{17}$$

Đặt $\beta_s \in (0, 1)$ là phương sai nhiễu ở bước s, $\alpha_s = 1 - \beta_s$ và $\overline{\alpha}_t = \prod_{s=1}^{t} \alpha_s$ là tích lũy đến bước t, không phải hệ số riêng của một bước. Ở đây z_0 là biểu diễn đích trong miền mà diffusion làm việc, không phải công thức tạo thiếu sáng của dự án. Khi suy luận, mô hình dùng điều kiện từ ảnh tối và nhiều bước khử nhiễu để ước lượng biểu diễn phục hồi trước khi tái tạo ảnh. Phân tách tần số giúp giải thích vì sao phương pháp có thể xử lý đồng thời chiếu sáng và chi tiết. Tuy nhiên, điều đó không bảo đảm rằng mọi nét số nhỏ đều được giữ đúng.

Nhóm dùng cấu hình suy luận gồm 10 bước lấy mẫu, trọng số EMA và bộ lấy mẫu do tác giả cung cấp. Nhóm không huấn luyện một mô hình diffusion mới trên GTSRB và không dùng nhãn biển báo để cập nhật bộ tăng cường. Thời gian đo trong báo cáo chỉ dành cho khối xử lý ảnh crop. Nhóm không quy đổi trực tiếp số đo này thành tốc độ khung hình của một hệ thống camera.

3.9.4. Mục tiêu phục hồi và mục tiêu phân loại khác nhau

Giả sử đặc trưng của bộ phân loại là f và phép tăng cường là E. Giảm $\|E(Y) - X\|^2$ không kéo theo giảm $\|f(E(Y)) - f(X)\|$. Mạng có thể nhạy với sai khác tại một vùng nhỏ chứa chữ số hoặc biểu tượng. Để kiểm tra tác động này, cần giữ cố định f, so sánh dự đoán trên cùng ảnh và thống kê cả trường hợp được sửa đúng lẫn bị làm sai. Phân tích ghép cặp ở phần sau thực hiện đúng nguyên tắc đó.

3.10. Khử nhiễu và thứ tự xử lý

Nhóm khảo sát khử nhiễu để xem các bộ lọc không gian ảnh hưởng như thế nào đến nhận dạng ảnh thiếu sáng. Nhóm cũng kiểm tra việc đặt bộ lọc trước hoặc sau phép tăng sáng. Các cấu hình được chọn trên validation, còn kết quả trên tập con và toàn bộ test được trình bày ở phần thực nghiệm.

3.10.1. Câu hỏi và phạm vi khảo sát

Nhóm đặt ra ba câu hỏi cho khảo sát này. Trước hết, nếu chỉ khử nhiễu mà không tăng sáng, mô hình có nhận dạng tốt hơn không? Tiếp theo, các bộ lọc có cơ chế giữ biên hoặc so sánh mảnh ảnh có giữ được chi tiết phân biệt lớp tốt hơn Gaussian không? Cuối cùng, nhóm muốn biết nên khử nhiễu trước hay sau tăng sáng trong các cấu hình đã chọn. Phạm vi vẫn là ảnh biển báo đã cắt ROI với suy giảm tổng hợp. Nhóm chưa dùng khảo sát này để kết luận cho ảnh toàn cảnh hoặc hệ thống cảnh báo trong xe.

3.10.2. Cơ chế các bộ lọc và giả thuyết

Với ảnh nhiễu I, bộ lọc Gaussian cho ảnh đầu ra

$$D_G(I)(p) = \sum_{q \in \mathcal{N}(p)} G_\sigma(p-q) I(q), \qquad \sum_{q \in \mathcal{N}(p)} G_\sigma(p-q) = 1. \tag{18}$$

Trung bình có trọng số làm giảm dao động cục bộ nhưng có thể làm mờ chữ số và đường viền nhỏ trên crop 64×64. Bilateral thêm trọng số theo khác biệt màu [11]:

$$D_B(I)(p) = \frac{1}{W_p} \sum_{q \in \mathcal{N}(p)} e^{-\|p-q\|^2/(2\sigma_s^2)} e^{-\|I(p)-I(q)\|^2/(2\sigma_c^2)} I(q), \tag{19}$$

Trong công thức bilateral, W_p là hệ số đưa tổng trọng số về 1. Bộ lọc hạn chế trộn pixel qua các biên có khác biệt màu lớn, nhưng nhiễu mạnh có thể làm sai độ tương tự mà bộ lọc ước lượng. Non-local Means (NLM) [12] dùng dạng $D_N(I)(p) = \sum_q w(p,q) I(q)$. Các trọng số của NLM dựa trên độ giống nhau giữa các mảnh ảnh, thay vì chỉ dựa vào khoảng cách pixel. Khi tăng độ mạnh lọc, phương pháp có thể giảm nhiễu nhiều hơn nhưng cũng xóa chi tiết. Nhóm dùng các hàm OpenCV cho phần triển khai và không huấn luyện thêm mô hình khử nhiễu [13, 14].

Gaussian và bilateral nhận ảnh RGB float32 trong $[0, 1]$. Riêng hàm NLM màu của OpenCV yêu cầu ảnh uint8. Vì vậy, mã làm tròn về 8 bit, đổi RGB sang BGR, gọi hàm lọc rồi chuyển kết quả về RGB float32. Hàm còn xử lý màu nội bộ dựa trên không gian Lab. Khi diễn giải PSNR và SSIM, nhóm cần tính đến các bước chuyển đổi này, vì thay đổi đầu ra không chỉ do nguyên lý NLM.

Gọi E là phép tăng sáng và D là phép khử nhiễu. Nhóm so sánh hai chuỗi $E(D(I))$ và $D(E(I))$. Hai chuỗi thường không cho kết quả giống nhau vì phép tăng sáng là phi tuyến và một số bộ lọc phụ thuộc cường độ. Khử nhiễu trước có thể giảm phần nhiễu bị nâng lên khi tăng sáng. Ngược lại, tăng sáng trước có thể làm cấu trúc rõ hơn nhưng cũng khuếch đại sai lệch. Nhóm kiểm tra cả hai thay vì giả định một thứ tự tốt hơn từ đầu.

3.10.3. Thiết kế chọn tham số công bằng

Trong khảo sát này, nhóm giữ nguyên cách chia tập theo track, ảnh crop, ba mức suy giảm, noise seed 101/202/303 và ba checkpoint seed 11/22/33. Nhóm không tinh chỉnh CNN bằng ảnh tối hay ảnh đã lọc. Việc chọn tham số vẫn dùng đúng 1.290 ảnh validation của khảo sát tăng sáng. Nhãn test không được dùng để chọn phương pháp. Các cấu hình được lưu trong `configs/processing_extension.json`.

Bảng 3. Lưới tham số khử nhiễu, lựa chọn bằng validation.

Thành phần	Cấu hình và vai trò
Gaussian	$(k, \sigma) = (3, 0{,}5)$ hoặc $(5, 0{,}8)$; đối chứng làm trơn cục bộ
Bilateral	$d = 5$; $(\sigma_c, \sigma_s) = (0{,}05, 1{,}5)$ hoặc $(0{,}10, 3)$, màu trên thang $[0, 1]$
NLM màu	$h = h_{color} = 3$ hoặc 7 trên thang 8 bit; cửa sổ mẫu 3, tìm kiếm 7
Tăng sáng kết hợp	Gamma và CLAHE, giữ tham số đã chọn từ validation đối chứng
Thứ tự	Cả khử nhiễu $\rightarrow$ tăng sáng và tăng sáng $\rightarrow$ khử nhiễu

Đầu tiên, nhóm chọn một độ mạnh cho mỗi bộ lọc dựa trên Macro-F1 khi khử nhiễu riêng lẻ. Nhóm giữ tham số đó cho cả hai thứ tự kết hợp với từng phép tăng sáng. Có 6 cấu hình riêng lẻ và 12 chuỗi cần đánh giá thêm trên validation. Sau lựa chọn độ mạnh, tập ứng viên test còn 3 bộ lọc riêng lẻ và 12 chuỗi. Cách làm này giúp phân biệt ảnh hưởng của thứ tự với độ mạnh lọc. Tuy nhiên, tham số tốt khi lọc riêng chưa chắc tốt khi kết hợp, vì tăng sáng có thể đổi nhiễu và độ tương tự giữa các vùng. Do đó, kết quả chỉ so sánh các chuỗi với tham số đã cố định, chưa phải kết quả tối ưu toàn cục. Nếu muốn tìm chuỗi tối ưu hơn, nhóm cần chọn đồng thời bộ lọc, bộ tăng cường và thứ tự trên validation, rồi kiểm tra bằng test độc lập. Nhóm giữ Identity, Gamma, CLAHE và quy trình đối chứng đã chọn để so sánh trên cùng ảnh. Nếu có cấu hình trùng nhau, nhóm chỉ tính một lần.

3.10.4. Khóa subset, full-test và cách phân tích

Nhóm dùng tập con 430 ảnh để đánh giá toàn bộ họ phương pháp sau khi chọn độ mạnh. Danh sách phương pháp chạy toàn bộ test được xác định *trước khi đọc kết quả tập con*. Trên validation, nhóm chọn cặp bộ lọc và tăng sáng có điểm trung bình hai thứ tự cao nhất, rồi giữ cả hai thứ tự và hai phép riêng lẻ tương ứng. Nhóm bổ sung bộ lọc riêng lẻ tốt nhất, ứng viên tổng thể tốt nhất và các đối chứng. Vì vậy, phần đánh giá toàn bộ test chỉ có tập ứng viên đã sàng lọc, không bao gồm mọi tổ hợp. Hai giao thức được cố định cùng lúc và ghi mã ảnh, tham số, hash mã nguồn cùng hash checkpoint.

Nhóm đánh giá Accuracy, Macro-F1, Weighted-F1, PSNR, SSIM và thời gian xử lý. Với các kết quả nhận dạng, nhóm lấy trung bình noise seed trong từng checkpoint rồi tính trung bình và độ lệch chuẩn qua ba checkpoint. Nhóm còn phân tích F1 từng lớp, ma trận nhầm lẫn và số ảnh đổi từ sai sang đúng hoặc từ đúng sang sai so với Identity. Chênh lệch thứ tự được tính trên cùng ảnh. Thời gian đo chỉ dành cho khối xử lý sau bước chạy làm nóng, chưa phải độ trễ của cả hệ thống camera. Nếu chất lượng ảnh tăng nhưng Macro-F1 giảm, nhóm cần xem lại nét số, đường viền và màu để hiểu kết quả.

Các thuật toán không nhận nhãn hoặc ảnh sáng tham chiếu. Bộ đánh giá mới dùng những thông tin đó để tính điểm. Mọi phương pháp nhận cùng ảnh suy giảm và được kiểm tra bằng cùng bộ phân loại. Khi phân tích thứ tự, nhóm sử dụng các cặp có cùng tham số để tránh nhầm với thay đổi độ mạnh lọc. Các chuỗi mới được đo trong cùng lần chạy và cùng phạm vi tác vụ. Thời gian của đối chứng dùng lại từ lần chạy khác chỉ được trình bày để tham khảo.

4. THỬ NGHIỆM VÀ SO SÁNH KẾT QUẢ

4.1. Thiết lập mô hình kiểm chứng ResNet-18

ResNet-18 là kiến trúc mạng tích chập có kết nối phần dư, giúp học phép biến đổi thông qua tổng giữa nhánh đặc trưng và nhánh đi tắt [15]. Trong bài tập lớn, lớp phân loại cuối được thay bằng ánh xạ từ 512 đặc trưng sang 43 lớp biển báo. Mô hình khởi tạo từ trọng số ImageNet và được tinh chỉnh trên tập ảnh gốc GTSRB.

Đầu vào ở khối xử lý ảnh có dạng $B \times 3 \times 64 \times 64$ khi ghép batch. Trong hàm forward của ResNet-18, toàn bộ crop được nội suy song tuyến tính lên 224×224, có chống răng cưa, rồi chuẩn hóa theo trung bình $[0,485; 0,456; 0,406]$ và độ lệch chuẩn $[0,229; 0,224; 0,225]$. Chuẩn hóa được áp dụng đúng một lần. Đầu ra là ma trận $B \times 43$.

Bảng 4. Cấu hình huấn luyện ResNet-18 dùng để kiểm chứng.

Thành phần	Thiết lập
Kiến trúc	ResNet-18, lớp cuối 43 đầu ra
Khởi tạo	ImageNet, tinh chỉnh toàn mạng
Dữ liệu huấn luyện	Ảnh gốc; không huấn luyện riêng theo enhancer
Bộ tối ưu	AdamW, learning rate 10^{-4}
Weight decay / batch size	10^{-4} / 32
Số epoch tối đa	20
Dừng sớm	Patience 5, min delta 0,001
Training seed	11, 22, 33
Chọn checkpoint	Macro-F1 validation clean tốt nhất

Trong huấn luyện, các phép tăng cường nhẹ gồm xoay tối đa $10°$, tịnh tiến tối đa 5%, thay đổi nhẹ sáng/tương phản/bão hòa và xóa ngẫu nhiên một vùng nhỏ. Không lật ngang biển báo vì có thể thay đổi ý nghĩa hướng di chuyển. Cụm từ "huấn luyện clean" ở đây nghĩa là không huấn luyện bằng mô hình thiếu sáng Gamma–Poisson–Gaussian của thí nghiệm, không có nghĩa là loại bỏ mọi augmentation.

Nhóm thu được các checkpoint tốt nhất ở epoch 3, 6 và 14, tương ứng với seed 11, 22 và 33. Các lần huấn luyện kết thúc ở epoch 8, 11 và 15. Mã lưu checkpoint khi Macro-F1 validation đạt giá trị cao nhất, còn bộ đếm dừng sớm dùng mức cải thiện tối thiểu 0,001. Vì hai quy tắc này khác nhau, thời điểm dừng không nhất thiết cách checkpoint tốt nhất đúng năm epoch. Sau bước huấn luyện, nhóm giữ nguyên trọng số để so sánh mọi phép xử lý ảnh.

4.2. Chỉ số đánh giá nhận dạng

Accuracy là tỷ lệ mẫu được phân loại đúng:

$$\text{Accuracy} = \frac{N_{\text{đúng}}}{N_{\text{tổng}}}. \tag{20}$$

Với mỗi lớp $c \in \{0, \ldots, 42\}$, Precision, Recall và F1 được tính từ số dự đoán đúng dương (TP), sai dương (FP) và sai âm (FN):

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \tag{21}$$

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad \text{Macro-F1} = \frac{1}{43}\sum_{c=0}^{42} F1_c. \tag{22}$$

Nếu mẫu số bằng 0, nhóm quy ước chỉ số tương ứng bằng 0 như trong mã nguồn. Macro-F1 cho mỗi lớp đóng góp ngang nhau nên phù hợp với việc đánh giá đủ 43 loại biển báo. Nhóm còn lưu Weighted-F1 làm chỉ số bổ sung, trong đó trọng số là số ảnh của từng lớp. Với tập con có đúng 10 ảnh/lớp, Weighted-F1 bằng Macro-F1 về mặt toán học. Trên toàn bộ test, số ảnh mỗi lớp khác nhau nên hai chỉ số có thể khác nhau.

Các bảng F1 trong báo cáo dùng Macro-F1 và ghi rõ đơn vị phần trăm. Chênh lệch giữa hai giá trị phần trăm được gọi là *điểm phần trăm*, tránh nhầm với tỷ lệ cải thiện tương đối.

4.3. Giao thức chọn tham số và tổng hợp số liệu

Nhóm chọn tham số của bảy phương pháp tăng cường trên 1.290 ảnh validation, với 30 ảnh cho mỗi lớp. Điểm lựa chọn là Macro-F1 trung bình qua ba mức suy giảm, ba noise seed và ba checkpoint. Nhóm thử ba số mũ cho Gamma, sáu cấu hình cho CLAHE và hai bộ tỉ lệ cho MSR. Các mô hình học sâu giữ nguyên trọng số pretrained. Trong nhóm tăng sáng, nếu điểm của một phương án cách điểm tốt nhất dưới 0,005, nhóm so tiếp theo độ trễ. Diffusion được chọn với Macro-F1 validation 72,77%, còn CLAHE đạt 68,86%.

Nhóm sử dụng lại tập validation và các checkpoint trên khi khảo sát khử nhiễu. Đầu tiên, nhóm chọn độ mạnh cho từng bộ lọc khi chạy riêng lẻ. Sau đó, nhóm giữ tham số này khi so sánh hai thứ tự kết hợp với Gamma và CLAHE. Validation được dùng để đánh giá thêm sáu cấu hình bộ lọc và 12 chuỗi xử lý. Sau khi chọn độ mạnh, tập test khảo sát 19 phương pháp, gồm bốn đối chứng và 15 cấu hình khử nhiễu hoặc kết hợp. Nhóm chọn ứng viên tổng thể theo Macro-F1 validation cao nhất, không chọn lại bằng điểm test. Đây là cách tìm tuần tự trong một lưới hữu hạn, chưa tối ưu đồng thời mọi tham số và thứ tự.

Để tổng hợp số liệu trong các bảng, nhóm lấy trung bình qua noise seed trong từng checkpoint trước. Sau đó, nhóm tính trung bình và độ lệch chuẩn mẫu qua ba checkpoint theo công thức:

$$\overline{m}_t = \frac{1}{3}\sum_{n=1}^{3} m_{t,n}, \quad \mu = \frac{1}{3}\sum_{t=1}^{3} \overline{m}_t, \quad s = \sqrt{\frac{\sum_t (\overline{m}_t - \mu)^2}{2}}. \tag{23}$$

Các noise seed và checkpoint sử dụng chung ảnh, không được coi là những ảnh độc lập. Độ lệch chuẩn qua checkpoint cũng không đo mức biến thiên PSNR/SSIM giữa ảnh.

4.4. Phạm vi đánh giá và kiểm tra bằng chứng

Với nhóm tăng sáng, nhóm thực hiện $3 + 3 \times 3 \times 3 \times 8 = 219$ lượt cho mỗi phạm vi, gồm tập con 430 ảnh và toàn bộ test 12.630 ảnh. Khảo sát khử nhiễu có $3 + 27 \times 19 = 516$ lượt trên tập con. Khi đánh giá toàn bộ test, nhóm giữ tám phương pháp đã chọn bằng validation, gồm các đối chứng, bộ lọc tốt nhất, cả hai thứ tự của cặp được chọn và ứng viên tổng thể. Phạm vi này có tổng cộng 219 lượt. Nhóm xác định danh sách phương pháp trước khi đọc kết quả trên tập con.

Bảng 5. Phạm vi và số dòng dự đoán đã kiểm tra; bao gồm đối chứng dùng lại, không phải toàn bộ quan sát độc lập.

Khảo sát	Ảnh/lượt	Lượt	Dòng dự đoán
Tăng sáng, subset	430	219	94.170
Tăng sáng, full-test	12.630	219	2.765.970
Khử nhiễu/kết hợp, subset	430	516	221.880
Khử nhiễu/kết hợp, full-test	12.630	219	2.765.970

Nhóm kiểm tra tổng cộng 5.847.990 dòng dự đoán bằng cách đối chiếu mã ảnh, nhãn, group ID và cấu hình. Các chỉ số Accuracy, Macro-F1 và Weighted-F1 được tính lại từ dự đoán, khớp bảng tổng hợp với sai số tuyệt đối không quá 10^{-8}. Nhóm đối chiếu ma trận nhầm lẫn trong ZIP cho 954 lượt đã lưu ma trận. Riêng phần tăng sáng trên tập con, ma trận được tính lại từ CSV. Hash của ba checkpoint khớp giữa bốn phạm vi đánh giá. Những đối chứng được dùng lại vẫn giữ nguyên dự đoán, nên số dòng lưu thêm không có nghĩa là có thêm ảnh nguồn độc lập. Các bảng và biên bản kiểm tra được lưu trong `report/evidence/final/`.

4.5. Chất lượng ảnh của các phương pháp tăng sáng

Bảng 6. PSNR (dB) / SSIM trên subset 430 ảnh; mỗi ô ghi PSNR trước, SSIM sau.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	19.49 / 0.6077	15.37 / 0.3410	13.79 / 0.2254
Gamma	23.94 / 0.7011	17.18 / 0.4498	14.84 / 0.2964
HE	11.45 / 0.3704	11.36 / 0.3237	11.06 / 0.2578
CLAHE	23.41 / 0.6982	18.29 / 0.5208	15.69 / 0.3712
MSR	8.70 / 0.3735	6.60 / 0.2408	7.26 / 0.1875
Zero-DCE	17.68 / 0.5067	20.08 / 0.4509	16.71 / 0.3157
Retinexformer	11.00 / 0.3853	14.78 / 0.4780	17.40 / 0.4350
Diffusion	14.50 / 0.5662	14.91 / 0.5411	14.88 / 0.4720

Các phương pháp không chỉ thay đổi độ sáng mà còn tác động đến cấu trúc và nhiễu của ảnh. Khi đọc bảng, nhóm nhận thấy phương pháp có PSNR cao nhất chưa chắc có SSIM cao nhất. Thứ hạng còn thay đổi theo mức suy giảm. Bảng này chỉ trình bày chất lượng trên

tập con. Ở phần tương quan, nhóm dùng các chỉ số ảnh và nhận dạng cùng đo trên toàn bộ test để tránh ghép hai phạm vi khác nhau.

4.6. Nhận dạng trên subset 430 ảnh

Bảng 7. Accuracy (%), mean ± sample SD trên subset 430 ảnh.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	87.67 ± 3.56	69.20 ± 5.21	47.36 ± 8.41
Gamma	89.46 ± 3.69	71.76 ± 6.07	48.27 ± 7.53
HE	85.61 ± 3.67	65.30 ± 4.68	42.22 ± 5.17
CLAHE	89.84 ± 3.94	72.92 ± 6.18	50.10 ± 8.32
MSR	81.06 ± 1.68	53.70 ± 3.48	31.55 ± 2.23
Zero-DCE	85.17 ± 5.30	64.55 ± 6.35	41.99 ± 6.28
Retinexformer	81.73 ± 2.27	70.31 ± 5.80	45.79 ± 5.66
Diffusion	91.63 ± 2.49	78.11 ± 5.26	56.02 ± 6.58

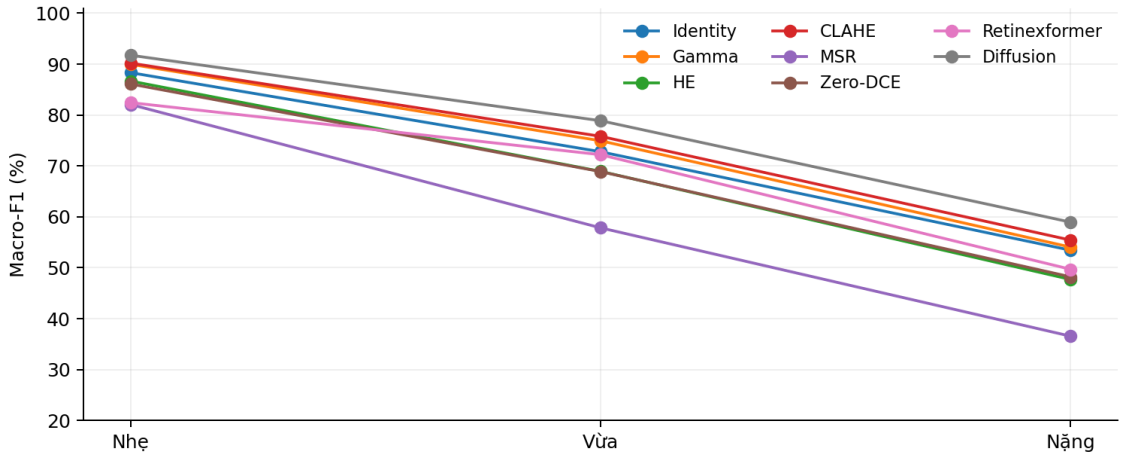
Bảng 8. Macro-F1 (%), mean ± sample SD trên cùng subset.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	88.33 ± 2.96	72.79 ± 4.32	53.45 ± 7.72
Gamma	89.97 ± 3.36	74.95 ± 5.33	54.05 ± 7.14
HE	86.68 ± 3.30	68.94 ± 4.45	47.70 ± 4.99
CLAHE	90.21 ± 3.70	75.82 ± 5.62	55.43 ± 7.73
MSR	82.08 ± 1.50	57.84 ± 2.79	36.56 ± 1.96
Zero-DCE	86.10 ± 4.97	68.90 ± 5.39	48.21 ± 6.01
Retinexformer	82.44 ± 1.90	72.21 ± 4.42	49.70 ± 4.67
Diffusion	91.75 ± 2.51	78.89 ± 4.99	58.96 ± 5.47

Trên tập con, Identity đạt Macro-F1 lần lượt là 88,33%, 72,79% và 53,45% ở mức nhẹ, vừa và nặng. Diffusion đạt các giá trị tương ứng là 91,75%, 78,89% và 58,96%. Mặc dù diffusion cải thiện kết quả so với giữ nguyên ảnh tối, hiệu năng ở mức nặng vẫn thấp hơn nhiều so với ảnh gốc. Điều đó cho thấy phép tăng cường chưa khắc phục hết tác động của suy giảm. Nhóm đọc các chênh lệch này cùng độ lệch chuẩn qua checkpoint.

4.7. Đánh giá tăng sáng trên full-test

Trên ảnh gốc chưa tạo suy giảm, ResNet-18 đạt Accuracy $99,22\% \pm 0,28$ và Macro-F1 $98,94\% \pm 0,32$. Với ảnh suy giảm giữ nguyên, Identity đạt Macro-F1 90,45%, 76,07% và 58,37% theo ba mức. Diffusion đạt 93,63%, 81,57% và 62,46%. Các kết quả đều sử dụng cùng ba CNN, không huấn luyện lại theo phương pháp xử lý. Nhóm tổng hợp riêng kết quả trên tập con và toàn bộ test vì hai phạm vi có số ảnh và phân bố lớp khác nhau.



Hình 6. Macro-F1 trên subset; cùng checkpoint và cùng ảnh tối được dùng cho các phương pháp.

Bảng 9. Macro-F1 (%) trên toàn bộ 12.630 ảnh test, tính lại từ dự đoán thô.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	90.45 ± 3.38	76.07 ± 4.69	58.37 ± 7.77
Gamma	91.65 ± 3.45	77.50 ± 5.27	59.25 ± 7.12
HE	88.87 ± 3.68	73.15 ± 3.75	53.25 ± 5.88
CLAHE	92.20 ± 3.39	78.16 ± 5.33	60.47 ± 8.05
MSR	84.31 ± 2.04	62.56 ± 2.26	39.62 ± 2.11
Zero-DCE	88.08 ± 4.54	72.34 ± 5.16	52.78 ± 7.01
Retinexformer	83.92 ± 1.26	74.28 ± 3.08	54.22 ± 4.91
Diffusion	93.63 ± 2.13	81.57 ± 4.98	62.46 ± 5.56

4.8. Khử nhiễu và các chuỗi kết hợp

Từ kết quả validation, nhóm chọn Gaussian với kernel 5×5 và $\sigma = 0,8$. Bilateral sử dụng $d = 5$, $\sigma_c = 0,10$ và $\sigma_s = 3$. Với NLM, nhóm chọn $h = h_{\text{color}} = 7$, cửa sổ mẫu 3 và cửa sổ tìm kiếm 7. Chuỗi Gaussian rồi Gamma đạt Macro-F1 validation 77,77%, cao hơn diffusion ở mức 72,77%. Vì vậy, nhóm chọn chuỗi này trước khi đánh giá test.

Gaussian đơn lẻ giúp cải thiện nhận dạng mặc dù bộ lọc không chủ động nâng sáng ảnh. Trong các cấu hình đã thử, bilateral rồi tăng sáng thường cho điểm tốt hơn thứ tự ngược lại. Với NLM, xu hướng có thể khác. Do đó, nhóm chưa tìm được một quy tắc thứ tự chung cho cả ba bộ lọc. Việc giữ cùng độ mạnh trong mỗi cặp là điều kiện cần để diễn giải phần chênh lệch do thứ tự.

Trên toàn bộ test, Gaussian rồi Gamma đạt Macro-F1 96,70%, 85,54% và 71,56% ở ba mức suy giảm. Mức tăng so với Identity lần lượt là 6,25, 9,47 và 13,19 điểm phần trăm. Ở mức vừa, Accuracy tăng từ 72,32% lên 83,75%. Riêng mức nặng, CLAHE rồi Gaussian cao hơn chuỗi được chọn khoảng 0,21 điểm phần trăm. Nhóm vẫn giữ lựa chọn từ validation thay vì thay đổi sau khi thấy test. Chênh lệch nhỏ này cũng chưa đủ để kết luận ưu thế thống kê.

Bảng 10. Macro-F1 (%) của 15 cấu hình khử nhiễu/kết hợp trên subset. Mũi tên là thứ tự áp dụng; cùng tham số bộ lọc cho mỗi cặp.

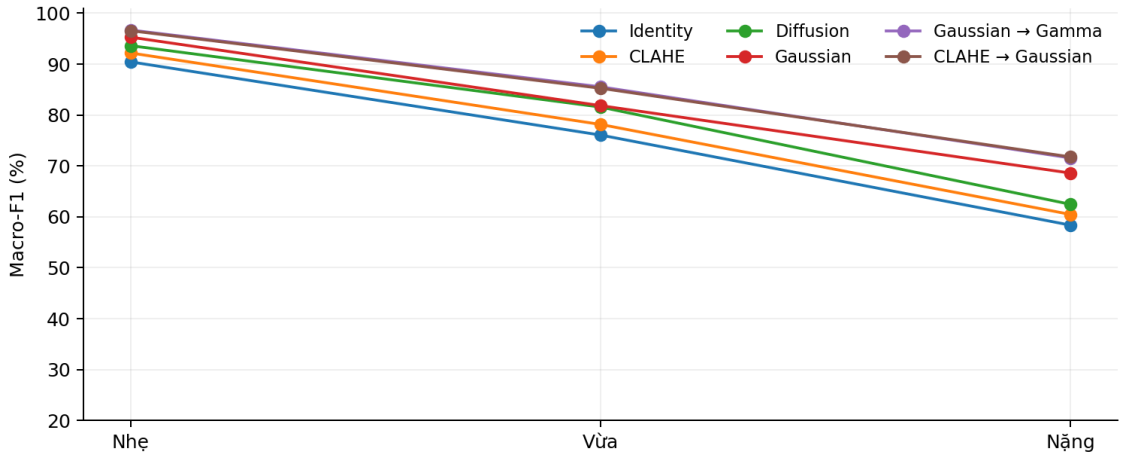
Phương pháp	Nhẹ	Vừa	Nặng
Gaussian	93.60 ± 2.63	79.37 ± 3.26	65.18 ± 2.15
Bilateral	93.76 ± 3.46	77.80 ± 5.16	57.60 ± 6.78
NLM	91.25 ± 2.13	74.34 ± 3.98	54.52 ± 7.30
Gaussian → Gamma	95.79 ± 1.38	82.98 ± 2.39	68.25 ± 1.57
Gamma → Gaussian	95.73 ± 1.30	82.82 ± 2.42	67.75 ± 1.43
Gaussian → CLAHE	95.14 ± 1.67	83.32 ± 2.32	68.40 ± 1.37
CLAHE → Gaussian	95.53 ± 1.57	83.46 ± 2.29	68.64 ± 1.86
Bilateral → Gamma	96.06 ± 2.03	83.12 ± 3.72	62.39 ± 5.44
Gamma → Bilateral	95.53 ± 1.91	80.44 ± 4.31	58.75 ± 6.78
Bilateral → CLAHE	95.71 ± 1.67	83.09 ± 3.45	63.31 ± 5.27
CLAHE → Bilateral	94.28 ± 2.78	80.41 ± 4.80	58.75 ± 7.01
NLM → Gamma	92.67 ± 2.12	76.13 ± 5.00	55.02 ± 7.05
Gamma → NLM	92.60 ± 2.03	76.69 ± 4.83	55.52 ± 7.04
NLM → CLAHE	92.80 ± 2.12	77.11 ± 5.29	56.40 ± 7.38
CLAHE → NLM	92.86 ± 1.92	78.67 ± 4.45	57.66 ± 7.00

Bảng 11. Macro-F1 (%) của tám phương pháp đã khóa cho full-test. Gaussian → Gamma được chọn bằng validation.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	90.45 ± 3.38	76.07 ± 4.69	58.37 ± 7.77
Gamma	91.65 ± 3.45	77.50 ± 5.27	59.25 ± 7.12
CLAHE	92.20 ± 3.39	78.16 ± 5.33	60.47 ± 8.05
Diffusion	93.63 ± 2.13	81.57 ± 4.98	62.46 ± 5.56
Gaussian	95.30 ± 1.93	81.85 ± 2.61	68.60 ± 2.74
Gaussian → CLAHE	96.41 ± 1.35	85.15 ± 2.70	71.62 ± 2.23
CLAHE → Gaussian	96.57 ± 1.21	85.26 ± 2.60	71.77 ± 2.30
Gaussian → Gamma	96.70 ± 1.16	85.54 ± 2.49	71.56 ± 2.01

Bảng 12. Accuracy (%) trên cùng full-test của khảo sát kết hợp.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	91.29 ± 3.54	72.32 ± 5.15	52.91 ± 7.92
Gamma	92.76 ± 3.40	74.57 ± 5.96	53.44 ± 7.22
CLAHE	93.65 ± 2.79	75.78 ± 5.27	55.56 ± 7.38
Diffusion	94.89 ± 1.67	82.78 ± 4.41	61.00 ± 6.12
Gaussian	96.10 ± 1.64	78.92 ± 3.18	63.18 ± 3.56
Gaussian → CLAHE	97.50 ± 0.88	83.71 ± 2.66	66.72 ± 2.50
CLAHE → Gaussian	97.58 ± 0.85	83.89 ± 2.65	66.83 ± 2.58
Gaussian → Gamma	97.66 ± 0.93	83.75 ± 3.10	66.33 ± 3.23



Hình 7. Full-test giữa đối chứng, tăng sáng, Gaussian đơn lẻ và hai chuỗi đại diện.

4.9. Ảnh hưởng của thứ tự trên full-test

Nhóm giữ cả hai thứ tự của cặp Gaussian–CLAHE trên toàn bộ test theo quy tắc chọn bằng validation. Khi lấy điểm của CLAHE rồi Gaussian trừ điểm của Gaussian rồi CLAHE, chênh lệch Macro-F1 trung bình là $+0,17$, $+0,11$ và $+0,15$ điểm phần trăm ở ba mức. Tuy nhiên, một số tổ hợp checkpoint và noise seed cho chênh lệch âm. Như vậy, thứ tự CLAHE rồi Gaussian chỉ nhỉnh hơn trung bình trong cấu hình đang xét, chưa phải lựa chọn luôn tốt hơn ở mọi lượt.

Trên toàn bộ test, nhóm chỉ đánh giá Gaussian rồi Gamma, không có chiều Gamma rồi Gaussian. Hai chiều của cặp Gamma chỉ được so trực tiếp trên validation và tập con. Vì vậy, kết quả thứ tự của Gaussian–CLAHE không được dùng để kết luận thay cho cặp Gamma hoặc các phép tăng sáng khác.

Nhóm sử dụng paired bootstrap [16] để ước lượng mức bất định của chênh lệch thứ tự. Thí nghiệm gồm 2.000 lần lấy mẫu lại với seed 20261025. Trong từng lớp, nhóm lấy có hoàn lại đúng số ảnh test ban đầu. Cùng một số lần xuất hiện của mỗi ID được áp dụng cho cả hai phương pháp, ba checkpoint và ba noise seed. Sau đó, nhóm tính lại Macro-F1 từng lượt, lấy trung bình noise trong checkpoint rồi trung bình qua checkpoint. Nhóm không xem chín tổ hợp seed là chín tập ảnh độc lập.

Nhóm báo cáo hai khoảng percentile 95%. Khoảng thứ nhất chỉ lấy mẫu lại ảnh và giữ nguyên các CNN. Khoảng thứ hai lấy mẫu thêm ba nhóm checkpoint có hoàn lại, trong đó mỗi nhóm vẫn giữ ba noise seed. Khoảng thứ hai phản ánh thêm biến động huấn luyện, nhưng chỉ có ba nhóm nên kết quả vẫn mang tính thăm dò. Cả hai cách đều giả định các ảnh test độc lập vì nhóm chưa có track test được xác minh. Do đó, khoảng ước lượng chưa bao phủ phụ thuộc giữa ảnh cùng một biển thực tế nếu có. Các khoảng được tính riêng từng mức và chưa hiệu chỉnh cho ba phép so sánh.

Khi chỉ lấy mẫu lại ảnh, các khoảng đều nằm trên 0 đối với những CNN đang giữ cố định. Khi lấy mẫu cả checkpoint, cả ba khoảng đều chứa 0. Nhóm vì vậy chưa có đủ cơ sở để nói ưu thế trung bình nhỏ này sẽ ổn định nếu huấn luyện lại mô hình. Kết quả cũng không

Bảng 13. Chênh lệch Macro-F1, CLAHE rồi Gaussian trừ Gaussian rồi CLAHE, đơn vị điểm phần trăm. Khoảng tin cậy percentile 95% từ cùng ảnh ghép cặp.

Mức	Chênh lệch	CI chỉ ảnh	CI checkpoint + ảnh
Nhẹ	+0.165	[+0.059; +0.275]	[-0.111; +0.442]
Vừa	+0.110	[+0.015; +0.201]	[-0.164; +0.358]
Nặng	+0.154	[+0.056; +0.255]	[-0.018; +0.311]

chứng minh hai thứ tự tương đương. Để kết luận rộng hơn, nhóm cần thêm các lần huấn luyện độc lập và cách lấy mẫu phù hợp với cấu trúc dữ liệu.

5. THẢO LUẬN KẾT QUẢ VÀ PHÂN TÍCH TƯƠNG QUAN

5.1. Chất lượng ảnh cao có bảo đảm nhận dạng tốt?

Trên toàn bộ test ở mức vừa, Zero-DCE đạt PSNR 19,98 dB, cao hơn diffusion với 14,77 dB. Tuy nhiên, Macro-F1 của Zero-DCE chỉ đạt 72,34%, trong khi diffusion đạt 81,57%. Qua trường hợp này, nhóm thấy rằng phương pháp gần ảnh gốc hơn theo sai số pixel chưa chắc giúp mô hình nhận dạng tốt hơn.

Kết quả khử nhiễu còn cho thấy một trường hợp mà cả hai chỉ số ảnh đều không cùng thứ hạng với F1. Ở mức nặng, Gaussian đơn lẻ có PSNR 13,78 dB và SSIM 0,2847. Diffusion đạt 14,79 dB và 0,4768, đều cao hơn Gaussian. Dù vậy, Macro-F1 của Gaussian là 68,60%, cao hơn diffusion với 62,46%. Kết quả cho thấy ảnh còn tối và chưa gần tham chiếu về cấu trúc trung bình vẫn có thể giữ được thông tin hữu ích cho bộ phân loại.

Ở mức vừa, Gaussian rồi Gamma đạt PSNR 17,62 dB, SSIM 0,5996 và Macro-F1 85,54%. Trong trường hợp này, chất lượng ảnh và nhận dạng cùng được cải thiện. Tuy nhiên, nhóm không coi đó là bảo đảm rằng PSNR hoặc SSIM tăng thì F1 luôn tăng. Chỉ số ảnh tính trên toàn bộ crop, còn CNN có thể phụ thuộc mạnh vào một vùng nhỏ chứa nét số, viền hoặc biểu tượng.

5.2. Phương pháp và kết quả phân tích tương quan

Nhóm tính tương quan riêng cho từng mức suy giảm, sử dụng tám phương pháp tăng sáng và đối chứng trên cùng 12.630 ảnh test. Mỗi phương pháp tạo thành một điểm dữ liệu, với các giá trị chất lượng ảnh và nhận dạng được tổng hợp tương ứng. Nhóm không đưa clean vào vì PSNR của ảnh so với chính nó là vô hạn và clean không phải một phương án phục hồi. Hệ số Pearson đo mức liên hệ tuyến tính theo công thức:

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}. \tag{24}$$

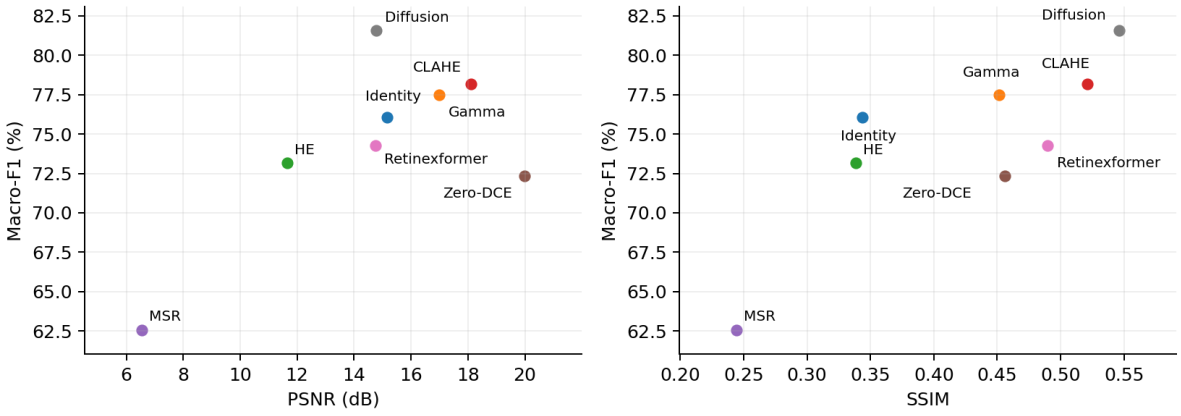
Spearman là Pearson trên thứ hạng, dùng thứ hạng trung bình khi bằng nhau.

Hệ số Spearman giữa PSNR và Macro-F1 lần lượt là 0,667, 0,357 và 0,286 khi đi từ mức nhẹ đến nặng. Với SSIM và Macro-F1, các giá trị là 0,714, 0,738 và 0,619. Trong tám phương án này, thứ hạng SSIM phù hợp với thứ hạng F1 hơn PSNR. Tuy nhiên, trường hợp

Bảng 14. Tương quan trên full-test, $n = 8$ phương pháp tăng sáng/đối chứng mỗi hàng.

Mức	Chất lượng	Nhận dạng	Pearson	Spearman
Vừa	PSNR	Accuracy	0.584	0.238
Vừa	PSNR	Macro-F1	0.673	0.357
Vừa	SSIM	Accuracy	0.862	0.857
Vừa	SSIM	Macro-F1	0.809	0.738
Nhẹ	PSNR	Accuracy	0.739	0.690
Nhẹ	PSNR	Macro-F1	0.713	0.667
Nhẹ	SSIM	Accuracy	0.838	0.762
Nhẹ	SSIM	Macro-F1	0.813	0.714
Nặng	PSNR	Accuracy	0.696	0.405
Nặng	PSNR	Macro-F1	0.702	0.286
Nặng	SSIM	Accuracy	0.733	0.738
Nặng	SSIM	Macro-F1	0.587	0.619

Gaussian và diffusion ở trên cho thấy nhóm vẫn cần đo nhận dạng trực tiếp, không thể chỉ dùng SSIM để chọn phương pháp.



Hình 8. PSNR/SSIM và Macro-F1 mức vừa trên full-test. Mỗi điểm là phương pháp, không phải một ảnh độc lập.

Phân tích này chỉ có tám điểm, trong khi các phương pháp dùng chung ảnh, phiên bản nhiễu và checkpoint. Một phương pháp có điểm thấp ở cả hai trục, chẳng hạn MSR, có thể ảnh hưởng nhiều đến hệ số Pearson. Vì vậy, nhóm xem đây là phân tích thăm dò, chưa phải bằng chứng về quan hệ nhân quả hoặc khả năng áp dụng cho camera ban đêm. Nhóm lưu riêng tương quan của khảo sát kết hợp, không gộp thêm các chuỗi dùng chung thành phần chỉ để tăng số điểm.

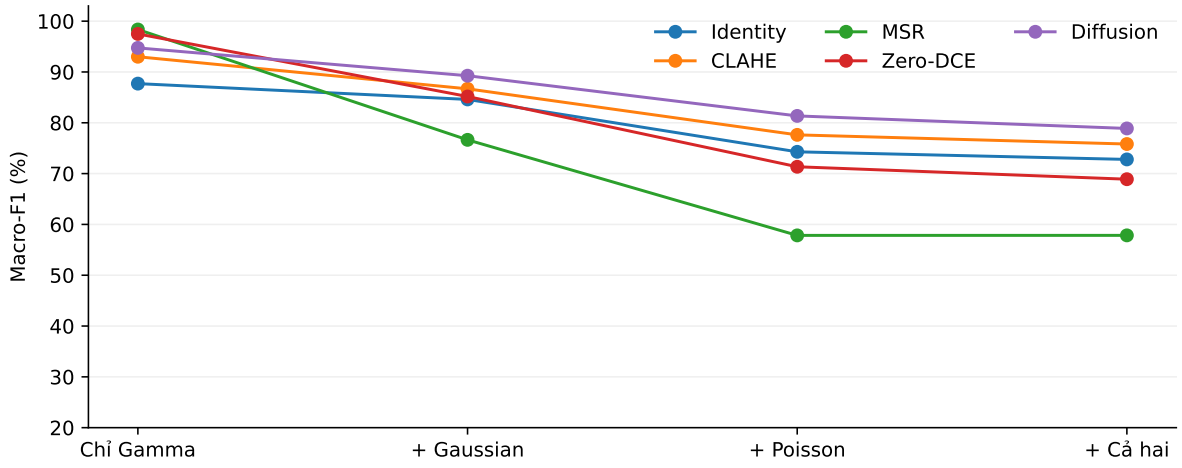
5.3. Ablation: tách độ tối và từng thành phần nhiễu

Để tách ảnh hưởng của từng thành phần, nhóm thực hiện thí nghiệm ablation. Nhóm giữ $\gamma_d = 2,2$, các checkpoint và tham số xử lý, rồi lần lượt thử bốn trường hợp: chỉ Gamma làm tối, thêm Gaussian $\sigma = 0,01$, thêm Poisson $p = 60$ và thêm cả hai loại nhiễu. Khảo sát có $4 \times 3 \times 8 \times 3 = 288$ lượt trên 430 ảnh. Với trường hợp chỉ Gamma, noise seed không làm thay đổi ảnh nên nhóm không coi đó là các quan sát ảnh độc lập.

Bảng 15. Macro-F1 (%) khi tách thành phần suy giảm; cùng tham số xử lý đã chọn.

Phương pháp	Chỉ Gamma	+ Gaussian	+ Poisson	+ Cả hai
Identity	87.71	84.60	74.29	72.79
Gamma	94.25	86.62	76.71	74.95
HE	93.91	82.23	72.26	68.94
CLAHE	93.00	86.68	77.62	75.82
MSR	98.36	76.64	57.84	57.84
Zero-DCE	97.49	85.17	71.35	68.90
Retinexformer	88.97	83.23	76.92	72.21
Diffusion	94.74	89.26	81.35	78.89

MSR đạt Macro-F1 98,36% khi ảnh chỉ bị Gamma làm tối, nhưng còn 57,84% khi ảnh có cả hai loại nhiễu. Zero-DCE giảm từ 97,49% xuống 68,90%. Diffusion giảm từ 94,74% xuống 78,89%. Nhóm cho rằng những kết quả này cho thấy cần đưa nhiễu vào khi khảo sát tăng sáng. Tuy nhiên, nhóm chưa thể nói Poisson luôn gây hại hơn Gaussian vì hai mức nhiễu trong thí nghiệm chưa được cân bằng về năng lượng.



Hình 9. Ảnh hưởng từng thành phần suy giảm trên subset, tính từ bảng ablation cùng gói kết quả.

5.4. Diễn giải hiệu quả khử nhiễu và thứ tự

Bộ lọc Gaussian làm giảm dao động cục bộ và phù hợp với một thành phần nhiễu mà nhóm đã đưa vào mô hình suy giảm. Khi lọc trước Gamma, bộ lọc có thể giảm phần nhiễu bị

khuếch đại ở vùng tối. Đổi lại, nó có thể làm mềm nét số và đường viền. Vì vậy, kết quả F1 tốt trên nhiễu tổng hợp chưa đủ để khẳng định hiệu quả tương tự với lóa đèn, nhòe chuyển động hoặc nhiễu cảm biến thực.

Với cặp Gaussian–CLAHE, khoảng tin cậy chỉ lấy mẫu ảnh có giá trị nhỏ và dương, nhưng các khoảng có lấy mẫu checkpoint đều chứa 0. Nhóm cần phân biệt sự thay đổi trong những mô hình đang giữ cố định với khả năng lặp lại ưu thế khi huấn luyện một mô hình khác. Kết quả hiện tại chưa hỗ trợ một quy tắc thứ tự chung cho mọi bộ lọc.

Bilateral và NLM có cơ chế giữ biên hoặc sử dụng các mảnh ảnh tương tự, nhưng điều đó không bảo đảm F1 cao hơn Gaussian trên crop nhỏ. Nhóm mới khảo sát một lưới tham số hữu hạn. NLM còn có bước lượng tử hóa 8 bit và chuyển màu nội bộ. Do đó, chênh lệch kết quả phản ánh cả cách triển khai, không chỉ riêng nguyên lý lọc.

Bảng 16. PSNR (dB) / SSIM trên full-test của các phương pháp đã sàng lọc.

Phương pháp	Nhẹ	Vừa	Nặng
Identity	19.33 / 0.6115	15.17 / 0.3433	13.56 / 0.2240
Gamma	23.82 / 0.7034	16.99 / 0.4516	14.61 / 0.2948
CLAHE	23.19 / 0.6981	18.11 / 0.5209	15.45 / 0.3679
Diffusion	14.52 / 0.5756	14.77 / 0.5462	14.79 / 0.4768
Gaussian	19.75 / 0.7267	15.40 / 0.4185	13.78 / 0.2847
Gaussian → CLAHE	24.37 / 0.8495	18.46 / 0.6208	15.80 / 0.4560
CLAHE → Gaussian	25.62 / 0.8798	18.84 / 0.6536	15.93 / 0.4807
Gaussian → Gamma	25.51 / 0.8856	17.62 / 0.5996	15.22 / 0.4295

5.5. Chi phí xử lý và giới hạn triển khai

Bảng 17. Độ trễ enhancer mức vừa trên full-test nhóm tăng sáng, ms/ảnh.

Phương pháp	Thời gian
Identity	0.126
Gamma	0.230
HE	0.199
CLAHE	0.417
MSR	2.235
Zero-DCE	1.589
Retinexformer	12.578
Diffusion	227.869

Nhóm sử dụng Tesla T4 trong thực nghiệm. Các phép truyền thống chạy trên CPU, còn mô hình học sâu chạy trên GPU qua phần mã tích hợp. Thời gian trong bảng chỉ đo khối tăng cường, không gồm tạo nhiễu, đọc ghi ảnh, tính chỉ số hoặc chạy CNN. Ở lần khảo sát khử nhiễu, Gaussian rồi Gamma mất khoảng 0,293 ms/ảnh, còn CLAHE rồi Gaussian mất

khoảng 0,688 ms/ảnh ở mức vừa. Một số đối chứng tăng sáng dùng lại kết quả từ lần chạy khác. Vì vậy, nhóm không dùng tỷ số thời gian giữa chúng và các chuỗi mới để kết luận ưu thế tốc độ trong cùng điều kiện.

Thí nghiệm của nhóm sử dụng RGB 64×64, vùng biển báo có sẵn, một kiến trúc CNN, ba checkpoint và một mô hình suy giảm tổng hợp. Nhóm chưa có kết quả trên camera đêm thực, mô hình phát hiện biển báo hoặc video. Phân tích bootstrap ở Bảng 13 chỉ dành cho cặp Gaussian–CLAHE với ba checkpoint và ba noise seed đã dùng, nên chưa xác lập ưu thế cho mọi cấu hình hoặc camera. Các mô hình tăng cường còn được học trước trên dữ liệu khác. Khi nói quy trình được chọn là tốt nhất, nhóm chỉ hiểu đó là phương án tốt nhất theo validation trong tập cấu hình đã khảo sát.

5.6. Phân tích lỗi ghép cặp và theo lớp

5.6.1. Định nghĩa được giúp và bị làm sai

Nhóm ghép các dự đoán theo cùng mã ảnh, mức suy giảm, noise seed và checkpoint. Trong các công thức dưới đây, b_i là dự đoán trên ảnh Identity, e_i là dự đoán sau xử lý và y_i là nhãn đúng. Nhóm đếm hai trường hợp: ảnh được sửa từ sai thành đúng (H) và ảnh bị đổi từ đúng thành sai (D).

$$H = \sum_i \mathbf{1}[b_i \neq y_i,\ e_i = y_i], \tag{25}$$

$$D = \sum_i \mathbf{1}[b_i = y_i,\ e_i \neq y_i]. \tag{26}$$

Với N ảnh ghép cặp, mức thay đổi Accuracy là $\Delta\text{Accuracy} = 100(H - D)/N$ điểm phần trăm. Nhóm dùng quan hệ này để kiểm tra phép đếm với kết quả tổng hợp. Hiệu $H - D$ không thay thế chênh lệch Macro-F1 vì Macro-F1 được tính theo từng lớp. Ngoài hai nhóm trên, một ảnh có thể được dự đoán đúng ở cả hai lần hoặc sai ở cả hai lần. Với nhóm cùng sai, nhãn dự đoán sau xử lý vẫn có thể khác nhãn sai ban đầu.

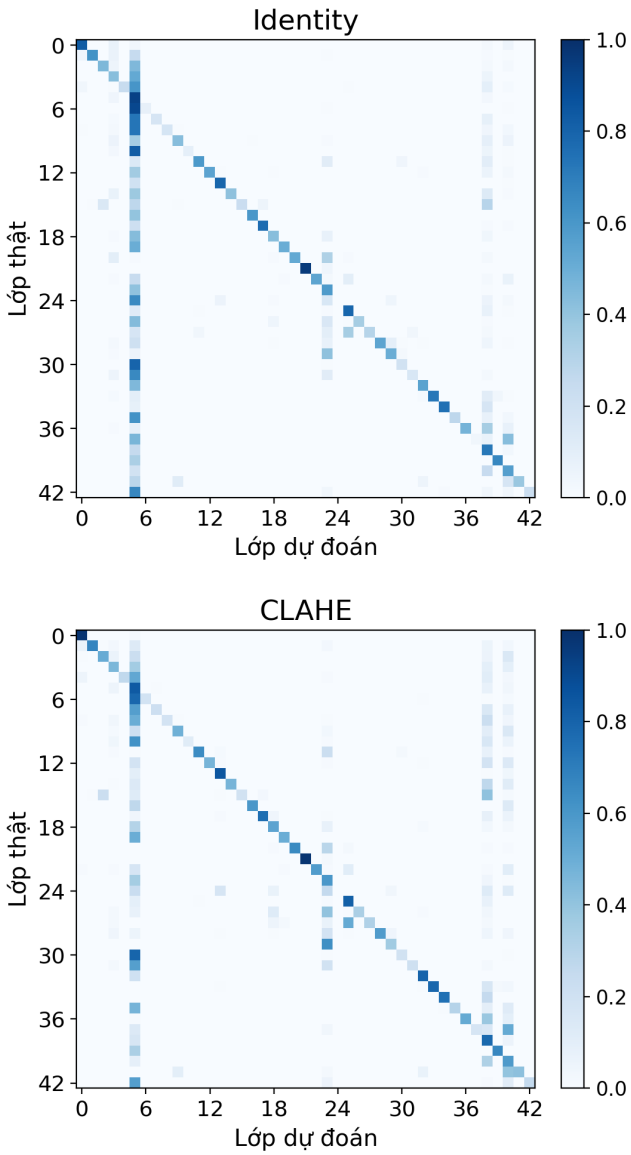
Bảng 18. Số ảnh trung bình được giúp (H), bị làm sai (D) mỗi lượt full-test 12.630 ảnh. Trung bình qua noise seed và checkpoint, không phải ảnh nguồn độc lập.

Phương pháp	Mức	H	D	Δ Acc. (đpt)
CLAHE	Nhẹ	390.00	91.89	2.36
CLAHE	Vừa	540.44	102.44	3.47
CLAHE	Nặng	462.11	128.11	2.64
Diffusion	Nhẹ	717.56	263.00	3.60
Diffusion	Vừa	1616.67	295.00	10.46
Diffusion	Nặng	1477.78	456.67	8.08
Gaussian $\rightarrow$ Gamma	Nhẹ	826.22	21.00	6.38
Gaussian $\rightarrow$ Gamma	Vừa	1472.67	29.22	11.43
Gaussian $\rightarrow$ Gamma	Nặng	1727.89	33.67	13.41

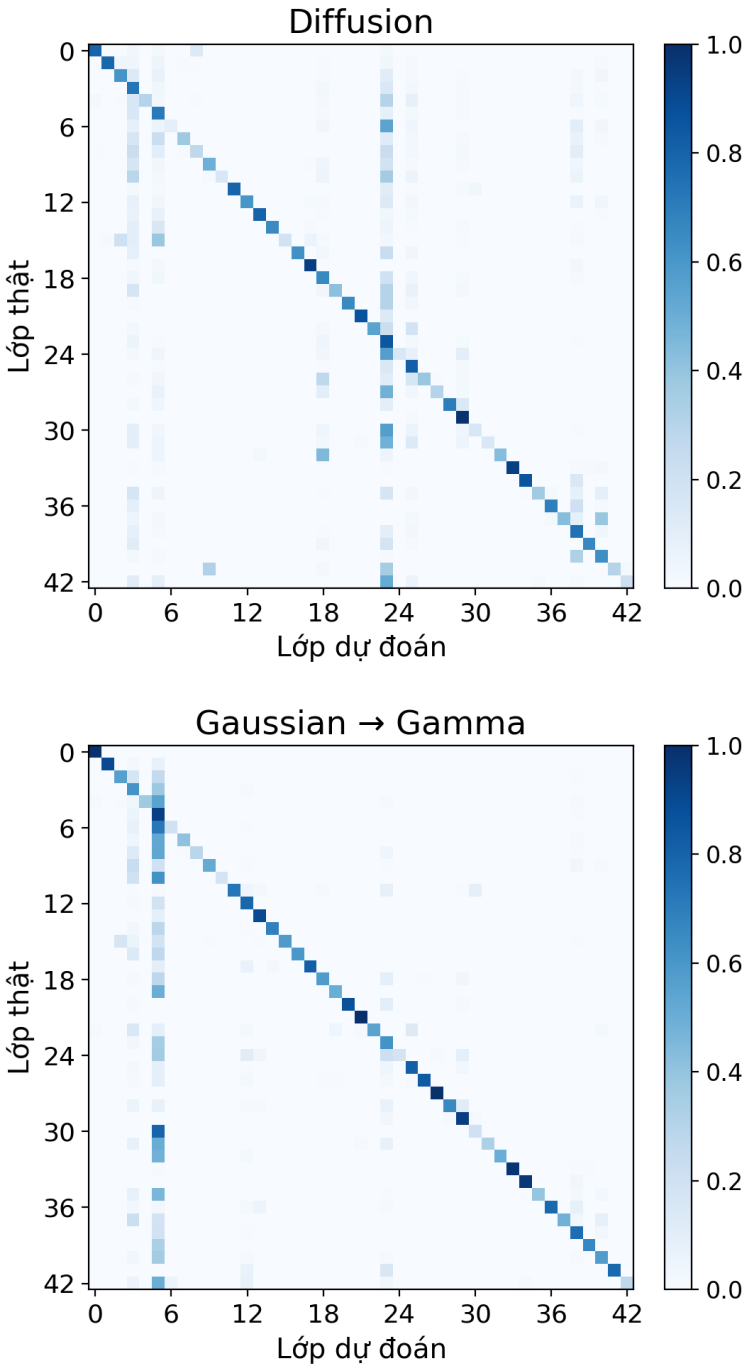
Ở mức vừa, Gaussian rồi Gamma sửa đúng trung bình 1472,67 ảnh nhưng làm sai 29,22 ảnh mỗi lượt, tăng ròng 1443,44 ảnh, tương ứng 11,43 điểm phần trăm Accuracy. Lợi ích tổng thể vẫn đi kèm nhóm mẫu bị ảnh hưởng bất lợi. Tính cả hai hướng chuyển giúp tránh chỉ trình bày ví dụ được cải thiện.

5.6.2. Ma trận nhầm lẫn và các cặp nhầm

Trong ma trận C_{ab}, hàng biểu thị nhãn thật và cột biểu thị nhãn mô hình dự đoán. Nhóm chia mỗi hàng cho số ảnh thật của lớp đó để xem tỷ lệ nhận ra đúng lớp và tỷ lệ nhầm sang lớp khác. Cách chuẩn hóa này giúp đọc ma trận khi số ảnh giữa các lớp trên toàn bộ test không bằng nhau.



Hình 10. Ma trận chuẩn hóa hàng của Identity và CLAHE, full-test mức nặng, checkpoint 11, noise seed 101. Mỗi hàng là một lớp thật; cột 5 biểu thị dự đoán giới hạn 80 km/h.



Hình 11. Ma trận của diffusion và Gaussian rồi Gamma trên cùng 12.630 ảnh, mức, checkpoint và noise seed như Hình 10. Đây là một lát cắt xác định, không phải ma trận trung bình qua seed.

Bảng 19. Ba cặp nhầm có tỷ lệ trung bình cao nhất của mỗi phương pháp ở mức nặng, full-test. Mẫu nguồn dùng chung giữa các lượt.

Phương pháp	Lớp thật	Lớp dự đoán	Tỷ lệ (%)
Identity	10	5	84.16
Identity	6	5	82.67
Identity	30	5	79.93
CLAHE	30	5	79.70
CLAHE	6	5	77.41
CLAHE	10	5	74.85
Diffusion	15	5	36.67
Diffusion	6	3	27.33
Diffusion	30	3	27.04
Gaussian → Gamma	30	5	71.63
Gaussian → Gamma	10	5	66.62
Gaussian → Gamma	6	5	66.44

5.6.3. Hiện tượng tập trung dự đoán vào lớp 5

Lớp 5 là biển giới hạn 80 km/h, có 630/12.630 ảnh, tương ứng 4,99% full-test. Định nghĩa $q_5 = \sum_a C_{a5}/N$ là tỷ lệ dự đoán lớp 5 và $e_5 = (\sum_a C_{a5} - C_{55})/N$ là tỷ lệ toàn bộ ảnh bị gán sai vào lớp này. Precision lớp 5 đo phần dự đoán 80 km/h thực sự đúng. Mỗi chỉ số được tính riêng từng lượt rồi tổng hợp theo noise seed và checkpoint.

Bảng 20. Tập trung dự đoán vào lớp 5 ở mức nặng, đơn vị %. Hai cột đầu lấy mẫu số là toàn bộ 12.630 ảnh/lượt; precision dùng số ảnh được dự đoán lớp 5.

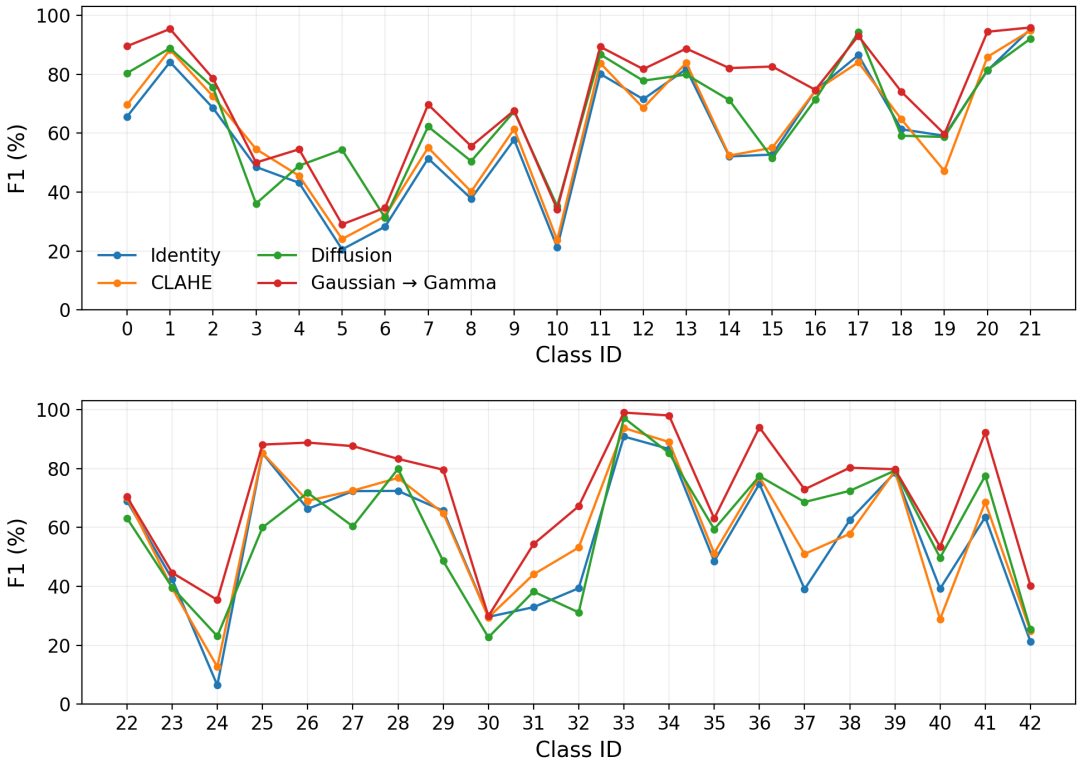
Phương pháp	Dự đoán lớp 5	Gán sai vào lớp 5	Precision lớp 5
Identity	43.17	38.32	11.51
CLAHE	34.52	29.82	13.83
Diffusion	8.99	5.21	42.58
Gaussian → Gamma	28.97	24.14	17.16

Identity dự đoán lớp 5 cho 43,17% ảnh, trong khi tỷ lệ thật của lớp này chỉ là 4,99%. Có 38,32% toàn bộ ảnh bị gán sai vào lớp này. Gaussian rồi Gamma giảm tỷ lệ dự đoán lớp 5 còn 28,97%, nhưng mức tập trung vẫn cao và precision lớp 5 chỉ đạt 17,16%. Diffusion có tỷ lệ dự đoán lớp 5 thấp hơn, ở mức 8,99%, dù Macro-F1 tổng thể thấp hơn chuỗi được chọn. Do đó, phương pháp có điểm trung bình tốt hơn chưa chắc giảm tốt nhất mọi kiểu lỗi.

Cột 5 đậm trong ma trận và các cặp nhầm từ lớp 10/6/30 sang lớp 5 cho thấy mô hình có xu hướng dồn dự đoán vào một lớp khi ảnh suy giảm nặng. Nhóm xem mất tương phản, nét số nhỏ và sự khác biệt của ảnh đầu vào so với dữ liệu huấn luyện là những giả thuyết cần kiểm tra. Ma trận chưa xác định nguyên nhân riêng là màu hay hình dạng. Nhóm cũng chưa đo đáp ứng bên trong mạng, độ nhạy theo vùng hoặc so sánh phân bố train, nên chưa quy trực

tiếp hiện tượng này cho mất cân bằng lớp. Sáu ảnh ở phần sau minh họa cả lỗi được sửa và trường hợp 60 bị nhầm thành 80 km/h sau xử lý.

5.6.4. Các lớp khó và ví dụ có metadata



Hình 12. F1 từng lớp mức nặng trên full-test, tách lớp 0–21 và 22–42 để dễ đọc. Trung bình noise trong checkpoint rồi trung bình ba checkpoint; không phải khoảng tin cậy của camera thực.

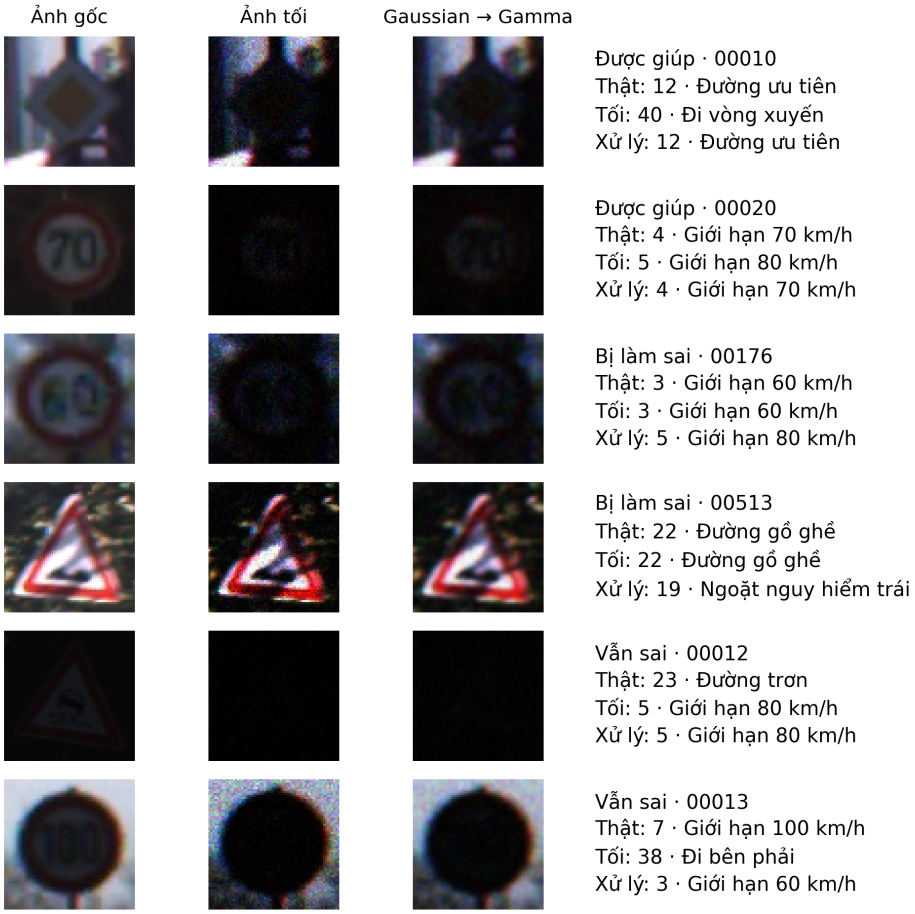
Bảng 21. Năm lớp có F1 thấp nhất của Gaussian rồi Gamma mức nặng. SD qua checkpoint sau trung bình noise; chênh lệch so Identity là điểm phần trăm.

Class ID	F1 (%)	SD	Δ F1
5	29.04	5.13	8.50
30	29.92	2.49	0.26
10	34.17	3.71	12.95
6	34.67	3.01	6.41
24	35.41	4.06	28.97

Mặc dù Macro-F1 tăng, một số lớp vẫn có F1 thấp. Nhóm cần đọc những lớp này cùng số ảnh thực tế, cặp nhầm và ảnh nguồn. Chỉ nhìn ma trận thì chưa thể khẳng định một cặp nhầm là do mất nét số hay sai màu. Nhóm cần quan sát ảnh cụ thể và có thêm phép kiểm tra để xác nhận những giả thuyết đó.

5.6.5. Đối chiếu trực quan sáu mẫu kiểm chứng

Nhóm chọn các mẫu trong Hình 13 từ toàn bộ test ở mức vừa, sử dụng checkpoint 11 và noise seed 101. Mỗi nhóm lấy hai ID nhỏ nhất. Nhóm cắt lại ảnh PPM chính thức theo đúng ROI, lề và phép nội suy của thí nghiệm. Cả 12 dự đoán trên ảnh tối và ảnh đã xử lý đều khớp CSV đã kiểm chứng. Nhóm còn đối chiếu nhãn của sáu ảnh với chú thích chính thức.



Hình 13. Ảnh gốc, ảnh tối và Gaussian rồi Gamma trên cùng sáu mẫu GTSRB [5]. Tên biển đi kèm Class ID; ID ảnh là phần cuối của `gtsrb/test/<ID>`. Các ảnh dùng cùng thang RGB, phóng bằng láng giềng gần nhất, không tự cân bằng sáng để hiển thị.

Được giúp: Với ảnh 00010, mô hình đổi từ dự đoán vòng xuyến sang đúng đường ưu tiên. Với ảnh 00020, dự đoán đổi từ giới hạn 80 sang đúng 70 km/h. Nhóm quan sát thấy nhiễu hạt giảm sau lọc, dù ảnh đầu ra vẫn tối. Hai ví dụ này cho thấy nhận dạng đúng không đòi hỏi ảnh phải sáng rõ hoàn toàn.

Bị làm sai: Với ảnh 00176, mô hình đang đoán đúng 60 nhưng đổi thành 80 km/h sau xử lý. Ảnh 00513 đổi từ đúng đường gồ ghề sang ngoặt trái. Ảnh đã lọc có ít hạt hơn, nhưng các nét nhỏ vẫn mềm. Nhóm vì vậy không thể coi giảm nhiễu là bảo đảm giữ được đặc trưng phân lớp.

Vẫn sai: 00012 và 00013 còn rất tối sau xử lý, nét biểu tượng và chữ số chưa rõ đủ để dự đoán đúng. Hình cho phép quan sát hiện tượng, chưa xác định pixel hoặc cơ chế nào gây ra quyết định của CNN. Sáu mẫu không thay thế thống kê toàn tập.

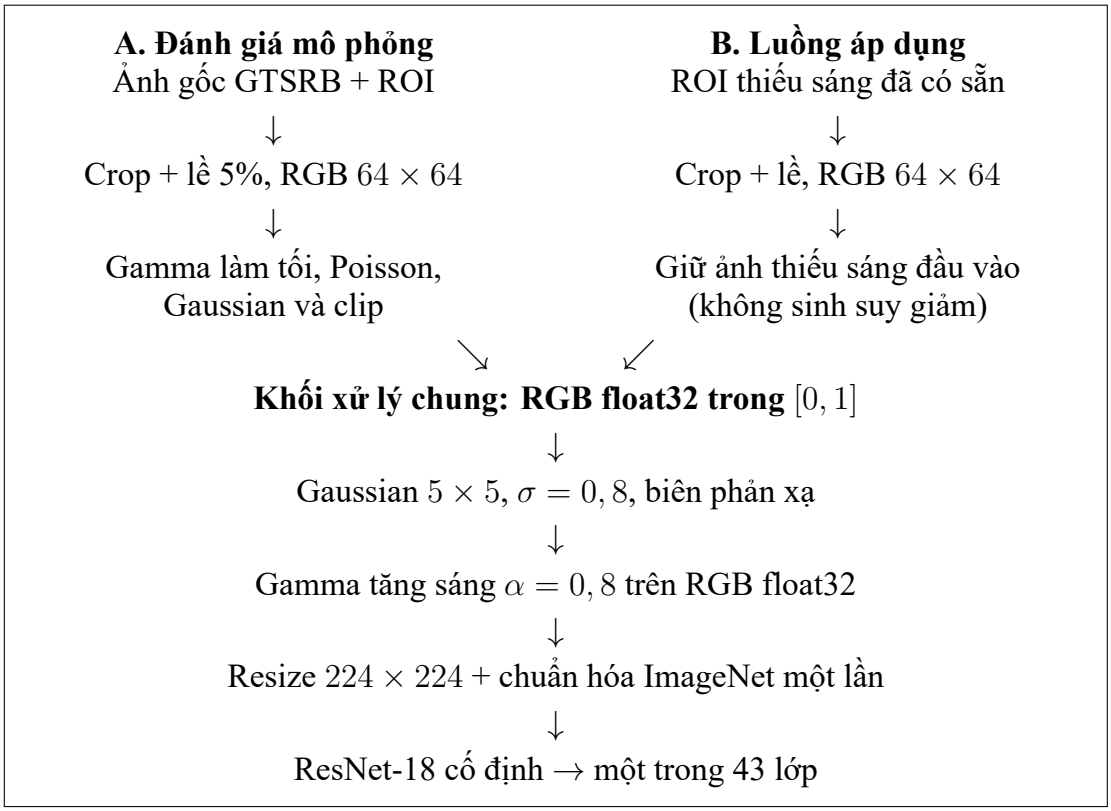
6. ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ

6.1. Tiêu chí lựa chọn

Nhóm lựa chọn quy trình theo mục tiêu nhận dạng đủ 43 lớp biển báo, nên dùng Macro-F1 trên validation làm tiêu chí chính. Accuracy và Weighted-F1 được dùng để kiểm tra thêm. PSNR và SSIM giúp giải thích ảnh đã thay đổi như thế nào, nhưng không thay thế kết quả nhận dạng. Trong nhóm tăng sáng, diffusion được chọn trước. Sau khi khảo sát thêm khử nhiễu và thứ tự kết hợp, Gaussian rồi Gamma đạt Macro-F1 validation cao nhất là 77,77% và được chọn để đánh giá test.

Quy trình được chọn không nhất thiết đạt điểm cao nhất ở mọi mức test. Chẳng hạn, CLAHE rồi Gaussian nhỉnh hơn ở mức nặng. Nếu nhóm đổi lựa chọn sau khi đọc kết quả này, tập test sẽ không còn giữ đúng vai trò kiểm tra cuối cùng. Nếu mục tiêu ứng dụng có thêm giới hạn về độ trễ, nhóm cũng cần đặt tiêu chí đó trước và lựa chọn bằng validation.

6.2. Quy trình được lựa chọn



Hình 14. Hai nguồn đầu vào dùng chung chuỗi được chọn trên validation. Chỉ nhánh A sinh suy giảm và dùng ảnh gốc để tính PSNR/SSIM ở 64×64; nhánh B mô tả cách áp dụng, chưa được đánh giá trên ảnh camera thực.

Khi áp dụng cho ảnh thiếu sáng đã có sẵn, nhóm chỉ chuẩn bị ảnh rồi đưa vào khối lọc và Gamma, không tạo thêm suy giảm. Luồng này giả định vùng biển báo đã được cung cấp và chưa có mô hình phát hiện vị trí. Nhãn và ảnh sáng tham chiếu không được đưa vào chuỗi

xử lý. Chỉ bộ đánh giá dùng chúng để đo chất lượng và kiểm tra phân loại. Trong cài đặt, bộ lọc dùng `BORDER_REFLECT_101`, và chuỗi Gaussian–Gamma không chuyển ảnh sang 8 bit.

Nhóm kiểm tra ảnh đầu ra về kích thước, số kênh, miền giá trị và các giá trị không hữu hạn. Ba checkpoint nhận dạng được giữ nguyên, không cập nhật theo ảnh test. Dù điểm validation và F1 test được cải thiện, nhóm chưa xem đây là bảo đảm an toàn cho một hệ thống hỗ trợ lái xe thực tế.

6.3. Đối chứng và tổ chức cài đặt

Nhóm dùng Identity, Gamma, CLAHE, diffusion và Gaussian đơn lẻ để phân biệt lợi ích của các thành phần. Khi so hai thứ tự Gaussian–CLAHE, nhóm giữ clip limit 1, lưới 4×4 và cùng tham số Gaussian. Nếu đồng thời thay đổi cả độ mạnh và thứ tự, nhóm sẽ khó xác định chênh lệch đến từ yếu tố nào.

Mã tạo suy giảm nằm trong `src/degradation.py`, còn các bộ tăng cường nằm trong `src/enhancement.py`. Nhóm cài đặt chuỗi kết hợp tại `src/tools/processing_pipeline.py` và dùng `src/tools/processing_study.py` để chọn tham số, cố định giao thức đánh giá. Tệp `src/metrics.py` tính các chỉ số, còn `configs/` lưu cấu hình. Kết quả đi kèm tham số, cách chia tập, mã ảnh và hash checkpoint để người đọc có thể kiểm tra từng phép so sánh.

6.4. Hướng đánh giá tiếp theo

Nếu tiếp tục đề tài, nhóm sẽ ưu tiên bổ sung ảnh thiếu sáng thực có nhãn biển báo phù hợp. Nhóm cần xem các lỗi về nét số, đường viền và màu, sau đó mở rộng sang ảnh toàn cảnh có mô hình phát hiện biển báo. Khi không có ảnh sáng ghép cặp chính xác, nhóm không thể tính PSNR và SSIM theo cách của thí nghiệm tổng hợp. Nhóm cũng cần thử thêm kiến trúc nhận dạng, điều kiện chụp và lần huấn luyện độc lập. Nếu xác minh được track test, nhóm nên lấy mẫu lại theo track thay vì từng ảnh. Khoảng bootstrap hiện tại chưa tính được nguồn phụ thuộc này.

6.5. Tái lập thực nghiệm

6.5.1. Mã nguồn và môi trường

Notebook công khai kèm mã và cấu hình:

https://www.kaggle.com/code/kieuthithutrang/gtsrb-low-light-enhancement-for-traffic-signs

Nhóm tải dữ liệu từ archive GTSRB chính thức. Mã và trọng số pretrained của các mô hình tăng cường được ghi nguồn, commit và SHA-256 để xác định phiên bản. Trong các phép so sánh, nhóm giữ nguyên cách chia tập, mã ảnh, mức suy giảm, noise seed và ba checkpoint. Tham số xử lý được chọn trên validation trước khi chạy test. Người đọc có thể xem hướng dẫn chạy trong `README.md` và các cấu hình trong `configs/`.

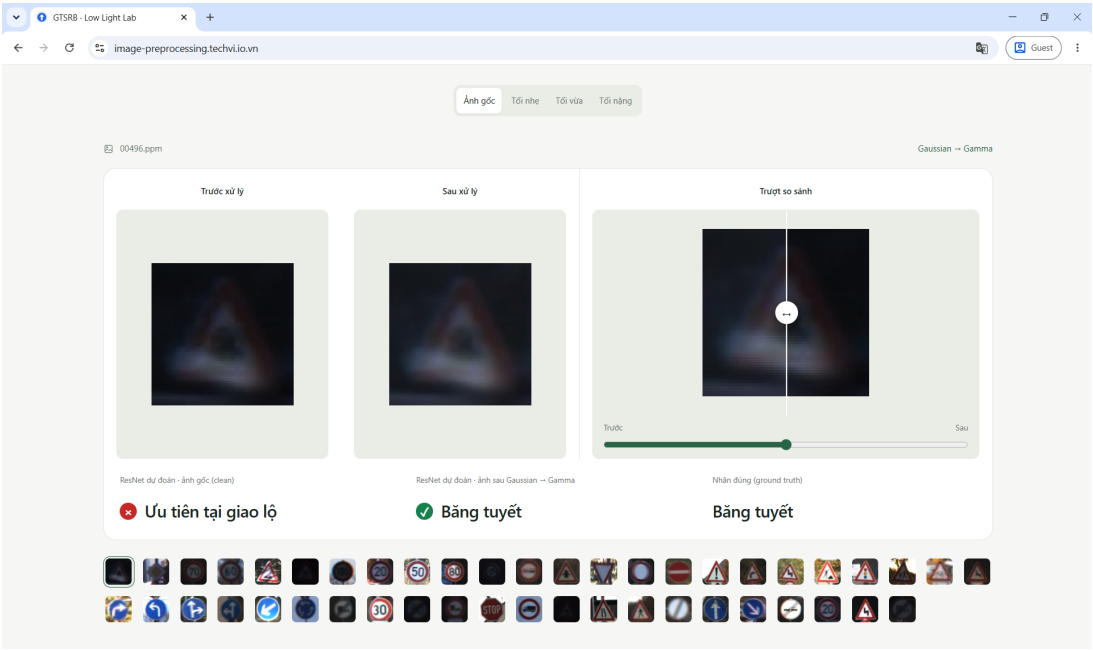
6.5.2. Bằng chứng và tính nhất quán

Gói kết quả lưu giao thức, trạng thái chạy, dự đoán CSV và ma trận nhầm lẫn NPZ. Nhóm đã tính lại Accuracy, Macro-F1 và Weighted-F1 từ 5.847.990 dòng dự đoán thuộc bốn phạm vi. Sai số so với bảng tổng hợp không quá 10^{-8}, và hash ba CNN khớp giữa các phạm vi. Những đối chứng dùng lại đều được ghi nguồn, không xem là quan sát độc lập mới. Việc đối chiếu nhãn và group ID giữa các lượt giúp kiểm tra tính nhất quán, nhưng không thay thế kiểm tra nhãn trên ảnh nguồn.

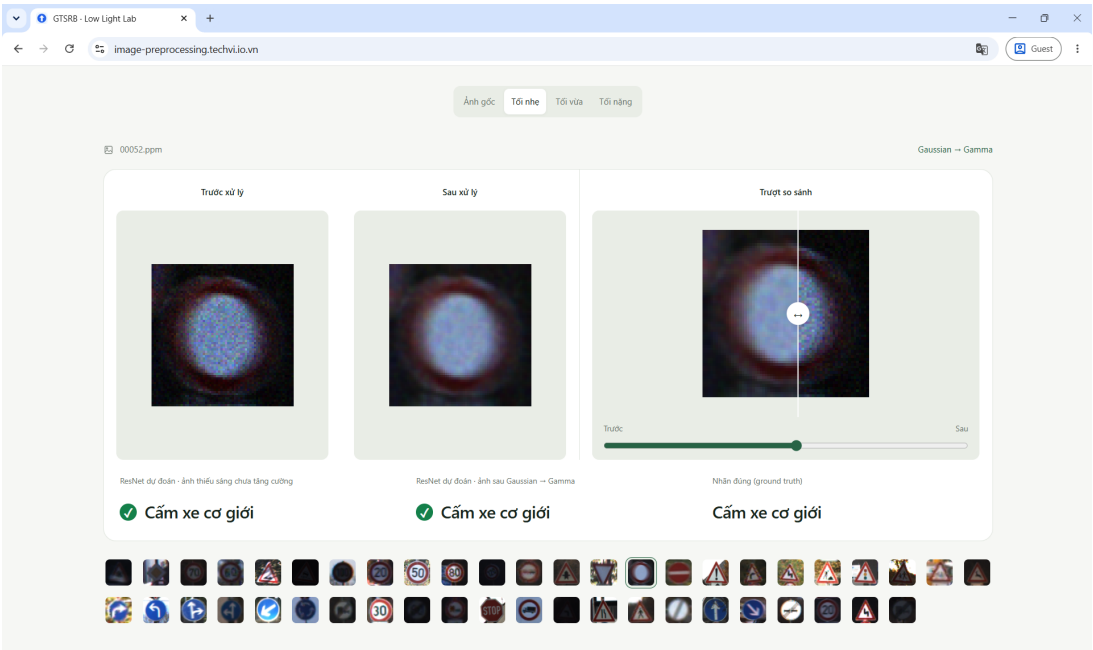
Nhóm lưu bằng chứng và thông tin nguồn trong `report/evidence/final/`. ZIP kết quả không chứa ảnh GTSRB, cache hoặc trọng số pretrained của các mô hình tăng cường. Người chạy lại cần lấy những đầu vào đó theo nguồn và cấu hình đã ghi. ZIP vẫn giữ các checkpoint CNN do nhóm huấn luyện. SHA-256 giúp phát hiện file có thay đổi, nhưng tự nó không chứng minh kết luận nghiên cứu là đúng.

6.6. Website demo

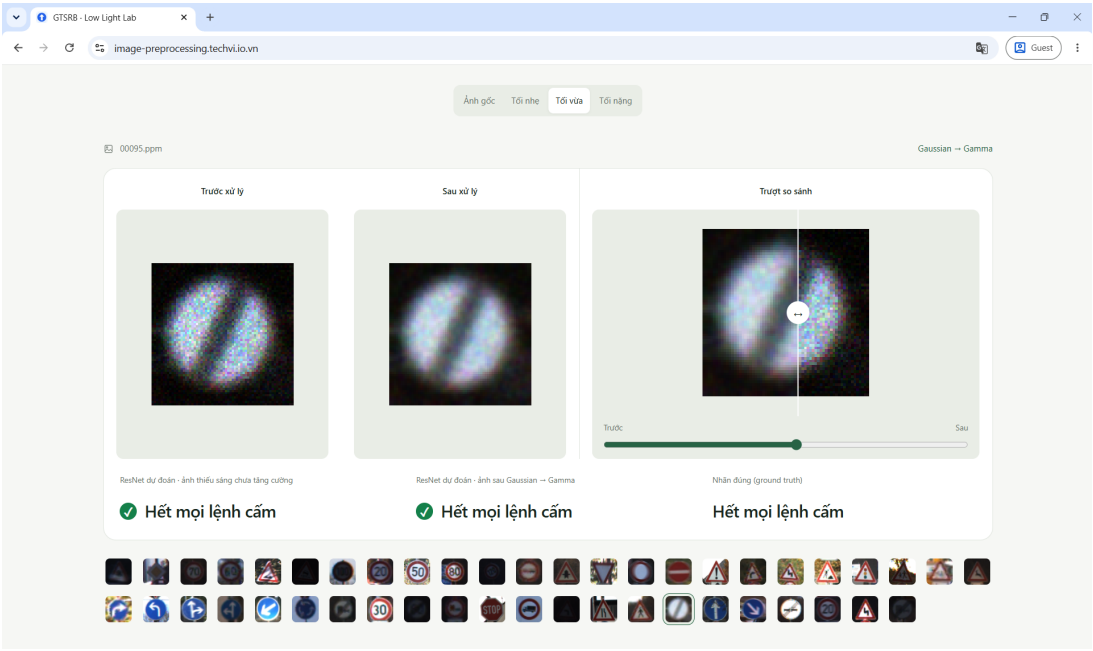
Website tại https://image-preprocessing.techvi.io.vn cho phép chọn ảnh và mức suy giảm, so sánh trước–sau Gaussian → Gamma, đối chiếu dự đoán ResNet-18 với nhãn đúng.



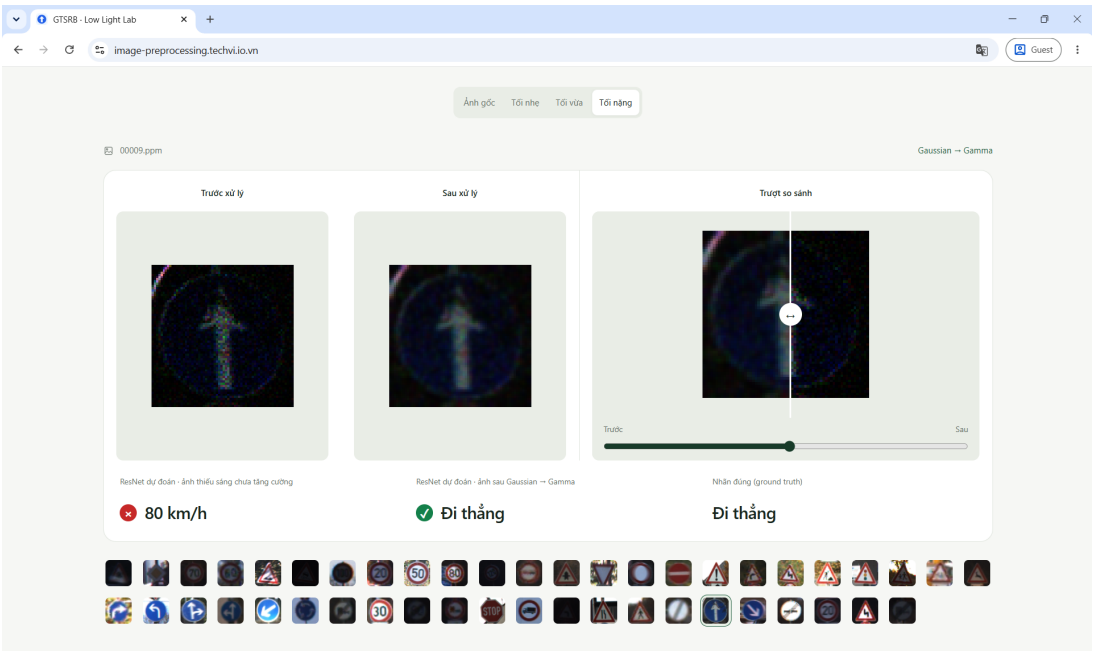
Hình 15. Demo với ảnh gốc 00496.ppm: dự đoán đổi từ "Ưu tiên tại giao lộ" sang đúng nhãn "Băng tuyết" sau xử lý.



Hình 16. Demo với ảnh tối nhẹ 00052.ppm: nhãn "Cấm xe cơ giới" được dự đoán đúng cả trước và sau xử lý.



Hình 17. Demo với ảnh tối vừa 00095.ppm: dự đoán giữ đúng nhãn "Hết mọi lệnh cấm" sau xử lý.



Hình 18. Demo với ảnh tối nặng 00009.ppm: dự đoán sai "80 km/h" trước xử lý được sửa thành đúng nhãn "Đi thẳng".

Nguồn: Ảnh chụp website demo của nhóm. Các ví dụ minh họa thuộc bộ mẫu demo, không dùng để ước lượng tỷ lệ cải thiện trên toàn bộ dữ liệu.

7. KẾT LUẬN

Trong bài tập lớn này, nhóm đã khảo sát các phương pháp tăng cường ảnh, khử nhiễu và thứ tự kết hợp khi nhận dạng 43 lớp biển báo GTSRB. Nhóm tạo ảnh thiếu sáng bằng Gamma kết hợp Poisson và Gaussian ở ba mức. Các phép xử lý sử dụng cùng ảnh đầu vào và ba checkpoint ResNet-18 đã giữ cố định. Nhóm lựa chọn tham số và danh sách phương pháp đánh giá toàn bộ test bằng validation trước khi chạy test.

Trong nhóm tăng sáng, diffusion được chọn theo quy tắc đánh giá validation. Khi xét thêm khử nhiễu và kết hợp, chuỗi Gaussian 5×5, $\sigma = 0,8$ rồi Gamma $\alpha = 0,8$ đạt Macro-F1 validation 77,77% và được chọn. Trên 12.630 ảnh test, chuỗi đạt Macro-F1 lần lượt là 96,70%, 85,54% và 71,56% ở ba mức suy giảm. So với ảnh tối giữ nguyên, mức tăng tương ứng là 6,25, 9,47 và 13,19 điểm phần trăm. Dù có cải thiện, ảnh thiếu sáng nặng vẫn là trường hợp khó đối với mô hình.

Qua kết quả, nhóm nhận thấy PSNR và SSIM chưa thể thay thế đánh giá nhận dạng. Ở mức nặng, Gaussian đơn lẻ có cả PSNR và SSIM thấp hơn diffusion nhưng F1 cao hơn. Trong thí nghiệm ablation, MSR đạt 98,36% khi chỉ có Gamma làm tối, nhưng còn 57,84% khi ảnh có cả hai loại nhiễu. Những kết quả này cho thấy ảnh sáng hơn hoặc có một chỉ số ảnh tốt hơn chưa đủ để kết luận các chi tiết phân biệt lớp đã được giữ lại.

Ảnh hưởng của thứ tự còn phụ thuộc bộ lọc, phép tăng sáng và cấu hình cụ thể. Trên toàn bộ test, cặp Gaussian–CLAHE có chênh lệch trung bình nhỏ theo hướng CLAHE rồi Gaussian tốt hơn, nhưng một số lượt lại cho kết quả ngược lại. Các khoảng bootstrap 95% chỉ lấy mẫu ảnh nằm trên 0, còn các khoảng lấy mẫu thêm checkpoint đều chứa 0. Vì vậy, nhóm chưa có đủ bằng chứng để khẳng định ưu thế này ổn định khi huấn luyện lại. Nhóm cũng chưa xác định được một thứ tự tốt nhất cho mọi phương pháp. Ở mức vừa, chuỗi được chọn sửa đúng trung bình 1472,67 ảnh nhưng làm sai 29,22 ảnh mỗi lượt. Do đó, khi đánh giá lợi ích, nhóm cần xem cả những lỗi mới phát sinh.

Đóng góp của nhóm là triển khai, kiểm tra và so sánh các phép xử lý trong điều kiện có kiểm soát, chưa phải đề xuất thuật toán mới. Các kết quả giúp nhóm lựa chọn tiền xử lý theo khả năng nhận dạng thay vì chỉ nhìn độ sáng đầu ra. Tuy nhiên, kết luận mới áp dụng cho ROI GTSRB với suy giảm mô phỏng, một kiến trúc CNN và lưới tham số hữu hạn. Nhóm chưa chứng minh hiệu quả trên camera ban đêm thực, video hoặc hệ thống cảnh báo trong xe. Đây là những phần cần bổ sung nếu phát triển đề tài theo hướng ứng dụng.

——— HẾT ———

TÀI LIỆU THAM KHẢO

[1] C. Guo *et al.*, "Zero-reference deep curve estimation for low-light image enhancement," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2020, pp. 1780–1789, doi: 10.1109/CVPR42600.2020.00185.

[2] Y. Cai, H. Bian, J. Lin, H. Wang, R. Timofte, and Y. Zhang, "Retinexformer: One-stage Retinex-based Transformer for low-light image enhancement," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, 2023, pp. 12504–12513, doi: 10.1109/ICCV51070.2023.01149.

[3] H. Jiang, A. Luo, H. Fan, S. Han, and S. Liu, "Low-light image enhancement with wavelet-based diffusion models," *ACM Trans. Graph.*, vol. 42, no. 6, Dec. 2023, Art. no. 238, doi: 10.1145/3618373.

[4] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "The German Traffic Sign Recognition Benchmark: A multi-class classification competition," in *Proc. Int. Joint Conf. Neural Netw. (IJCNN)*, 2011, pp. 1453–1460, doi: 10.1109/IJCNN.2011.6033395.

[5] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "German Traffic Sign Recognition Benchmark GTSRB," public dataset archive. Accessed: Oct. 24, 2026. [Online]. Available: https://sid.erda.dk/public/archives/daaeac0d7ce1152aea9b61d9f1e19370/published-archive.html

[6] OpenCV, "Histograms - 2: Histogram equalization." Accessed: Oct. 19, 2026. [Online]. Available: https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html

[7] K. Zuiderveld, "Contrast limited adaptive histogram equalization," in *Graphics Gems IV*, P. S. Heckbert, Ed. Academic Press, 1994, pp. 474–485, doi: 10.1016/B978-0-12-336156-1.50061-6.

[8] D. J. Jobson, Z. Rahman, and G. A. Woodell, "A multiscale retinex for bridging the gap between color images and the human observation of scenes," *IEEE Trans. Image Process.*, vol. 6, no. 7, pp. 965–976, July 1997, doi: 10.1109/83.597272.

[9] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," *IEEE Trans. Image Process.*, vol. 13, no. 4, pp. 600–612, Apr. 2004, doi: 10.1109/TIP.2003.819861.

[10] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 6840–6851. [Online]. Available: https://arxiv.org/abs/2006.11239

[11] C. Tomasi and R. Manduchi, "Bilateral filtering for gray and color images," in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 1998, pp. 839–846, doi: 10.1109/ICCV.1998.710815.

[12] A. Buades, B. Coll, and J.-M. Morel, “A non-local algorithm for image denoising,” in *Proc. IEEE Computer Society Conf. Computer Vision and Pattern Recognition (CVPR)*, vol. 2, 2005, pp. 60–65, doi: 10.1109/CVPR.2005.38.

[13] OpenCV, “Smoothing images.” Accessed: Oct. 24, 2026. [Online]. Available: https://docs.opencv.org/4.x/d4/d13/tutorial_py_filtering.html

[14] OpenCV, “Image denoising.” Accessed: Oct. 24, 2026. [Online]. Available: https://docs.opencv.org/4.x/d5/d69/tutorial_py_non_local_means.html

[15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[16] B. Efron, “Bootstrap methods: Another look at the jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979, doi: 10.1214/aos/1176344552.